

Eksploracyjna analiza danych, statystyka i przygotowanie danych

Wykład przygotowujący do Olimpiady Sztucznej Inteligencji

Marta Pałgielska

19.09.2026


Gdzie znaleźć dodatkowe materiały o AI?

kaggle™

Sebastian Raschka


GeeksforGeeks

Literatura



Biblioteki do analizy danych



biblioteka do wczytywania,
czyszczenia i analizy danych

Series – jedna kolumna

DataFrame – tabela

Typowe operacje:
filtrowanie i sortowanie
obsługa braków
grupowanie i agregacja
statystyki opisowe
łączenie zbiorów danych





biblioteka do wizualizacji danych

Umożliwia tworzenie m.in.:
wykresów liniowych
słupkowych
histogramów
scatter plotów
boxplotów

Jakie mogą być formaty danych?





 jpg, mp4 etc.

Typy danych

Dane numeryczne

wartości wyrażone liczbami, na których można wykonywać działania matematyczne.

Ciągłe – mogą przyjmować dowolną wartość w zakresie

np. temperatura: 36,7°C, masa: 72,4 kg

Dyskretne – przyjmują określone, najczęściej całkowite wartości

np. liczba wizyt: 4, liczba produktów: 12

Dane kategoryczne

opisują przynależność do określonej grupy lub klasy.

Nominalne – bez naturalnej kolejności
np. kolor, kraj, typ urządzenia

Porządkowe – kategorie mają określoną kolejność
np. niski → średni → wysoki

Binarne – tylko 2 możliwe wartości
np. tak/nie, 0/1

Gdzie znaleźć dane?

kaggle



Przygotowanie Danych




errors

inconsistent
data

NaN

outliers

Przygotowanie Danych



GLOBAL WARMING

<https://knowyourmeme.com/photos/2104681-okbuddyretard>

Etapy czyszczenia danych

- ✓ ogarnięcie NaN-ów
- ✓ poprawa niespójności (np. Male/M/man)
- ✓ usunięcie duplikatów
- ✓ usunięcie zbędnych kolumn
- ✓ poprawa typów danych (float, datetime)
- ✓ ogarnięcie outlierów
- ✓ walidacja logiczna
- ✓ normalizacja/standaryzacja



Obsługa brakujących danych

Brakujące dane, czyli wartości NaN, None lub puste pola w zbiorze danych.

- 1 Identyfikacja braków: sprawdzenie liczby/% braków w kolumnach za pomocą np. `isna()`, `isnull()`
- 2 Usuwanie braków za pomocą `dropna()`, czyli usunięcie wierszy lub kolumn z brakami. Sensowne, gdy braków jest mało i ich usunięcie nie zniekształca danych
- 3 Uzupełnianie braków, czyli imputacja
dane numeryczne → średnia, mediana
dane kategoryczne → moda, "Unknown"
przykład: `fillna()`
- 4 Czasem informacja o samym braku
można dodać kolumnę typu `was_missing = 0/1`
sam fakt braku może być czasem istotną cechą dla modelu

Kodowanie danych kategorycznych

Modele ML zazwyczaj pracują na liczbach, dlatego kategorie tekstowe trzeba przekształcić do postaci numerycznej.

Label Encoding

każda kategoria → liczba
kot → 0, pies → 1, koń → 2
dobre głównie dla danych
porządkowych
przy danych nominalnych może
sztucznie sugerować kolejność

One-Hot Encoding

każda kategoria → osobna
kolumna 0/1
kolor = czerwony → [1, 0, 0]
dobre dla danych nominalnych
wada: dużo kategorii to dużo
nowych kolumn

Ordinal Encoding

przypisujemy liczby zgodnie z
rzeczywistą kolejnością
niski → 0, średni → 1, wysoki → 2

Skalowanie

przekształcanie cech numerycznych tak,
aby miały porównywalny zakres wartości




Po co skalować?

- żeby cechy o dużych wartościach nie dominowały nad pozostałymi
- żeby poprawić działanie algorytmów opartych na odległości i gradientach
- dla szybszego/stabilniejszego uczenia modelu


Przygotowanie Danych

STANDARYZACJA



średnia = 0
odchylenie = 1

NORMALIZACJA



wartości z zakresu [0,1]

Standaryzacja Danych

Aby sprowadzić dane do rozkładu normalnego:

- Wczytujemy dane,
- Z całego przedziału danych odczytujemy średnią i odchylenie standardowe,
- Wykonujemy standaryzację: $S = (\text{dane} - \text{średnia}) / \text{odchylenie}$.

Aby przywrócić dane do stanu przed standaryzacją:

- Wczytujemy parametry użyte w standaryzacji
- $\text{dane} = S * \text{odchylenie} + \text{średnia}$

Standaryzacja Danych

```
import numpy as np
import numpy.typing as npt

# dane = []
# for _ in range(10):
#     dane.append(np.random.randint(-4,10))

# Generujemy losowe liczby całe z zakresu [-4; 10)
dane: list[int] = [np.random.randint(-4, high: 10) for _ in range(10)] # ← Komprehensja list. Analog w komentarzu wyżej
dane_array: npt.NDArray = np.array(dane) # Konwersja na np.NDArray


def standaryzacja(dane: npt.NDArray) → tuple[npt.NDArray, tuple[np.float64, np.float64]]: 1 usage
    srednia: np.float64 = dane.mean()
    odchylenie: np.float64 = dane.std()
    return (dane - srednia) / odchylenie, (srednia, odchylenie)


def przywrocenie_standaryzacji(standaryzowane: npt.NDArray, srednia: np.float64, odchylenie: np.float64) → npt.NDArray:
    return standaryzowane * odchylenie + srednia


print(f"Dane wejściowe: {dane_array}")
standaryzowane, parametry = standaryzacja(dane_array)
print(f"Dane standaryzowane: {standaryzowane}\nŚrednia: {parametry[0]}\nSTD: {parametry[1]}")
przywroczone_dane = przywrocenie_standaryzacji(standaryzowane, *parametry)
print(f"Przywrócone dane: {przywroczone_dane}")
```

Przykład standaryzacji, Jakub Susoł

Standaryzacja

średnia 0 z odchyleniem 1

różne jednostki lub zakresy żeby zachować porównywalny wpływ (normalizacja spłaszcza różnice)

outliery są istotne

metoda zakłada rozkład normalny lub używa odległości euklidesowej

np. HCA, PCA, regresja, metody oparte o macierze kowariancji

KIEDY?

Normalizacja

wartości w przedziale $[0, 1]$

ważne rzeczywiste proporcje wartości (np. obrazy)


metody oparte na odległości Manhattan

np. sieci neuronowe (szybsza nauka), KNN, gradient boosting

Amazon's AI Recruiting Tool: seksizm wbudowany w dane



Amazon's AI Recruiting Tool: seksizm wbudowany w dane



Czy to wina modelu czy danych?

Czy można było to naprawić?

Czy rekrutacja przez AI może być w ogóle sprawiedliwa?

JAKOŚĆ DANYCH JEST KLUCZOWA DLA MODELU!



EDA

(Exploratory Data Analysis)



CEL:

zrozumienie rozkładu,
zależności i problemów




EDA

(Exploratory Data Analysis)



statystyki opisowe



rozkłady, histogramy



rozkład klas



korelacje



wizualizacje outlierów
(boxplot, scatter plot)

Statystyki opisowe

Służą do szybkiego poznania rozkładu i jakości danych przed budową modelu.

Miary położenia

średnia – przeciętna wartość
mediana – wartość środkowa
moda – najczęściej występująca wartość


Miary rozproszenia

min/max – zakres wartości
range = max - min
wariancja – zróżnicowanie danych
odchylenie standardowe – typowe
odchylenie od średniej
IQR = $Q3 - Q1$ – rozstęp
międzykwartyłowy
Kwantyle
Q1 – 25%
Q2 – 50% = mediana
Q3 – 75%


Dla danych kategorycznych

liczba unikalnych wartości
częstość występowania kategorii
najczęstsza kategoria



Rozkład



Czy jest normalny?



Histogramy



W jaki sposób dane są rozłożone w danej serii, np. ilość napiwków, gęstość trójglicerydów itp. Zwykle są wykonywane tylko dla jednej zmiennej

Rozkład klas

Pokazuje, ile obserwacji należy do każdej klasy zmiennej docelowej.

Przykład:

klasa 0 = 900 obserwacji

klasa 1 = 100 obserwacji

Więc mamy niezbalansowany zbiór danych


Dlaczego to ważne?

model może preferować klasę dominującą,
wysoka accuracy może być myląca,
trzeba sprawdzać też precision, recall, F1-score.


Jak sprawdzić?

```
df["target"].value_counts()
```

```
df["target"].value_counts(normalize=True)
```




Scatter Plot



Wykres relacji dla dwóch zmiennych, przedstawiający wzajemną zależność pomiędzy danymi.


Scatter Plot



Kwartet Anscomba – jak rozkład danych może się różnić dla zbiorów o takiej samej średniej, odchyleniu, równaniu regresji i współczynniku korelacji

https://pl.wikipedia.org/wiki/Kwartet_Anscombe'a

Korelacje



Jak zmiana jednej zmiennej wpływa na wartości drugiej

<https://towardsdatascience.com/a-data-scientists-essential-guide-to-exploratory-data-analysis-25637eee0cf6>

Korelacja

miara zależności pomiędzy zmiennymi

Ze względu na kierunek:

dodatnia = wzrost jednej zmiennej wiąże się ze wzrostem drugiej

ujemna = wzrost jednej zmiennej wiąże się ze spadkiem drugiej

brak korelacji = brak wyraźnej zależności

Ze względu na siłę:

0.0–0.3 = słaba

0.3–0.5 = umiarkowana

0.5–0.7 = silna

0.7–1.0 = bardzo silna

Korelacja nie oznacza przyczynowości!

Przetwarzanie danych sekwencyjnych

Forward fill

uzupełnia brakującą wartość ostatnią znaną wartością

przydatne w szeregach czasowych, gdy stan utrzymuje się do kolejnego pomiaru

np. 10, NaN, NaN, 14 → 10, 10, 10, 14

w Pandas: `ffill()`

Padding danych o różnej długości

wyrównuje długość sekwencji przed podaniem ich do modelu

krótsze sekwencje są uzupełniane specjalną wartością, np. 0

pre-padding → uzupełnianie na początku

post-padding → uzupełnianie na końcu

stosowane np. w NLP, RNN, LSTM i Transformerach

Cechy statystyczne w przesuwanych oknach

statystyki liczone dla kolejnych fragmentów sekwencji

np. okno z ostatnich 10 pomiarów

typowe cechy: średnia, mediana, min/max, odchylenie standardowe, trend/zmiana

pozwalają modelowi uchwycić lokalny kontekst i zmiany w czasie

np. sygnał czasowy → okno 10 próbek → mean, std, min, max → cechy dla ML

Klastrowanie

grupowanie podobnych obserwacji w klastry,
bez wcześniej podanych etykiet



Po co klastrować?

- odkrywanie naturalnych grup w danych
- wykrywanie podobnych wzorców
- pomoc w analizie danych bez etykiet


k-means be like:



Hierarchical Cluster Analysis (HCA)




HCA – Klastrowanie Hierarchiczne





To nic innego jak grupowanie osobników o podobnych cechach, zwykle obliczając dystans między punktami.

HCA - Miary Odległości



<https://www.maartengrootendorst.com/blog/distances/>

HCA - Dendrograms



węzły - skupienia
liście - obiekty

HCA – Metody łączenia

Single linkage (metoda najbliższego sąsiada) – odległość między dwoma klastrami to najmniejsza odległość między ich elementami.

Complete linkage (metoda najdalszego sąsiada) – używa największej odległości między elementami klastrów.

Metoda Warda – minimalizuje wzrost wariancji wewnątrz klastrów po połączeniu.

HCA – Metody łączenia

Single linkage – dobre, gdy klastry są wydłużone albo nieregularne, ale potrafi połączyć wszystko w jedno

Complete linkage – super, gdy chcesz mieć ładne, zwarte grupy i wyraźne granice; jeśli masz odstające punkty to działa gorzej

Average linkage – coś pomiędzy single a complete, sensowne, zbalansowane klastry, bezpieczny wybór

Ward – najlepsza, gdy masz dane liczbowe i chcesz, żeby klastry były jak najbardziej jednorodne, często wybierana w praktyce, bo daje czyste, równe grupy

HCA – Klastrowanie Hierarchiczne



HCA – w służbie policji

Andrzej Porębski¹

**Analiza skupień zorganizowanych grup przestępczych
jako przykład zastosowania metod statystycznych
w kryminologii**



Feature Engineering

tworzenie lub przekształcanie cech tak,
aby lepiej opisywały problem dla modelu

Sposoby:

- tworzenie nowych cech z istniejących, np. BMI = $\text{mas}/\text{wzrost}^2$
- agregacje
- średnia, suma, min, max
- cechy czasowe (dzień tygodnia, miesiąc, godzina)
- cechy z sekwencji
- interakcje między cechami
- transformacje matematyczne, np. log, sqrt
- grupowanie wartości do przedziałów, np. wiek = (18–30, 31–50, 51+)
- redukcja/wybór cech

**Wykonujemy tak, żeby nie używać informacji z test setu ani przyszłości
(zapobieganie data leakage)!**

THANK
YOU!