

Klasteryzacja i redukcja wymiarowości

Wykład przygotowujący do Olimpiady Sztucznej Inteligencji

Marta Pałgielska

03.10.2026

Czym jest klastrowanie?



Klastrowanie

grupowanie podobnych obserwacji w klastry,
bez wcześniej podanych etykiet



Po co klastrować?

- odkrywanie naturalnych grup w danych
- wykrywanie podobnych wzorców
- pomoc w analizie danych bez etykiet

k-means be like:




Czym jest podobieństwo?

Podobieństwo w klastrowaniu mówi, jak bardzo dwie obserwacje są do siebie zbliżone **na podstawie ich cech**.

Wynik klasteryzacji zależy od:


- wybranych cech,
- skali cech,
- metryki odległości,
- reprezentacji danych,
- algorytmu.



<https://www.maartengrootendorst.com/blog/distances/>

Klaster = grupa obiektów bardziej podobnych do siebie niż do obiektów spoza grupy.

Klastrowanie



<https://www.geeksforgeeks.org/machine-learning/clustering-in-machine-learning/>



Klasteryzacja nie odpowiada na pytanie „do której znanej klasy należy ten obiekt?”, tylko raczej „czy w tych danych naturalnie pojawiają się jakieś grupy?”


K-MEANS

Algorytm k-średnich

Metoda k-średnich jest metodą uczenia maszynowego bez nadzoru.


W podstawie leży taki dobór klastrów, aby łączna wariancja wszystkich klastrów była minimalna.

Wariancję tę określa się poprzez sumę kwadratów odległości pomiędzy każdą z obserwacji, a środkiem danego klastra.



Dobór ilości klastrów

Metoda punktu łokcia
(elbow method)



Dobór ilości klastrow


Metoda punktu łokcia
(elbow method)

Wykres to suma kwadratów odległości poszczególnych obserwacji od centroidów w funkcji ilości klastrow.

Zasada wyboru na podstawie wykresu jest bardzo podobna do wykresu osypiska stosowanego w analizie głównych składowych – wybieramy **takie k, dla którego wykres przestaje gwałtownie spadać**, a następne wartości są już do siebie zbliżone.

Dobór ilości klastrow

Metoda profilu
(silhouette method)



Dobór ilości klastrow

Metoda profilu (silhouette method)

Wartości wskaźnika sylwetki otrzymane dla metody profilu:

Dla $k = 2$ klastrow, Silhouette Score jest równy 0.4041

Dla $k = 3$ klastrow, Silhouette Score jest równy 0.3941

Dla $k = 4$ klastrow, Silhouette Score jest równy 0.3848

Dla $k = 5$ klastrow, Silhouette Score jest równy 0.3587

Dla $k = 6$ klastrow, Silhouette Score jest równy 0.3372

Dla $k = 7$ klastrow, Silhouette Score jest równy 0.3112

Dla $k = 8$ klastrow, Silhouette Score jest równy 0.3514

Dla $k = 9$ klastrow, Silhouette Score jest równy 0.3206

Dla $k = 10$ klastrow, Silhouette Score jest równy 0.3063

Wskaźnik sylwetki mówi o tym, jak poszczególny obiekt jest podobny do pozostałych w grupie oraz jak różny jest od obiektów w pozostałych grupach.

Za optymalną liczbę klastrow uważa się taką, dla której średnia wartość sylwetki jest największa, co w tej sytuacji dałoby $k=2$. Wskaźnik ocenia jakość grupowania, wartości w przedziale **0.71-1** pokazują **silne zgrupowanie**, **0.51-0.70** **umiarkowane** zgrupowanie, **0.26-0.50** **zgrupowanie słabe** (mogło zostać wytworzone sztucznie, należy spróbować dodatkowych metod analizy), **<0.25 brak znaczącego zgrupowania**.

Kroki algorytmu k-średnich

1

Ustalenie liczby skupień

2

Wyznaczenie wstępnych środków skupień (wstępnymi środkami skupień są losowo wybrane obiekty spośród danych)

3

Obliczenie odległości obiektów od środków skupień (w tym momencie następuje wybór typu odległości)

4

Przypisanie obiektów do skupień (obiekt zostaje przypisany do skupienia, do którego ma najmniejszą odległość)

5



Ustalenie nowych środków skupień

(nowym centroidem jest punkt, którego współrzędne są średnią arytmetyczną współrzędnych punktów należących do danego skupienia)

Wykonywanie kroków 3,4,5 do czasu, aż warunek zatrzymania zostanie spełniony

(algorytm kończy się po wykonaniu n założonych iteracji lub gdy środki skupień przestaną się zmieniać)

Przykład



K-MEANS++

Algorytm k-średnich ++

Problem zwykłego k-means:

losowe centroidy mogą trafić bardzo blisko siebie,
co może prowadzić do słabego lokalnego rozwiązania.

K-means++

wybiera początkowe centroidy bardziej inteligentnie, ponieważ
kolejne centroidy są preferencyjnie wybierane **dalej od już istniejących.**
To zwykle daje bardziej stabilny start.

KMeans(init="k-means++")



DENSITY-BASED SPATIAL CLUSTERING OF APPLICATIONS WITH NOISE

Algorytm DBSCAN

klastry tworzone są na podstawie lokalnej gęstości punktów,
nie trzeba wcześniej podawać liczby klastrów.

K-means: gdzie są środki klastrów?

DBSCAN: gdzie znajdują się gęste obszary danych?



Algorytm DBSCAN

Zalety

- **odporny na wpływ obserwacji odstających**
- **grupy o niewypukłym kształcie**
- **możliwość definiowania wielu miar odległości** – jest to problemem w przypadku np. k-średnich.

Wady

- **nie daje możliwości definiowania *a priori* liczby klastrów**
- problematyczny dobór parametrów wejściowych

Parametry wejściowe DBSCAN


epsilon (Eps) – promień sąsiedztwa, czyli minimalna odległość między dwiema obserwacjami, niezbędna do uznania ich za sąsiadów

min_samples (MinPoints) – minimalna liczba obserwacji potrzebna, aby wybrana obserwacja została uznana za punkt środkowy danej grupy (liczony jest również punkt środkowy)



DBSCAN



k-means



Klastrowanie hierarchiczne (HCA)



węzły – skupienia
liście – obiekty

Gaussian Mixture Models

Algorytm, w którym każdy klaster modelujemy jako rozkład Gaussa i dostajemy prawdopodobieństwo przynależności do poszczególnych komponentów.

K-means:

Punkt A należy do klastra 2.

GMM:

Punkt A należy do
w 70% do klastra 1,
w 29% do klastra 2,
w 1% do klastra 3.

Spectral clustering

Algorytm, w którym tworzymy graf podobieństwa między punktami.
Punkty to węzły, podobieństwa to krawędzie.
Wykorzystujemy strukturę grafu do znalezienia grup.




dobrze radzi sobie z nieliniową strukturą


może znaleźć klastry o dziwnych kształtach




większy koszt obliczeniowy

słabsza skalowalność do ogromnych datasetów






Redukcja wymiarów = wyciskarka



Po co nam redukcja wymiarów?





Klątwa wielowymiarowości



Klątwa wielowymiarowości

Wraz ze wzrostem liczby wymiarów:

dane stają się coraz rzadsze,

odległości między punktami tracą sens,

modele uczą się wolniej i łatwiej przeuczyć model,
rośnie koszt obliczeniowy.



Metody liniowe

PCA

(Principal Component Analysis)

najpopularniejsza, przekształca
dane w nowe, ortogonalne osie
maksymalnej wariancji

LDA

(Linear Discriminant Analysis)

uwzględnia przynależność do klas
optymalna dla klasyfikacji

ICA

(Independent Component Analysis)

szuka komponentów statystycznie
niezależnych

Metody nieliniowe

t-SNE

(t-distributed Stochastic Neighbor Embedding)

świetna do wizualizacji, zachowuje lokalną strukturę danych

UMAP

(Uniform Manifold Approximation and Projection)

szybsze od t-SNE, zachowuje więcej globalnej struktury

Isomap

oparta na geodezyjnych odległościach na kolektorze danych

Metody oparte o uczenie maszynowe

Autoenkodery (Autoencoders)

sieci neuronowe uczące się kompresji danych

Feature selection (np. LASSO, SelectKBest)

wybierają najważniejsze cechy bez tworzenia nowych

PRINCIPAL COMPONENT ANALYSIS

Analiza składowych głównych (PCA)

liniowa metoda redukcji wymiarów

Tworzy nowe zmienne - składowe główne (principal components) jako kombinacje liniowe oryginalnych cech. A każda kolejna składowa wyjaśnia możliwie dużo zmienności danych oraz jest prostopadła do poprzednich. PC1 wyjaśnia największą część wariancji, PC2 największą część pozostałej wariancji, potem PC3, PC4 itd.



Jak działa PCA?



1

Standaryzacja danych

2

Obliczenie macierzy kowariancji/korelacji

3


Wyznaczenie wektorów i wartości własnych

4

Wybór składowych głównych

5

Transformacja danych



Case study

Dane z Biura Statystyk Pracy ze Stanów Zjednoczonych.
Przedstawiają tygodniowe zarobki w 2020 roku z podziałem na stany.

Macierz korelacji

	Transformowana liczba pracowników	Transformowana mediana zarobków	Transformowana liczba kobiet pracujących	Mediana zarobków kobiet	Transformowana ilość mężczyzn pracujących	Mediana zarobków mężczyzn
Transformowana liczba pracowników	1.000000	0.287842	0.999026	0.300256	0.999373	0.262250
Transformowana mediana zarobków	0.287842	1.000000	0.284447	0.969466	0.290151	0.969635
Transformowana liczba kobiet pracujących	0.999026	0.284447	1.000000	0.299753	0.996842	0.260402
Mediana zarobków kobiet	0.300256	0.969466	0.299753	1.000000	0.300320	0.901497
Transformowana ilość mężczyzn pracujących	0.999373	0.290151	0.996842	0.300320	1.000000	0.263151
Mediana zarobków mężczyzn	0.262250	0.969635	0.260402	0.901497	0.263151	1.000000

Wektory i wartości własne

	Wektory własne					
Transformowana liczba pracowników	-0.419575	-0.396923	0.010384	0.019246	-0.814499	0.050215
Transformowana mediana zarobków	-0.403576	0.425013	-0.003109	0.735537	-0.002831	-0.339790
Transformowana liczba kobiet pracujących	-0.418716	-0.397564	0.000062	-0.305947	0.361194	-0.665248
Mediana zarobków kobiet	-0.398912	0.406232	-0.709910	-0.373295	0.000774	0.180341
Transformowana ilość mężczyzn pracujących	-0.419611	-0.395872	0.016430	0.284961	0.454001	0.616135
Mediana zarobków mężczyzn	-0.388015	0.426637	0.704017	-0.380078	0.002155	0.165289
Wartości własne	3.884728	2.006370	0.098145	0.008493	0.000001	0.002262
% Wyjaśnianej wariancji	64,75 %	33,43 %	1,64 %	0,14 %	0,00025 %	0,04 %

Macierz ładunków czynnikowych

	PC1	PC2	PC3	PC4	PC5	PC6
Transformowana liczba pracowników	-0.826970	-0.795437	-0.825277	-7.862446e-01	-0.827041	-0.764767
Transformowana mediana zarobków	-0.562228	0.602016	-0.563135	5.754130e-01	-0.560739	0.604316
Transformowana liczba kobiet pracujących	0.003253	-0.000974	0.000020	-2.224010e-01	0.005147	0.220555
Mediana zarobków kobiet	0.001774	0.067786	-0.028195	-3.440211e-02	0.026261	-0.035027
Transformowana ilość mężczyzn pracujących	-0.000991	-0.000003	0.000439	9.412193e-07	0.000552	0.000003
Mediana zarobków mężczyzn	0.002388	-0.016162	-0.031641	8.577637e-03	0.029305	0.007862

Wybór ilości głównych składowych




kryterium osypiska (1966)

kryterium Kaisera (1960)

kryterium minimalnego zasobu
wyjaśnianej zmienności (>70%)


$$64.75 \% + 33.43 \% = 98.18 \%$$




Wybór ilości głównych składowych

	PC1	PC2
Transformowana liczba pracowników	-0.826970	-0.795437
Transformowana mediana zarobków	-0.562228	0.602016
Transformowana liczba kobiet pracujących	0.003253	-0.000974
Mediana zarobków kobiet	0.001774	0.067786
Transformowana ilość mężczyzn pracujących	-0.000991	-0.000003
Mediana zarobków mężczyzn	0.002388	-0.016162


Wykres ładunków czynnikowych



Wykres ładunków czynnikowych



Biplot



Wnioski

PC1 silnie zależy od zarobków (kobiet i mężczyzn),
rozdziela stany bogatsze i biedniejsze.

PC2 związany z udziałem pracujących mężczyzn.

Connecticut, Massachusetts, New Jersey = wysokie zarobki.

Texas, Florida, Georgia = więcej pracujących mężczyzn, ale niższe zarobki.

PCA ujawnia naturalne klastry stanów wg cech społeczno-ekonomicznych.

Jak działa t-SNE?



t-Distributed Stochastic Neighbor Embedding

stochastyczna metoda porządkowania sąsiadów
w oparciu o rozkład t






zachowuje lokalne struktury danych,
ale niekoniecznie globalne




świetne do wizualizacji, ale nie nadaje się do predykcji



wyniki mogą się różnić przy każdym uruchomieniu
(chyba że ustawi się `random_state`)





1

Obliczenie podobieństw między punktami
w przestrzeni wysokowymiarowej

2

Losowa inicjalizacja punktów w przestrzeni 2D lub 3D

3

Obliczenie podobieństw między punktami
w niskim wymiarze

4

Minimalizacja różnicy między tymi dwoma
rozkładami podobieństw

5

Przemieszczanie punktów w 2D,
aż rozkłady będą jak najbardziej zbliżone

Perplexity

Mała wartość (5–30):

t-SNE skupia się bardziej na lokalnej strukturze danych.
Może uwydatnić małe klastry.
Większe ryzyko szumu i przetrenowania.

Większa wartość (50–100):

t-SNE patrzy szerzej, uwzględnia więcej sąsiadów.
Zachowuje więcej globalnej struktury.
Może spłaszczyć lokalne różnice.

PCA vs t-SNE

szybki, liniowy, deterministyczny

zachowuje globalną strukturę
(maksymalizuje wariancję)

szybka redukcja wymiarów

wolniejszy, nieliniowy, probabilistyczny

lepiej oddaje lokalne podobieństwa


wizualizacja złożonych zbiorów danych



UMAP

UMAP (Uniform Manifold Approximation and Projection) to metoda redukcji wymiarów. Służy do przedstawienia danych wysokowymiarowych w 2D lub 3D. Stara się zachować przede wszystkim lokalną strukturę danych.

UMAP buduje najpierw graf sąsiedztwa: dla każdego punktu szuka jego najbliższych sąsiadów, zapisuje relacje podobieństwa, a potem próbuje odwzorować te relacje w 2D/3D.



<https://medium.com/mcd-unison/umap-an-alternative-dimensionality-reduction-technique-7a5e77e80982>

n_neighbors – im mniejsza tym większy nacisk na lokalne grupy

min_dist – im większe tym bardziej rozproszone grupy

PODSUMOWANIE



THANK
YOU!