Olimpiada AI

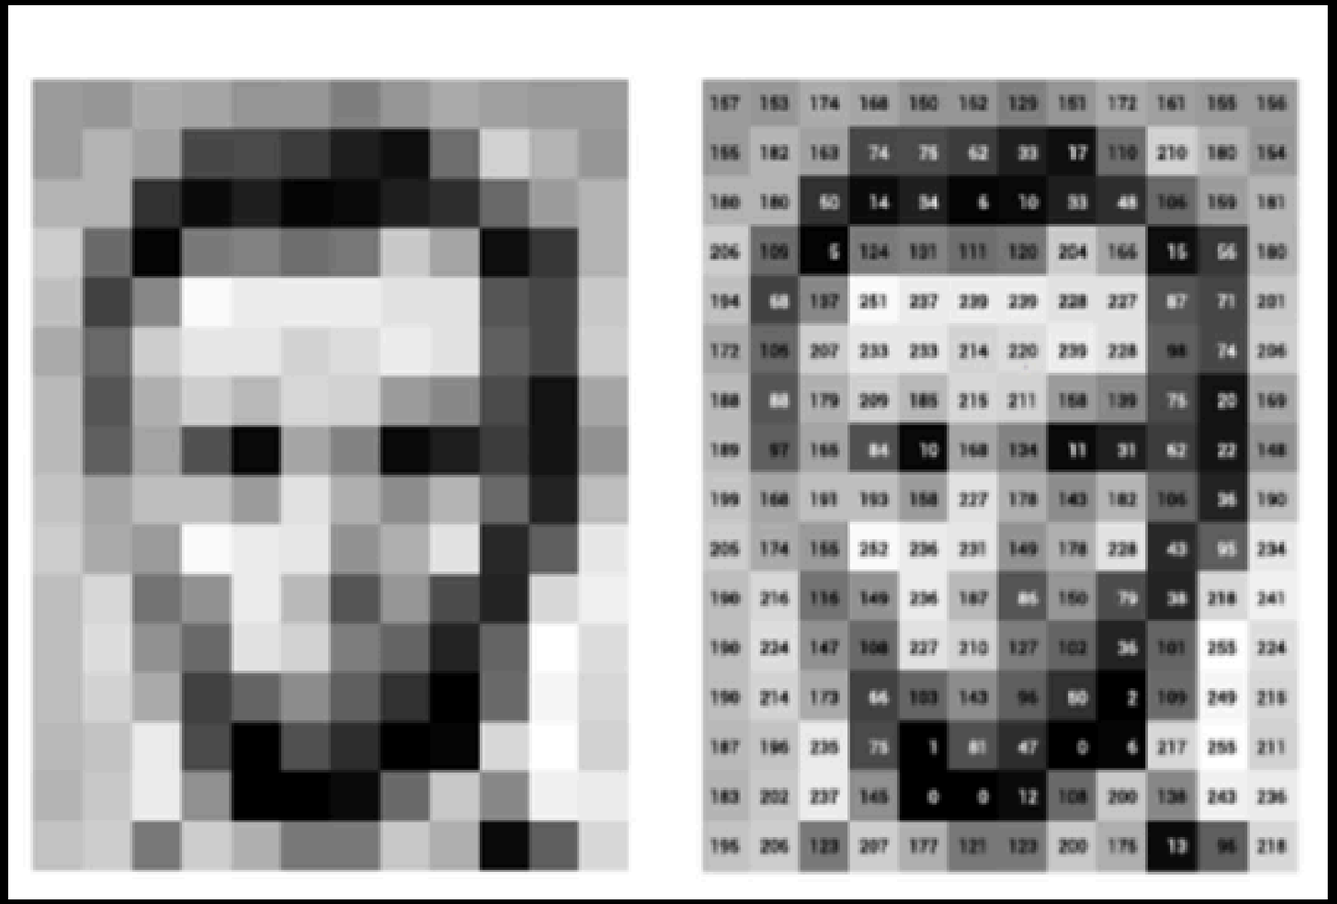
# Konwolucyjne Sieci Neuronowe i Wizja Komputerowa

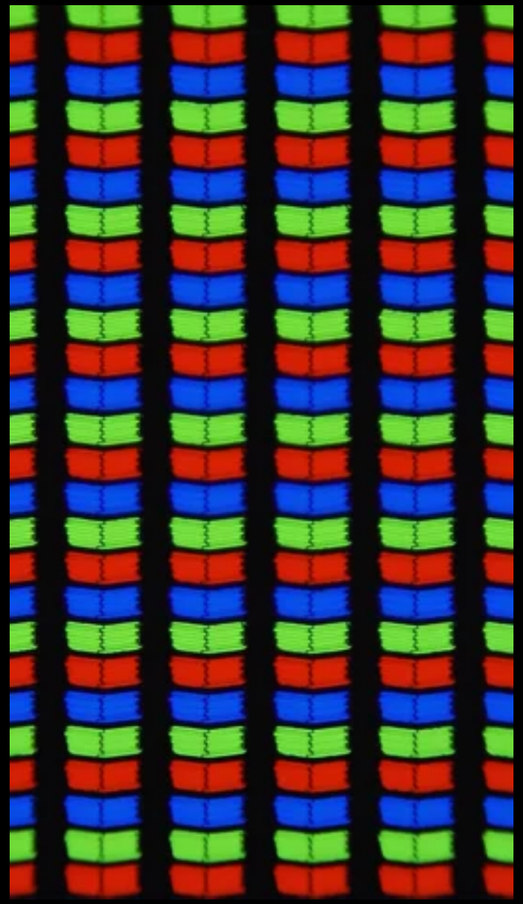
Wykład przygotowujący do Olimpiady Sztucznej Inteligencji

24.10.2026

Jakub Susoł

# Czym dla komputera jest grafika?



# Wymiarowość danych

- 480p = 854 * 480 = 409 920
- 720p = 1280 * 720 = 921 600
- 1080p = 1920 * 1080 = 2 073 600
- 4k = 3840 * 2160 = 8 294 400

(razy 3 jeżeli zdjęcie ma być kolorowe)

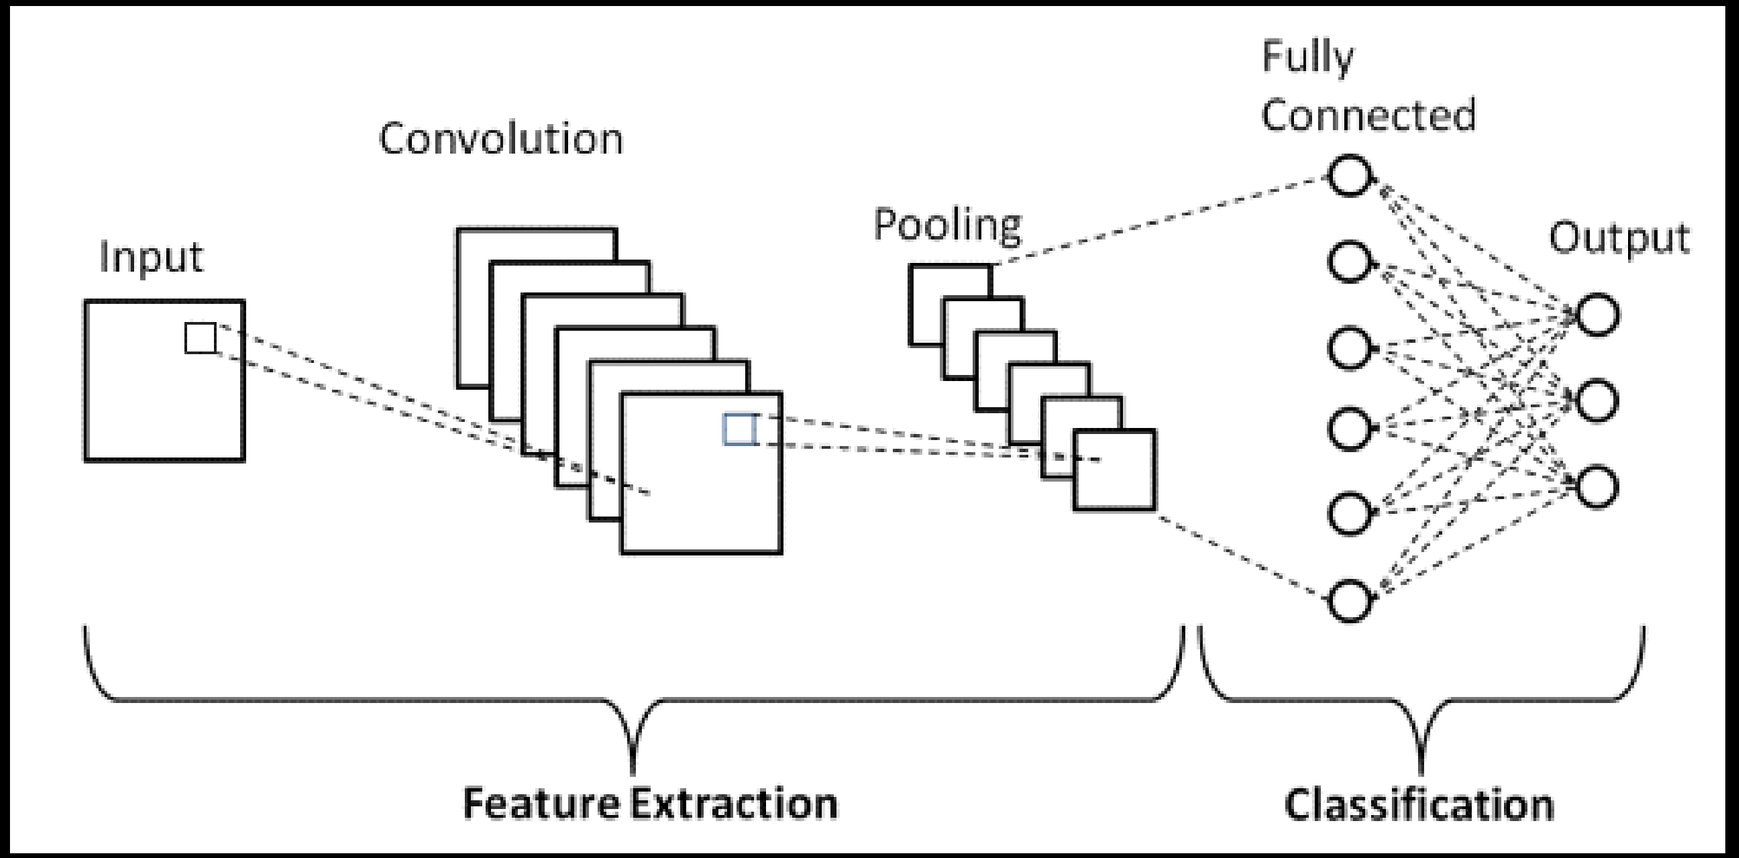
**3x32x32**



# Konwolucyjna sieć neuronowa (CNN)

Jest to rodzaj sieci głębokiego uczenia, który wykorzystuje operacje konwolucji do automatycznego wykrywania lokalnych wzorców w danych (np. obrazach), umożliwiając efektywne rozpoznawanie cech takich jak krawędzie, tekstury i obiekty.

# Architektura sieci konwolucyjnej




**https://adamharley.com/nn_vis/cnn/2d.html**

# Co to w ogóle konwolucja?

| | | | | | | |
|---|---|---|---|---|---|---|
| 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 0 | 60 | 113 | 56 | 139 | 85 | 0 |
| 0 | 73 | 121 | 54 | 84 | 128 | 0 |
| 0 | 131 | 99 | 70 | 129 | 127 | 0 |
| 0 | 80 | 57 | 115 | 69 | 134 | 0 |
| 0 | 104 | 126 | 123 | 95 | 130 | 0 |
| 0 | 0 | 0 | 0 | 0 | 0 | 0 |

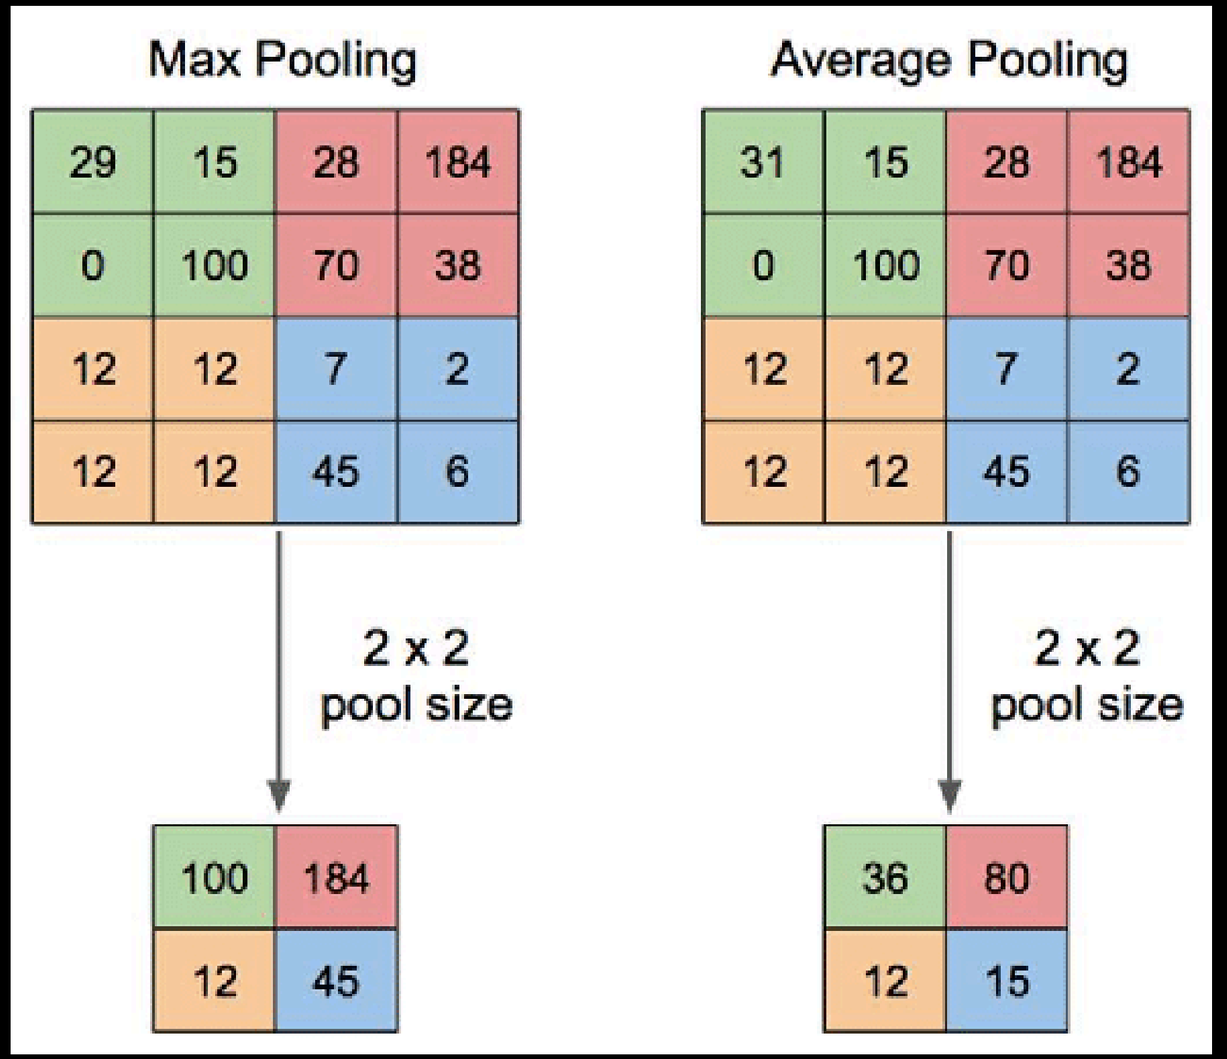
Kernel

| | | |
|---|---|---|
| 0 | -1 | 0 |
| -1 | 5 | -1 |
| 0 | -1 | 0 |

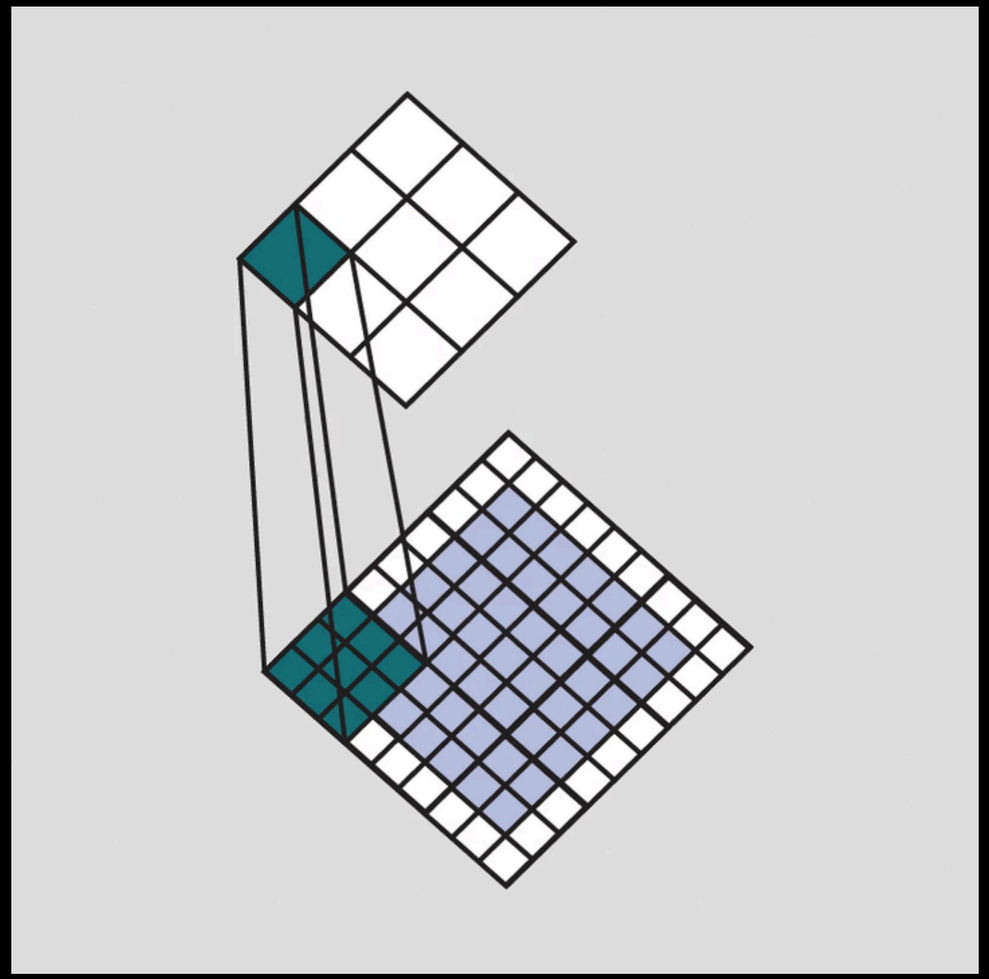
| | | | | |
|---|---|---|---|---|
| 114 | 328 | -26 | 470 | 158 |
| 53 | 266 | -61 | -30 | 344 |
| 403 | 116 | -47 | 295 | 244 |
| 108 | -135 | 256 | -128 | 344 |
| 314 | 346 | 279 | 153 | 421 |

https://svitla.com/uploads/ckeditor/2024/Math%20at%20the%20heart%20of%20CNN/image_930660943761713546482755.gif

# Pooling


Max Pooling
29 15 28 184
0 100 70 38
12 12 7 2
12 12 45 6
2 x 2
pool size
100 184
12 45
Average Pooling
31 15 28 184
0 100 70 38
12 12 7 2
12 12 45 6
2 x 2
pool size
36 80
12 15

# Stride



https://cdn-images-1.medium.com/max/480/1*awHl8cYgPSP4Aj8t929T5g.gif

# Po sklejeniu wszystkiego:

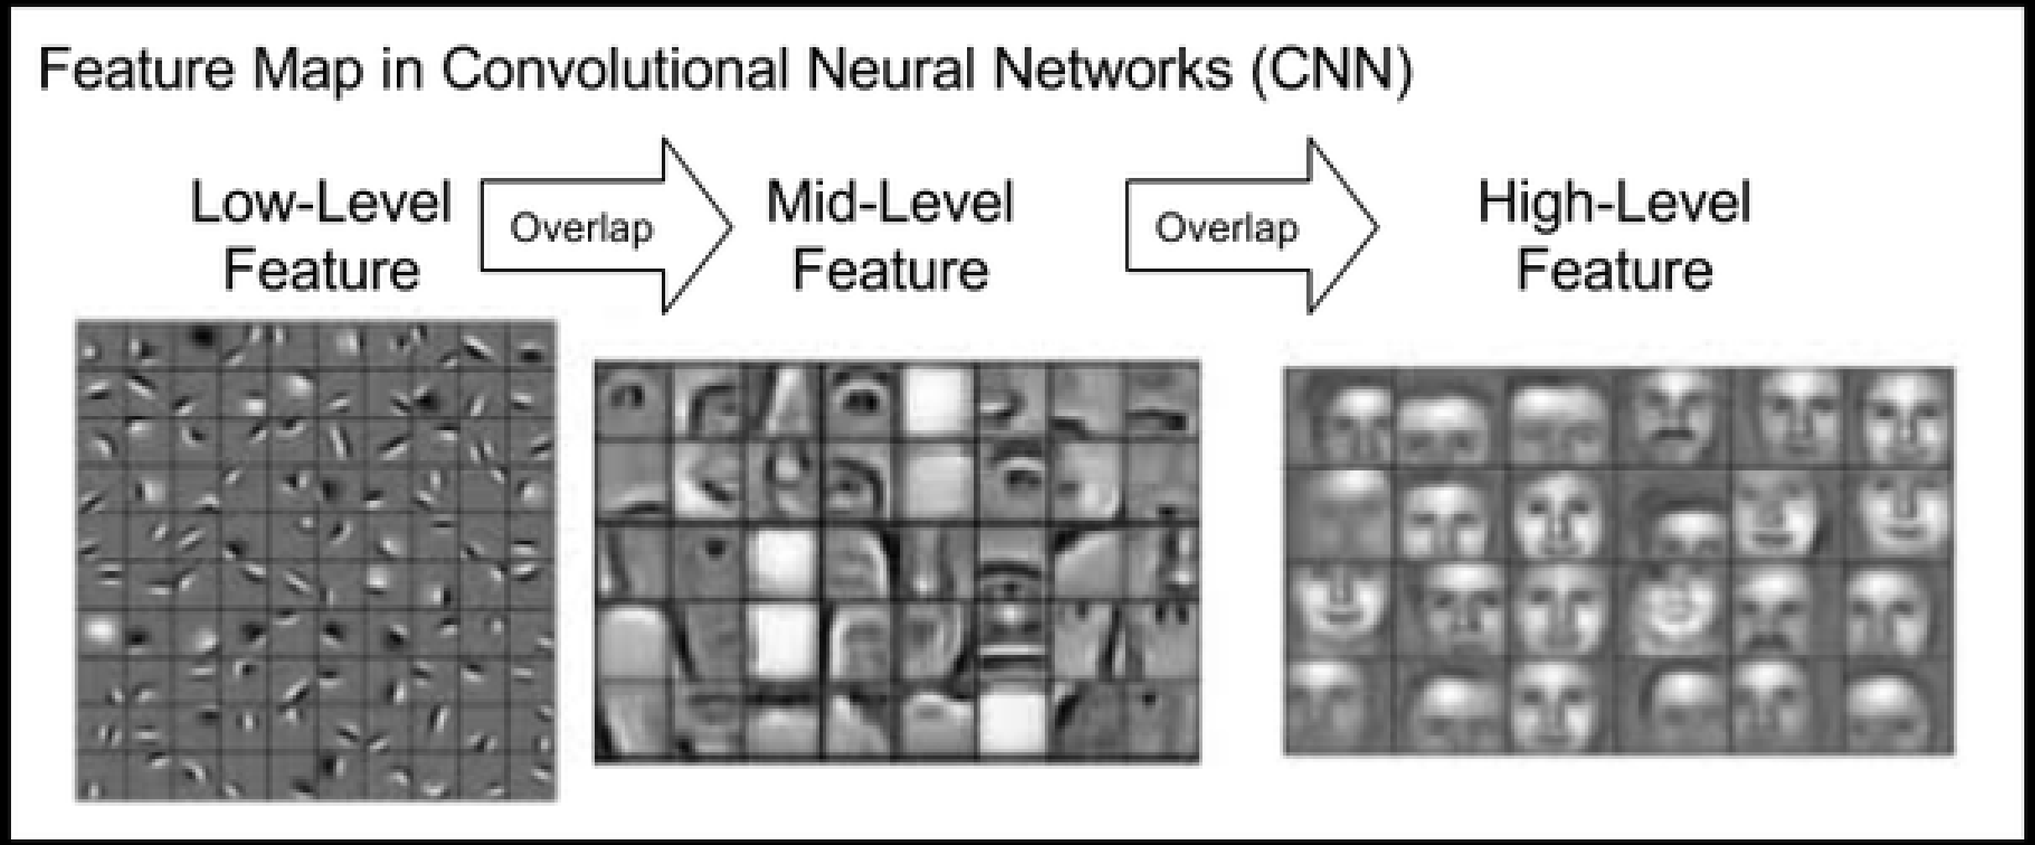




# Kroki CNN

1. Pobranie obrazu i podzielenie go na lokalne fragmenty
2. Nakładanie filtrów (konwolucja) i wyliczanie map cech
3. Przepuszczenie map cech przez funkcję aktywacji (np. ReLU)
4. Zmniejszenie wymiaru przez pooling
5. Powtarzanie konwolucji i poolingu w kolejnych warstwach
6. Spłaszczenie map cech do wektora i klasyfikacja za pomocą warstw w pełni połączonych (FC)

# A pod maską CNN-a...



# Modele pretrenowane

Torch posiada zestaw pretrenowanych modeli do różnych zastosowań w module torchvision.models. Są to gotowe do użycia lub dotrenowania sieci wyszkolone na zestawie ImageNet w przypadku klasyfikatorów, ale znajdziemy tez sieci identyfikujące punkty kluczowe, warstwy segmentacji i generalnej detekcji obiektów.

Głównymi różnicami w modelach pretrenowanych jest ich generalna architektura, wydajność i precyzja przy zastosowaniu dołączonych do nich wag oraz charakterystyka zastosowań modelu, o których więcej można dowiedzieć się z dokumentacji.

# Ze znanych modeli

## Inception

rozpoznawanie obiektów o różnych rozmiarach

## MobileNet

aplikacje mobilne

szybkie i lekkie modele klasyfikacji obrazów

## ResNet

głęboka klasyfikacja

detekcja

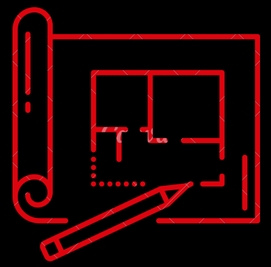
segmentacja

## VGG

prosta klasyfikacja

punkt wyjściowy

# VGG: VGG16, VGG19



prosta i jednorodna

13/16 warstw konwolucyjnych

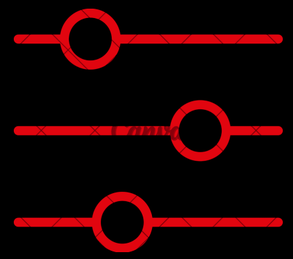
3 warstwy w pełni połączone

filtr 3x3



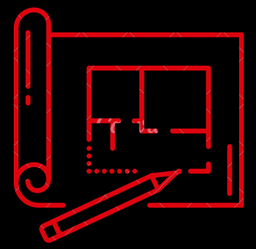
wolny w trenowaniu

brak optymalizacji



138/144 mln parametrów

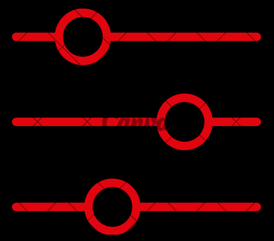
# ResNet: 18, 34, 50, 101, 152



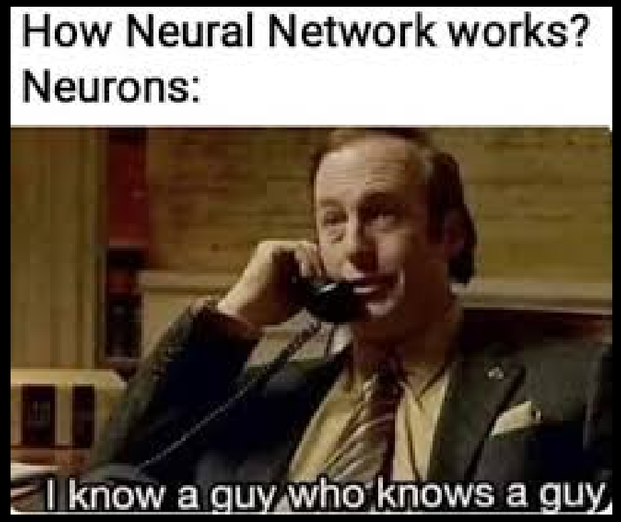
zastosowanie *residual connections*



średni, ale szybszy w trenowaniu niż VGG

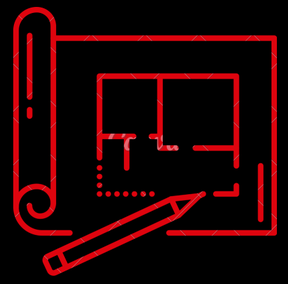


12-58 mln parametrów




*residual connections* - umożliwiają tworzenie bardzo głębokich architektur przy zmniejszonym problemie zanikania gradientu

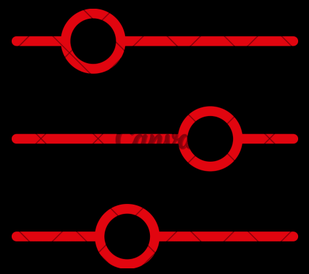
# MobileNet: MobileNetV1, MobileNetV2



zastosowanie *depthwise separable convolutions*



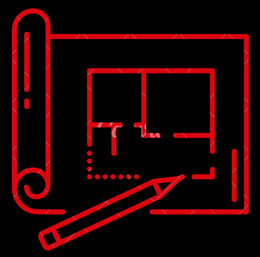
bardzo szybki w trenowaniu



3-4 mln parametrów

*depthwise separable convolutions* – każda operacja konwolucyjna jest rozdzielona na dwie części: filtracja kanałów i filtrację przestrzenną

# Inception: InceptionV1(GoogLeNet), V2, V3

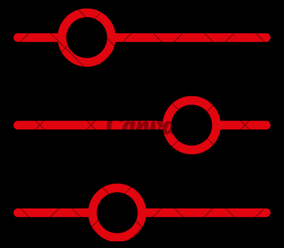


inception modules

różne rozmiary filtrów (np. 1x1, 3x3, 5x5) w jednej warstwie



może być wolny przez równoległe filtry konwolucyjne



7-23 mln parametrów

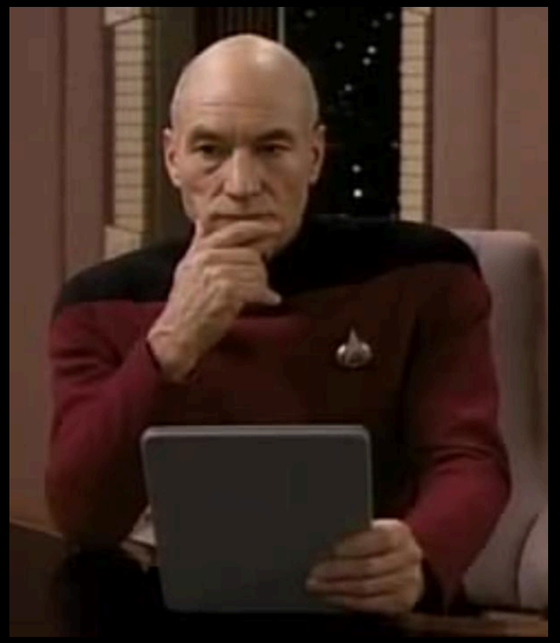


# To który mam wybrać?



# To który mam wybrać?

Czy zależy mi na czasie trenowania?
Czy mam dużo pamięci do wykorzystania?
Czy potrzebuję modelu dla urządzeń mobilnych?
Czy model ma być bardzo dokładny?
Jak duży jest zbiór danych?
Czy sieć ma być bardzo głęboka?
Czy zależy mi na prostocie architektury?
Czy chcę model odporny na zanikający gradient?
Czy potrzebuję wykrywać obiekty o różnych rozmiarach?
Czy zależy mi na szybkości działania modelu?
Czy potrzebuję modelu do pracy w czasie rzeczywistym?
Czy muszę zredukować liczbę parametrów?
Czy model musi działać na wielu urządzeniach?
Czy mam dużo danych, ale ograniczone zasoby obliczeniowe?
Czy chcę uzyskać najlepsze wyniki w klasyfikacji obrazów?

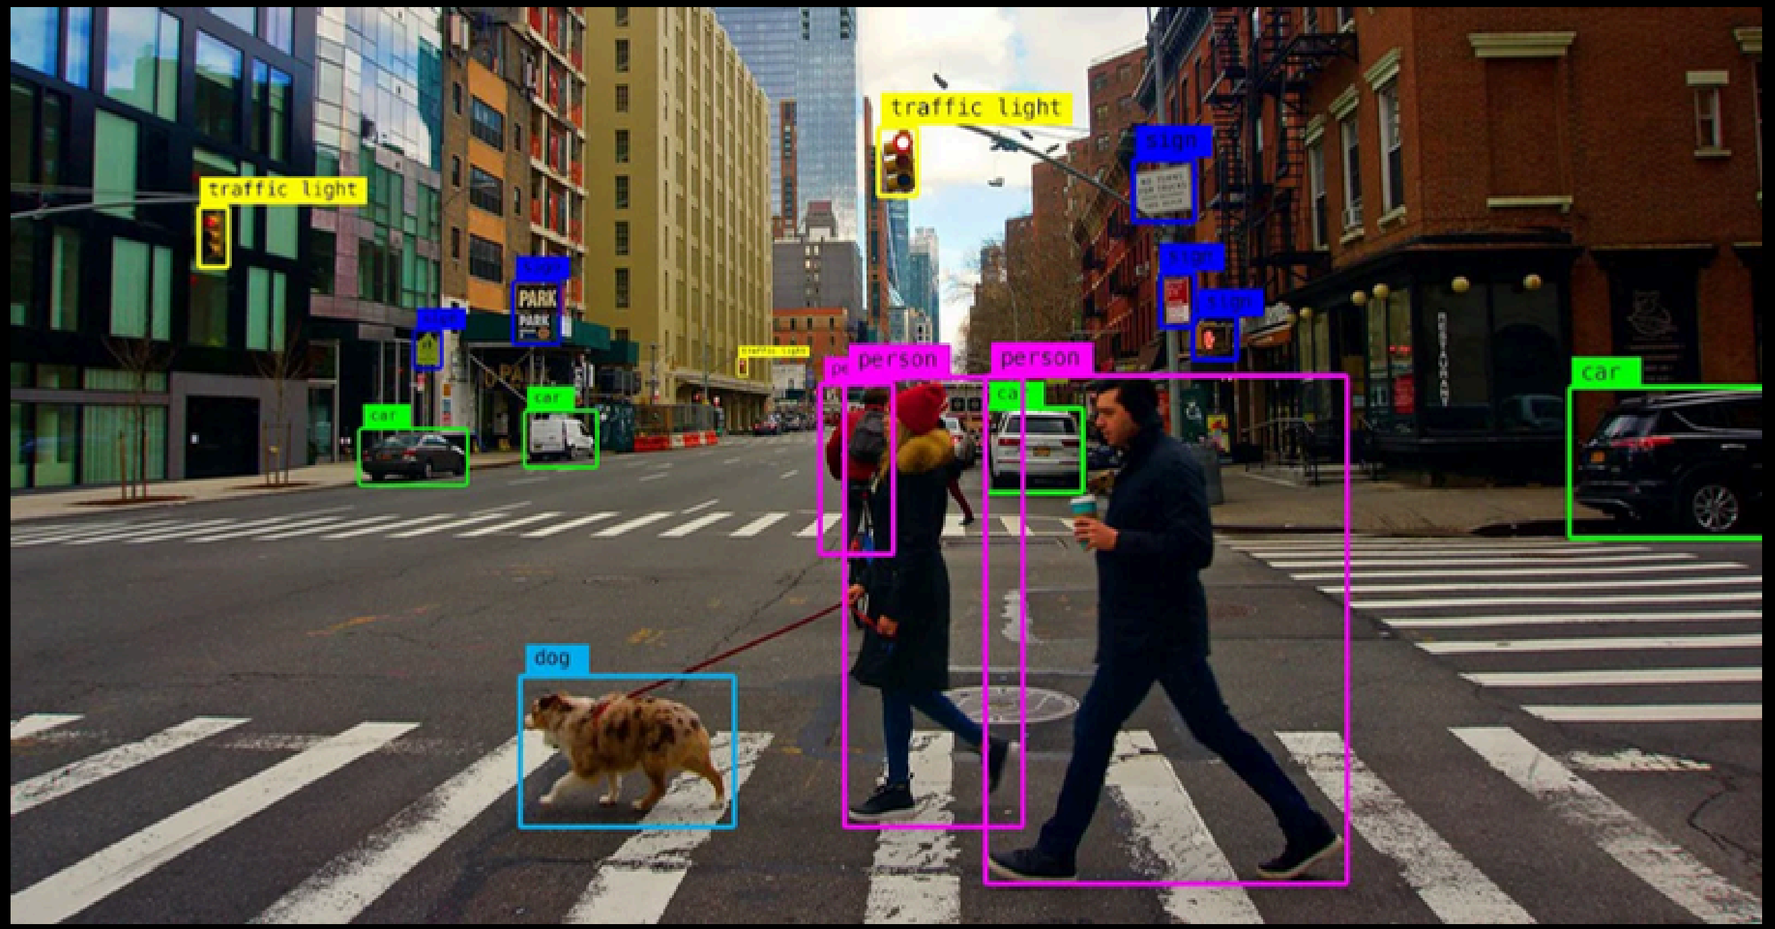


# I teraz pojawia się pytanie:

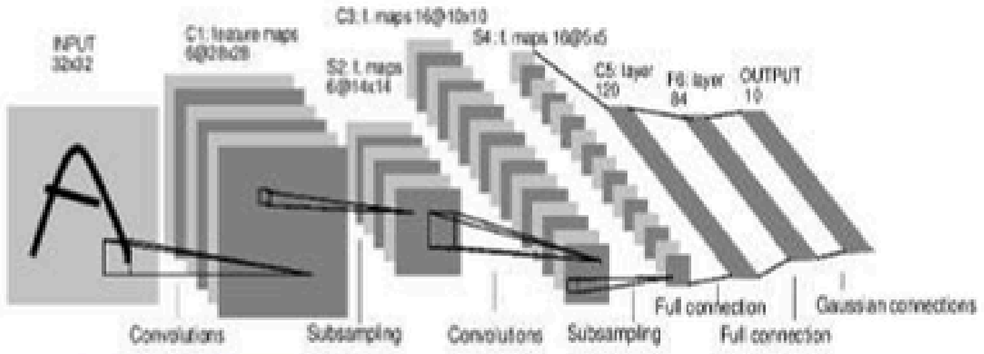



https://joemonster.org/p/2130084

# Wizja komputerowa



# WHO WOULD WIN?



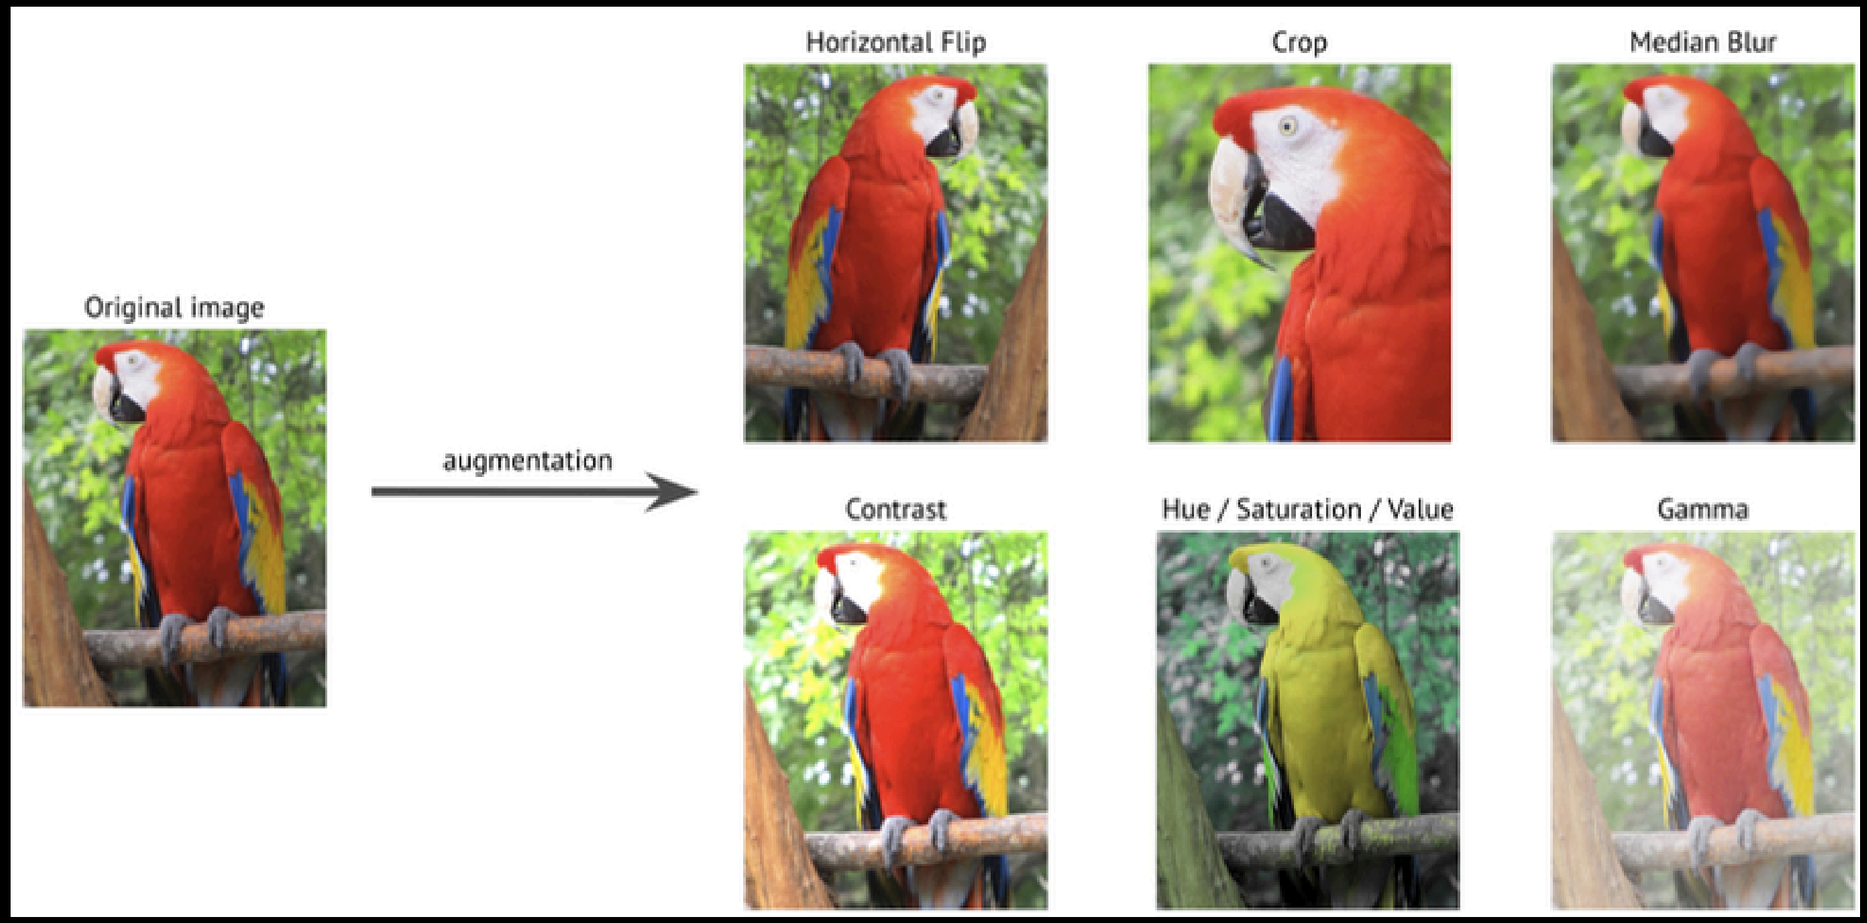

a complex model designed by elite researchers



cheetah

one noisy boi

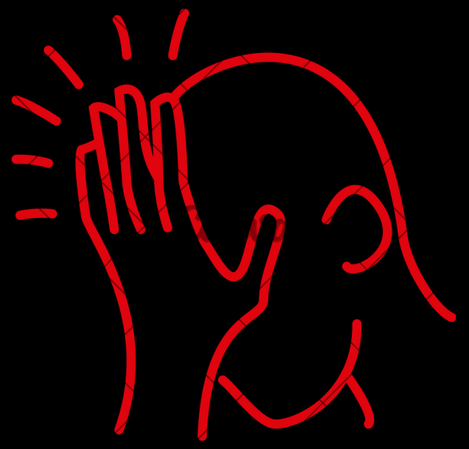
# Ale przed tym jak sprawimy żeby komputer miał oczy...



# I po co to sie robi?



# I po co to sie robi?



Zmniejszenie podatności na błędy



Sprawdzenie precyzji przewidywania

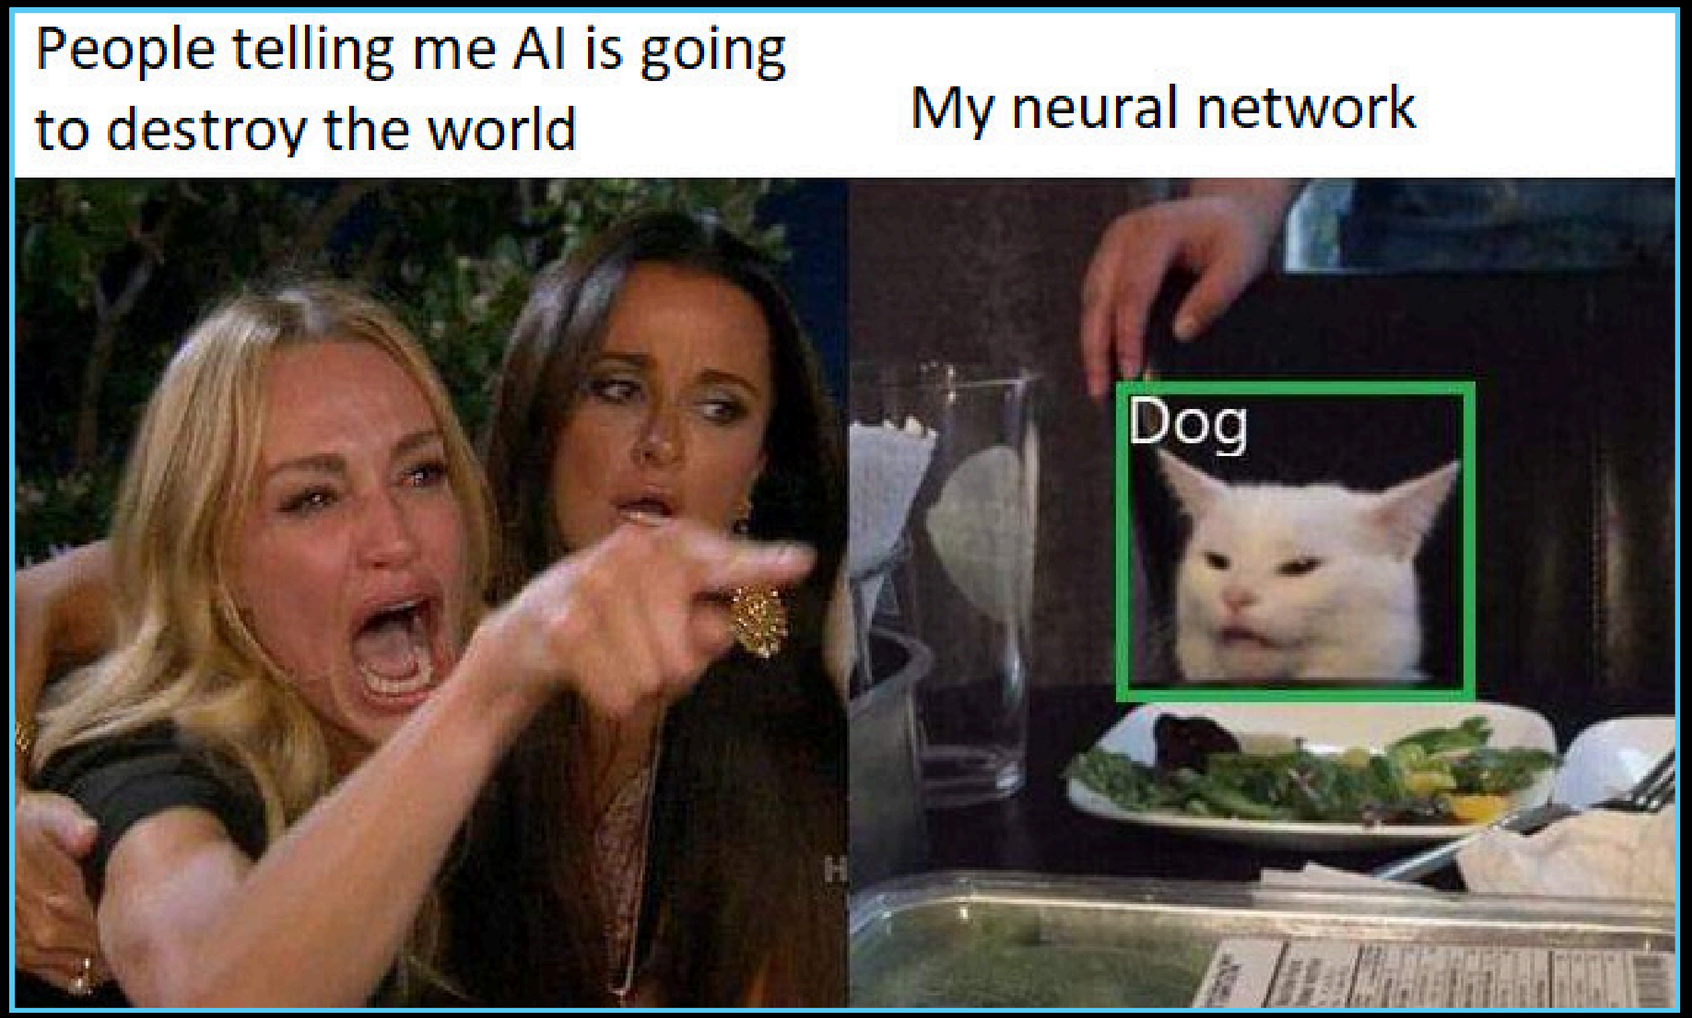


Pozbycie się niepożądanych artefaktów

# Transformacja obrazu pomaga sieci nauczyć się wyciągać cechy bez względu na zawartość obrazu i jakość



# W przeciwnym wypadku dostajemy takie kwiatki:



# Kroki Computer Vision

1. Pobranie obrazu i klasyfikacja za pomocą konwolucyjnej sieci neuronowej
2. Znalezienie obiektu na obrazie, ustalenie koordynatów położenia centroidu
3. Oznaczenie obiektu “bounding boxem”
4. Zwrócenie prawdopodobieństwa klasyfikacji i nazwy zklasyfikowanego obiektu
5. Nałożenie maski na obraz wejściowy z informacjami i bounding boxem

# Przykłady modeli CV

“Jednostrzałowce”:

**YOLO - You Only Look Once** (**Ultralytics**)

SSD - Single Shot Detection

Wykonują konwolucje i detekcje wszystkich obiektów na obrazie w jednym przejściu sieci

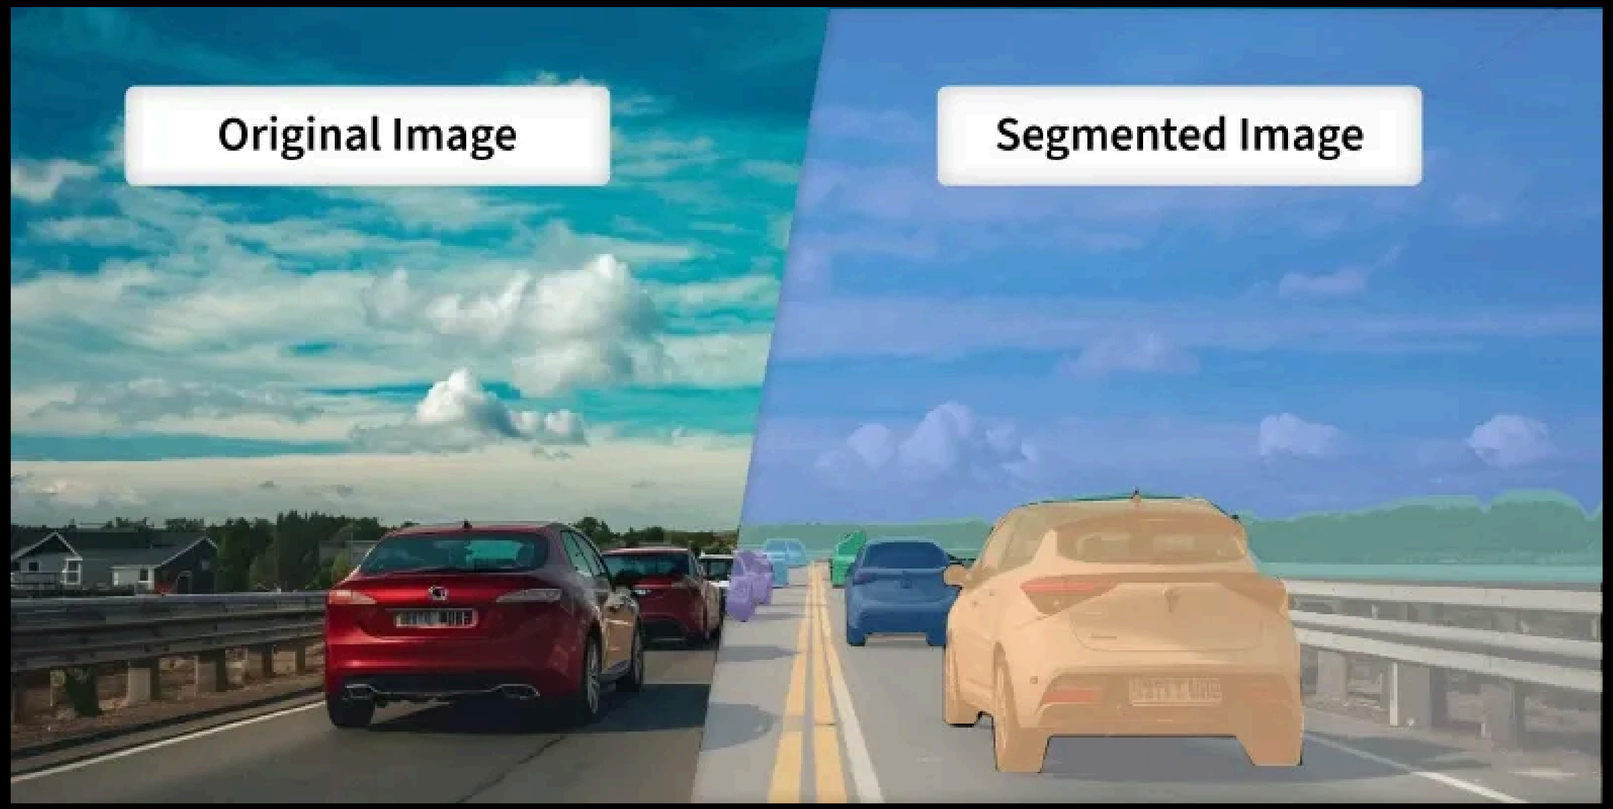
Bazujące na podziale obrazu:

**Region-Based Convolutional Neural Networks** (**R-CNNs**)

Dzieli obraz na mniejsze fragmenty - “regiony” - i klasyfikuje każdy z nich osobno

# Segmentacja

Teraz, jak mamy dobrze zklasyfikowane obiekty na naszym obrazie, co jeśli chcielibyśmy je wyciąć albo dokładnie obrysować? Do tego używa się podejścia nazywanego Segmentacją.



# Segmentacja

Segmentacja rozszerza naszą wizję komputerową przez dodanie kilku algorytmów:

Detekcja krawędzi
Klasteryzacja pikseli
Instancjowanie obiektów (również używane w CNN-ach)
Maskowanie

Po zaaplikowaniu ich na naszych detekcjach, możemy dokładniej obrysować wykryty obiekt i wykonać na nim jakaś dodatkową analizę lub transformatę.

# Gdzie się używa segmentacji?

W obecnych czasach segmentacja jest wszędzie a same algorytmy są na tyle zoptymalizowane i wydajne, że można je odpalić nawet na lodówkach czy innych tosterach.

Z życia wziętym przykładem są samochody z “autopilotem” (Tesla itp.), ale to nie ogranicza się tylko do motoryzacji czy mądrych lodówek które przypominają, że trzeba iść po mleko. Segmentacja też używana jest np. do ustawiania tła na wideokonferencji, coś a’la tani green-screen. Albo odblokowywania telefonu twarzą.

# Dodatkowe materiały

https://www.viam.com/post/computer-vision-object-detection-guide

https://www.lightly.ai/blog/object-detection

https://www.mdpi.com/1424-8220/25/4/1033

https://www.geeksforgeeks.org/computer-vision/computer-vision/

# Pytania



# Dziękuję za Uwagę!