

Zadania detekcji i segmentacji

Dr Szymon Płotka

Uniwersytet Jagielloński

7.11.2026

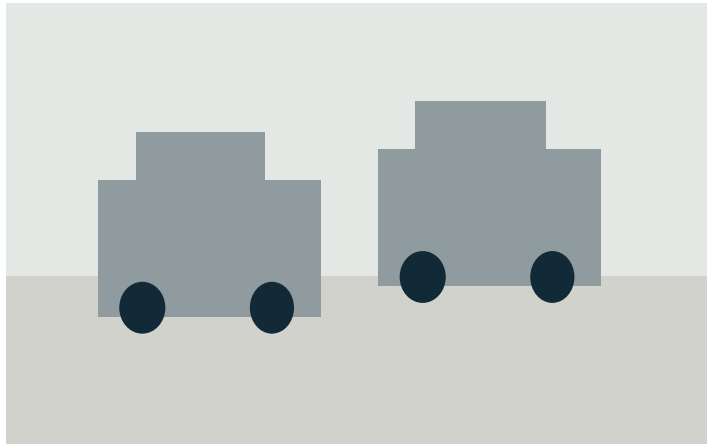
Agenda

1. *Czym się różni klasyfikacja, detekcja, oraz segmentacja?*
2. *Wstęp do problemu detekcji obiektów na obrazach*
   - Definicja i podstawy problemu detekcji
   - Metryki używane w zadaniach detekcji
   - Popularne architektury sieci neuronowych używane do detekcji obiektów
3. *Wstęp do problemu segmentacji obiektów na obrazach*
   - Definicja i podstawy problemu segmentacji
   - Metryki używane w problemie segmentacji
   - Popularne architektury sieci neuronowych używane do segmentacji obiektów

Wprowadzenie

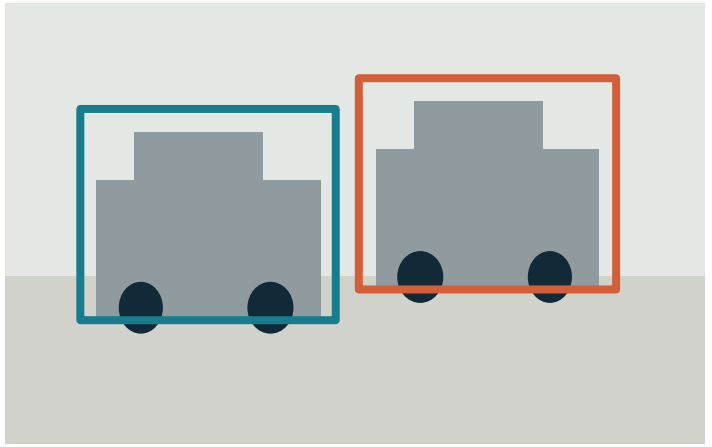
Klasyfikacja, detekcja, segmentacja

Klasyfikacja



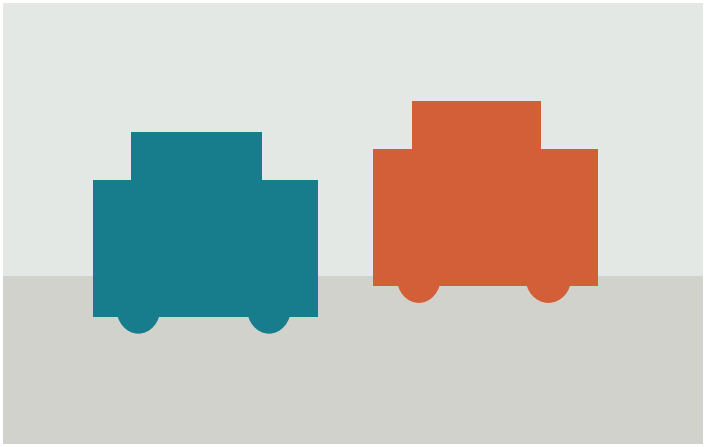
„Są tu samochody”

Detekcja



Klasa i ramka obiektu

Segmentacja

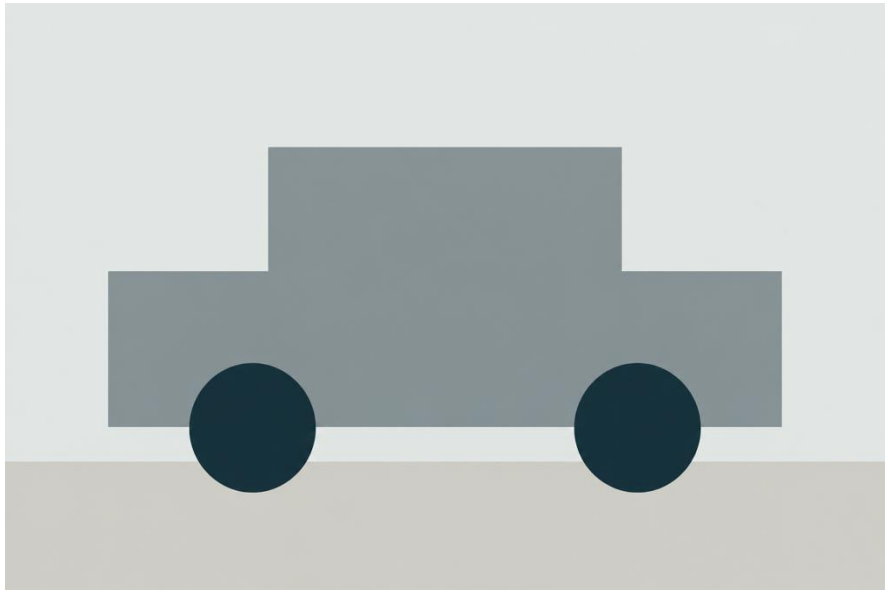


Klasa i piksele obiektu

Klasyfikacja

Co jest na obrazie?

Obraz wejściowy



Model

→

Samochód

Możliwe kategorie:

samochód, rower, autobus

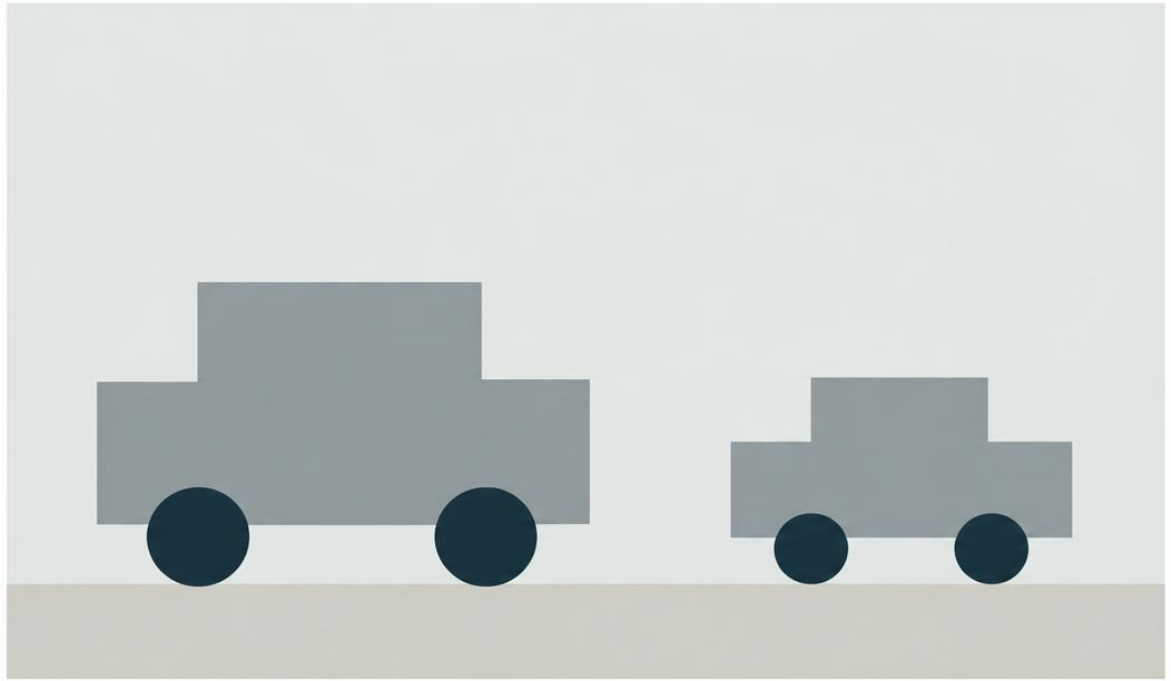
Jedna etykieta opisuje cały obraz.

Czy taka odpowiedź wystarczy, żeby policzyć samochody?

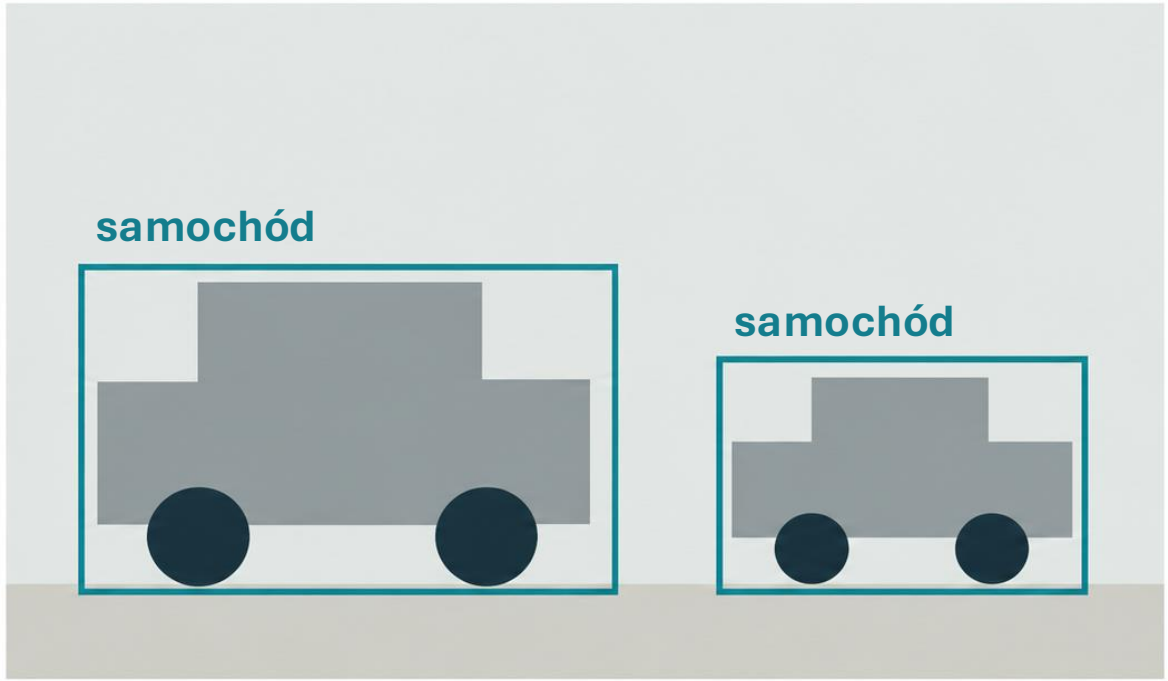
Detekcja

Jakie obiekty i gdzie?

Obraz wejściowy



Wynik detekcji



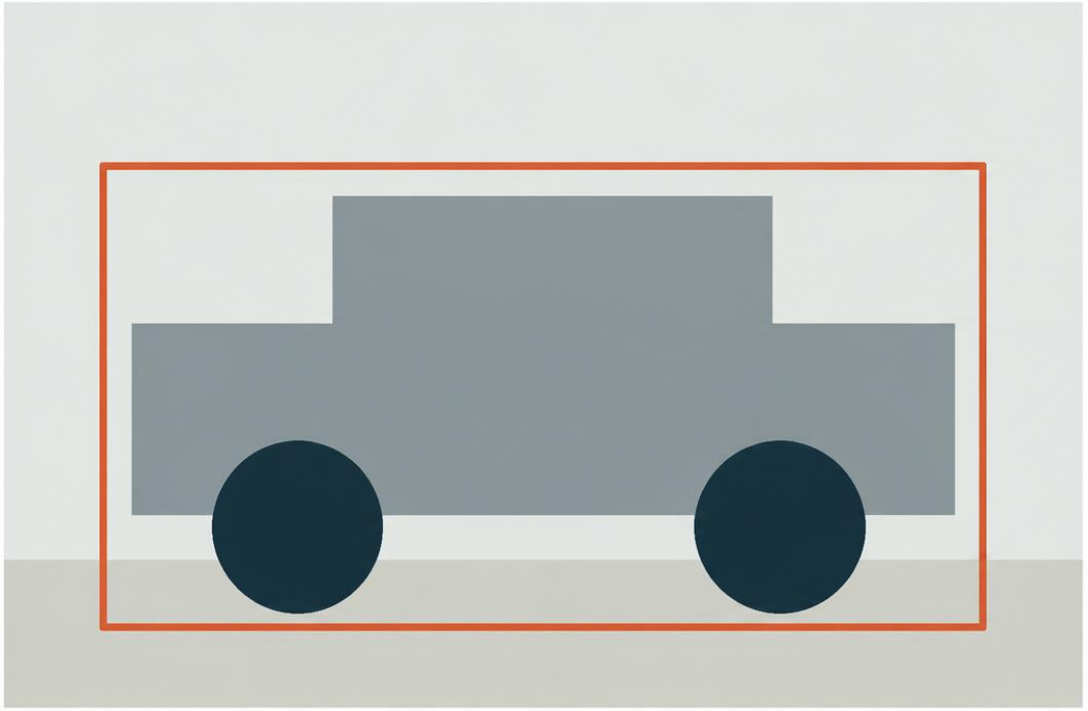
Każdy wykryty obiekt otrzymuje klasę i ramkę.

Czy ramka pokazuje dokładny kształt samochodu?

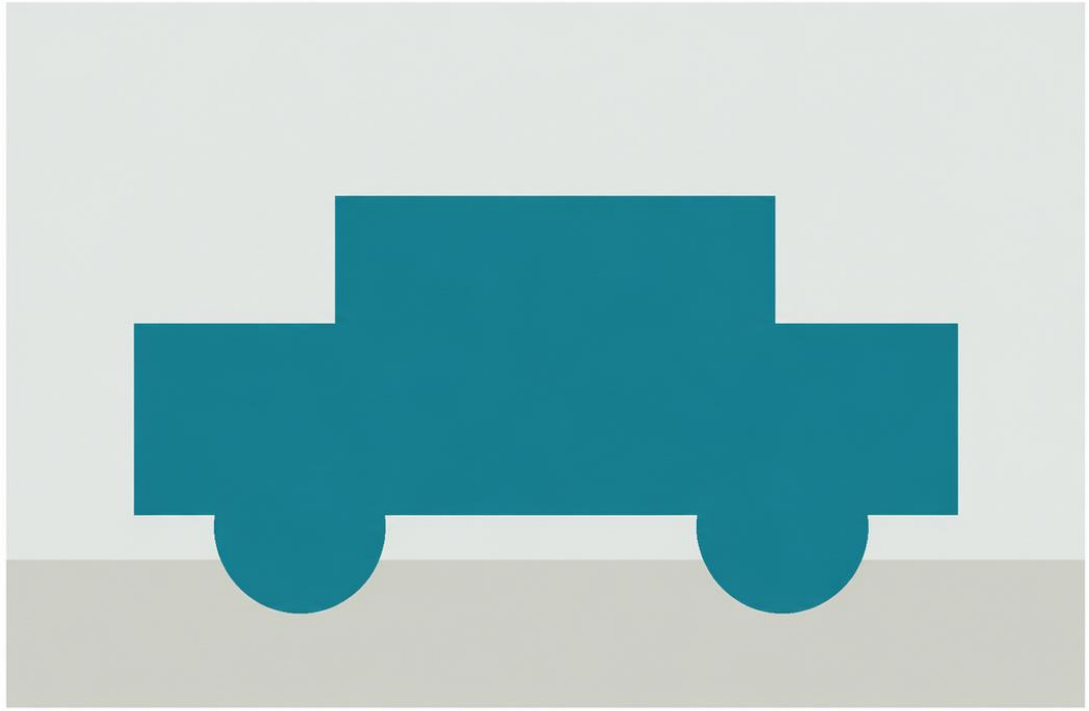
Segmentacja

Do czego należy każdy piksel?

Ramka obiektu



Maska klasy „samochód”



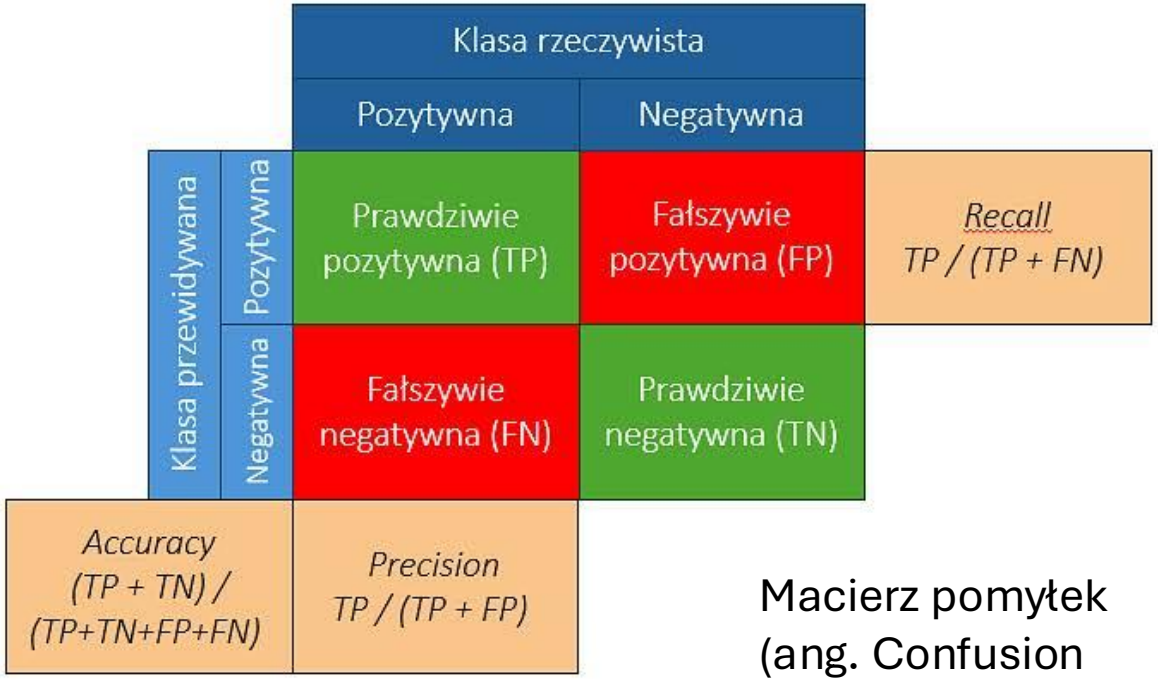
Każdy piksel otrzymuje etykietę: „samochód” albo „tło”.

Co pomoże obliczyć powierzchnię obiektu: ramka czy maska?

Detekcja

Detekcja – wstęp do metryk

- Precyzja (ang. precision) = $\frac{TP}{TP+FP}$
- Czułość (ang. recall) = $\frac{TP}{TP+FN}$



Macierz pomyłek (ang. Confusion matrix)

TP = prawdziwie pozytywny (ang. True positive)
FP = fałszywie pozytywny (ang. False positive)
TN = prawidziwie negatywny (ang. True negative)
FN = fałszywie negatywny (ang. False negative)

Źródło: https://www.drmalinowski.edu.pl/posts/2907-macierz-pomylek



Prawdziwie pozytywny (TP)
Sukces



Fałszywie negatywny (FN)
Najbardziej niebezpieczny błąd



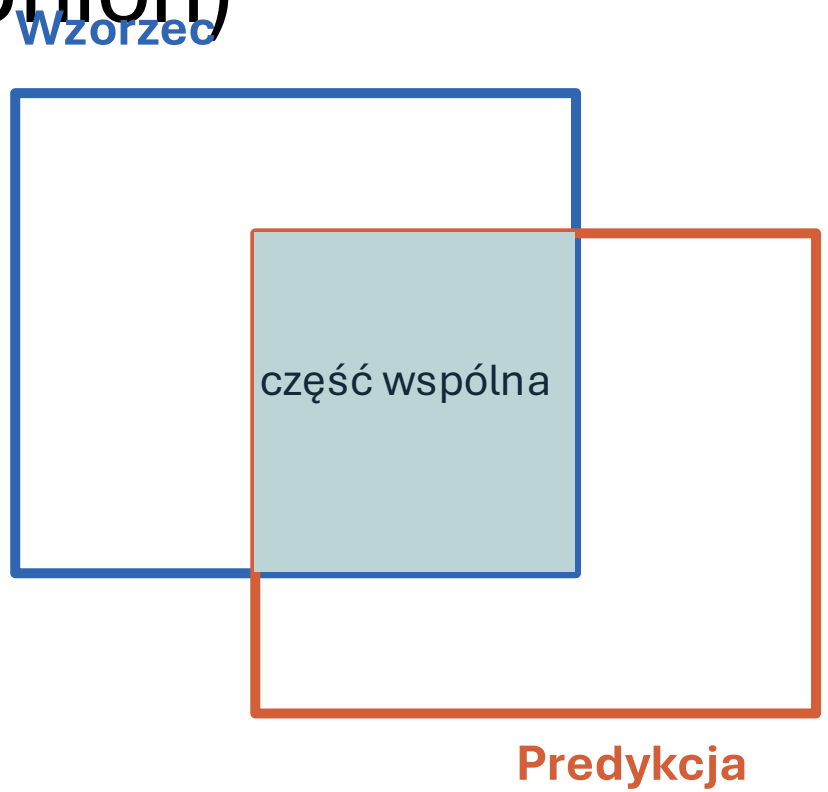
Fałszywie pozytywny (FP)
Fałszywy alarm



Prawdziwie negatywny (TN)
Prawidłowe zignorowanie tła



Metryki używane w problemie detekcji cd.
IoU = Przecięcie nad sumą (ang. Intersection-over-Union)



$$\text{IoU} = \frac{\text{pole części wspólnej}}{\text{pole sumy obszarów}}$$

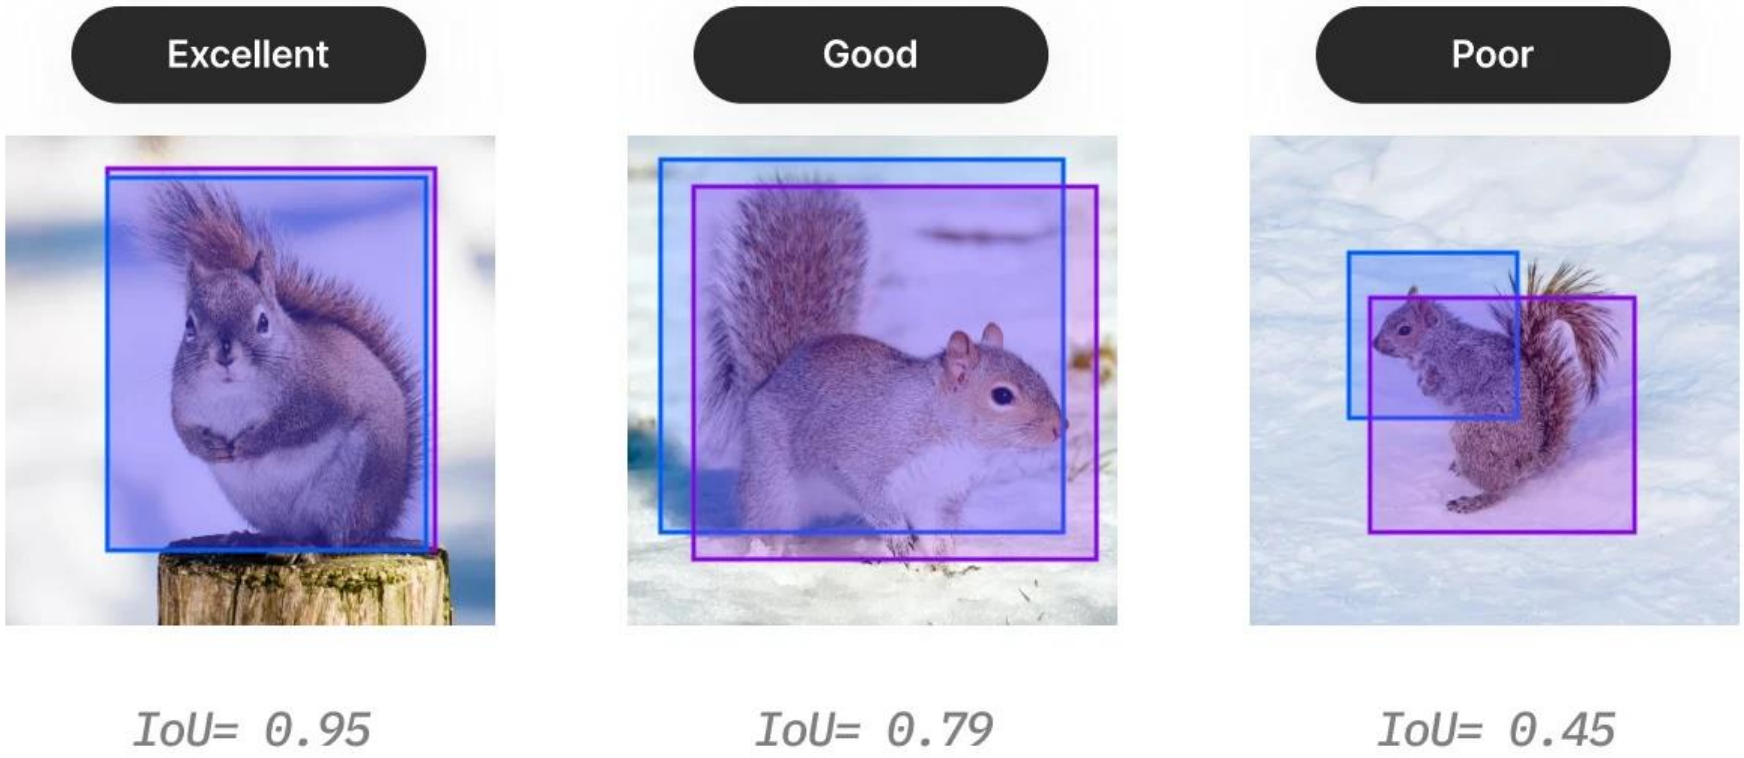
$$\text{IoU} = \frac{TP}{TP+FP+FN}$$

0: brak pokrycia
1: idealne pokrycie

Dotyczy ramek i masek

Source: https://www.v7darwin.com/blog/intersection-over-union-guide

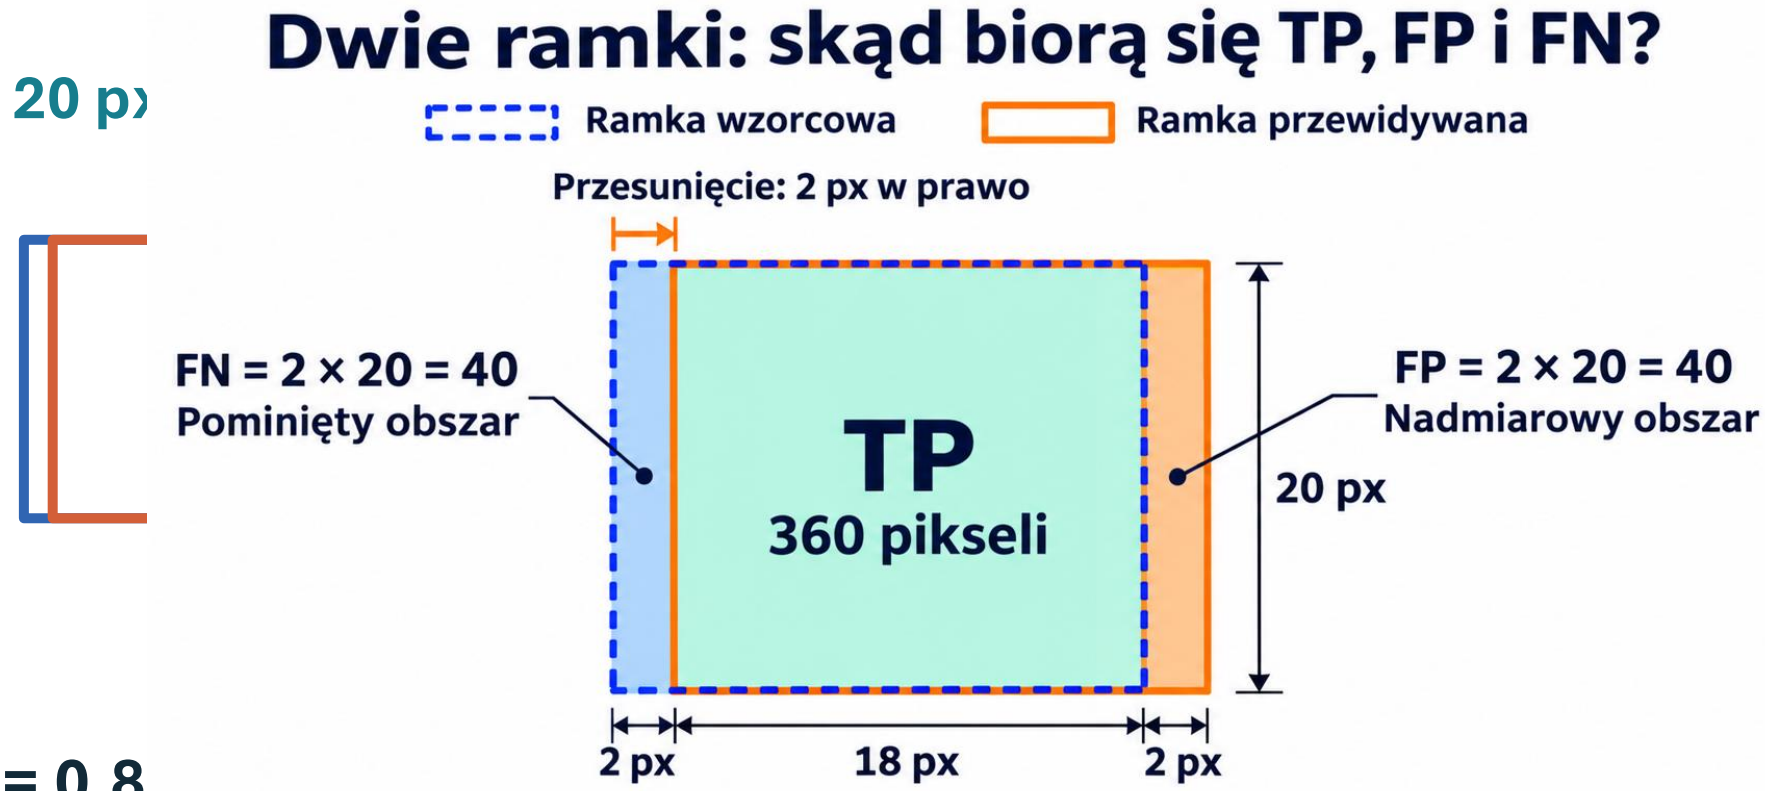
IoU – kiedy jest dobrze?



Source: https://www.v7darwin.com/blog/intersection-over-union-guide

To samo przesunięcie mocniej szkodzi małym obiektom

20 × 20 px



IoU = 0,8

$$TP = 18 \times 20 = 360$$

$$IoU = 360 / (360 + 40 + 40) \approx 0{,}818$$

Tutaj TP, FP i FN oznaczają obszary pikseli, nie liczbę wykrytych obiektów.

IoU – czy aby na pewno jest dobrze?

a) **Błędna klasa:** ramka idealnie pasuje, ale samochód otrzymuje etykietę „rower”.

b) **Duplikaty:** kilka ramek dobrze obejmuje ten sam obiekt, tworząc dodatkowe fałszywe alarmy.

c) **Pominięcia:** znaleziony obiekt ma IoU = 1, ale drugiego obiektu model nie wykrywa.

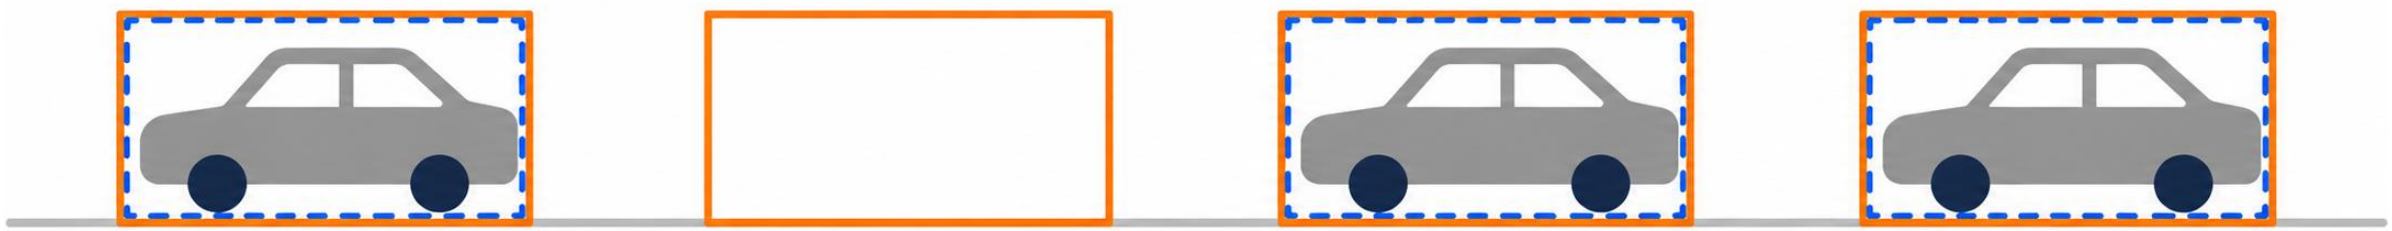
Wysokie IoU potwierdza zgodność lokalizacji konkretnej pary ramek, a nie poprawność całej detekcji.



Czy model dobrze znajduje samochody?

Chcemy znaleźć 3 auta. Model zgłasza 4 miejsca.

1. zgłoszenie	2. zgłoszenie	3. zgłoszenie	4. zgłoszenie



Trafienie	Fałszywy alarm	Trafienie	Trafienie

Niebieskie ramki: prawdziwe auta. Pomarańczowe: zgłoszenia modelu.

Model pokazuje najpierw zgłoszenia, których jest najbardziej pewny.

Dwa pytania o jakość

Po obejrzeniu wszystkich 4 zgłoszeń

Ile zgłoszeń było trafnych?

3 z 4 = 75%

To precision, czyli precyzja.

$$\text{Precyzja} = \frac{TP}{TP+FP}.$$

Ile prawdziwych aut znaleziono?

3 z 3 = 100%

To recall, czyli czułość.

$$\text{Czułość} = \frac{TP}{TP+FN}$$

Znaleźliśmy wszystkie auta, ale pojawił się też fałszywy alarm.

Oglądamy zgłoszenia po kolei

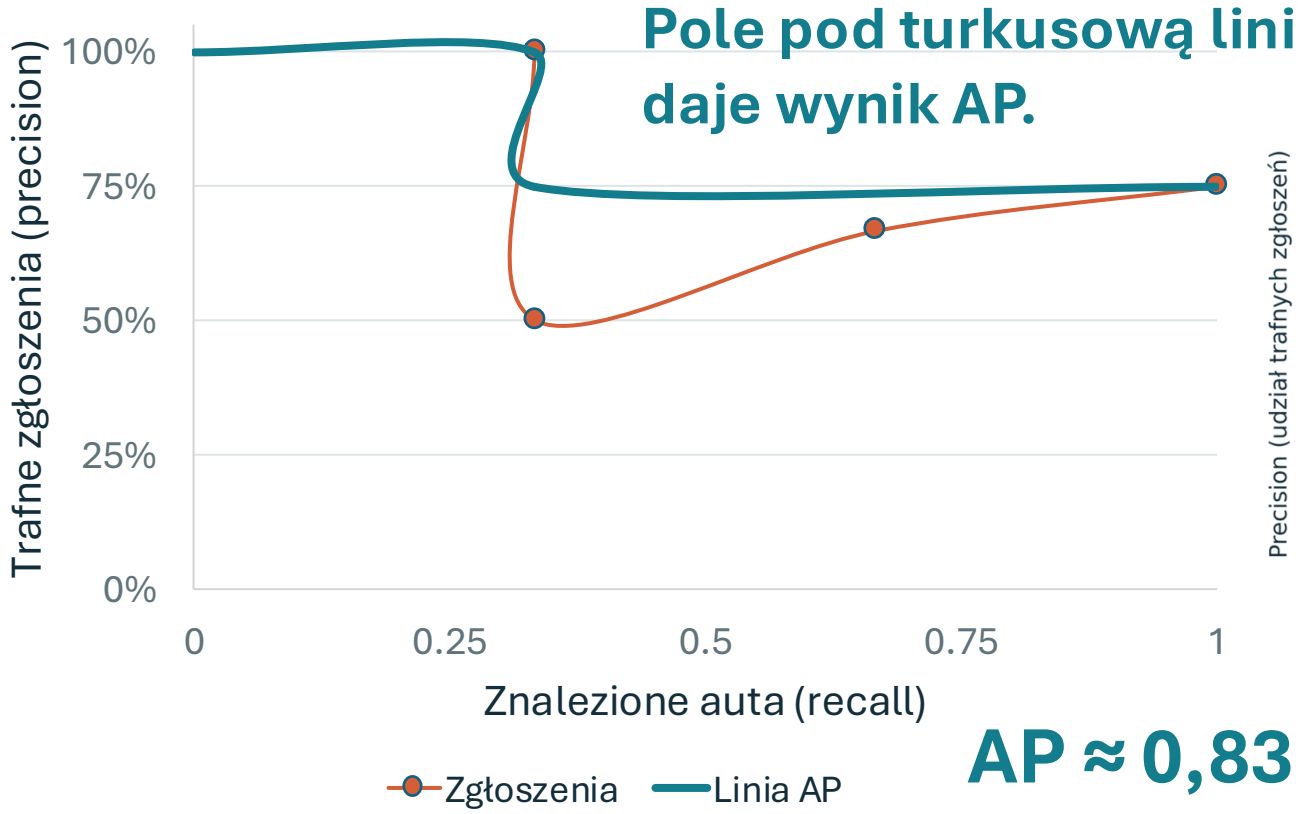
Po każdym kroku ponownie odpowiadamy na oba pytania

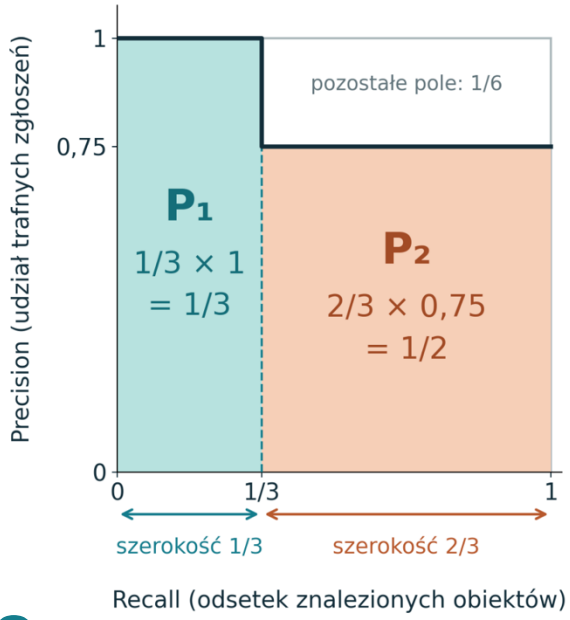
Przyjęte zgłoszenia	Trafne zgłoszenia precision	Znalezione auta recall
Pierwsze: trafienie	1 z 1 = 100%	1 z 3 ≈ 33%
Dodajemy alarm	1 z 2 = 50%	1 z 3 ≈ 33%
Dodajemy trafienie	2 z 3 ≈ 67%	2 z 3 ≈ 67%
Dodajemy trafienie	3 z 4 = 75%	3 z 3 = 100%

Fałszywy alarm pogarsza precyzję. Nie znajduje kolejnego auta.

Wykres zamieniamy w wynik AP

AP (Average Precision) podsumowuje listę zgłoszeń w skali od 0 do 1





Prostokąt 1

szerokość 1/3
wysokość 1

Prostokąt 2

szerokość 2/3
wysokość 0,75

AP = P₁ + P₂

= 1/3 + 1/2

= 5/6 ≈ 0,833

Linia pomija przejściowe spadki, po których wynik się poprawił.

Dlaczego kolejność ma znaczenie?

Te same 3 trafienia i 1 alarm, ale inny początek listy

Kolejność zgłoszeń	AP
trafienie, trafienie, trafienie, alarm	1,00
trafienie, alarm, trafienie, trafienie	≈ 0,83
alarm, trafienie, trafienie, trafienie	0,75

Lepiej, gdy model najpierw pokazuje poprawne odpowiedzi.

W każdym wierszu na końcu znaleźliśmy wszystkie auta.

Czy AP = 1 oznacza brak błędów?

Spójrzmy jeszcze raz na najlepszą listę

trafienie, trafienie, trafienie, alarm

AP = 1,00

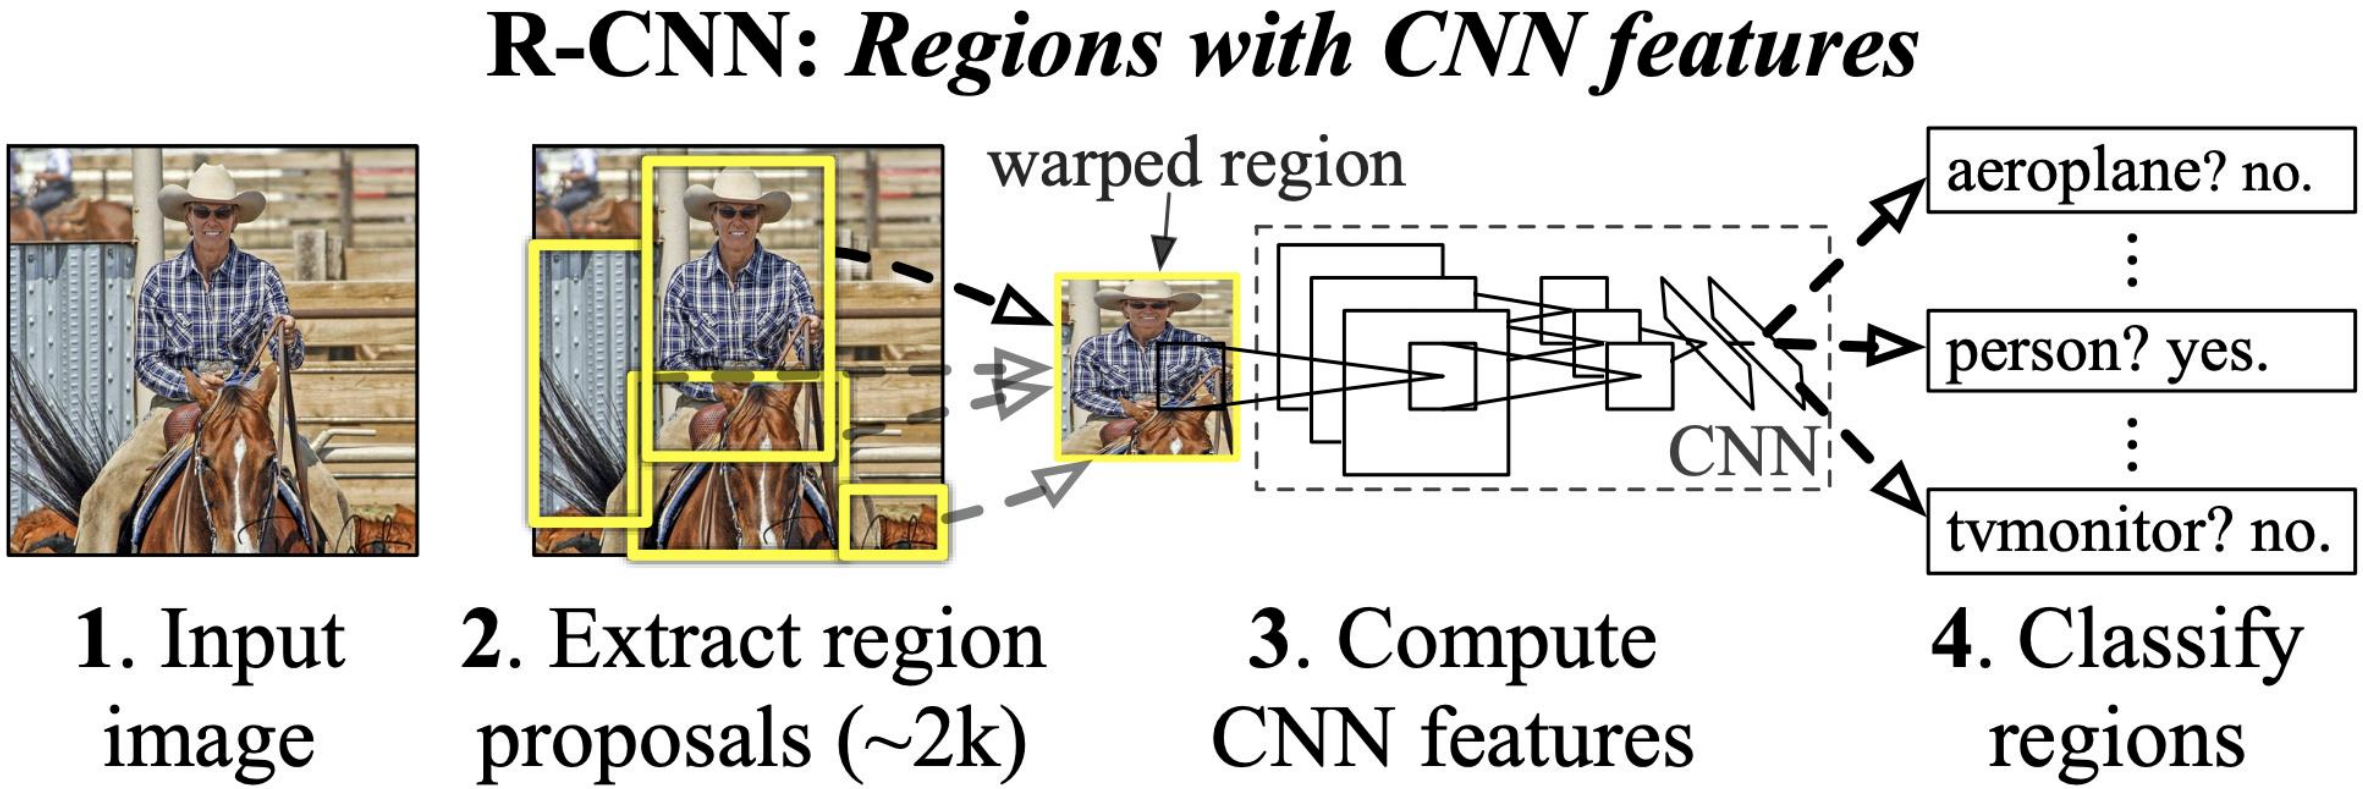
A jednak ostatnie zgłoszenie jest fałszywym alarmem.

W aplikacji trzeba wybrać, jak pewne zgłoszenia pokazywać.

AP pomaga porównywać modele. Warto też obejrzeć ich pomyłki.

Architektury używane do detekcji

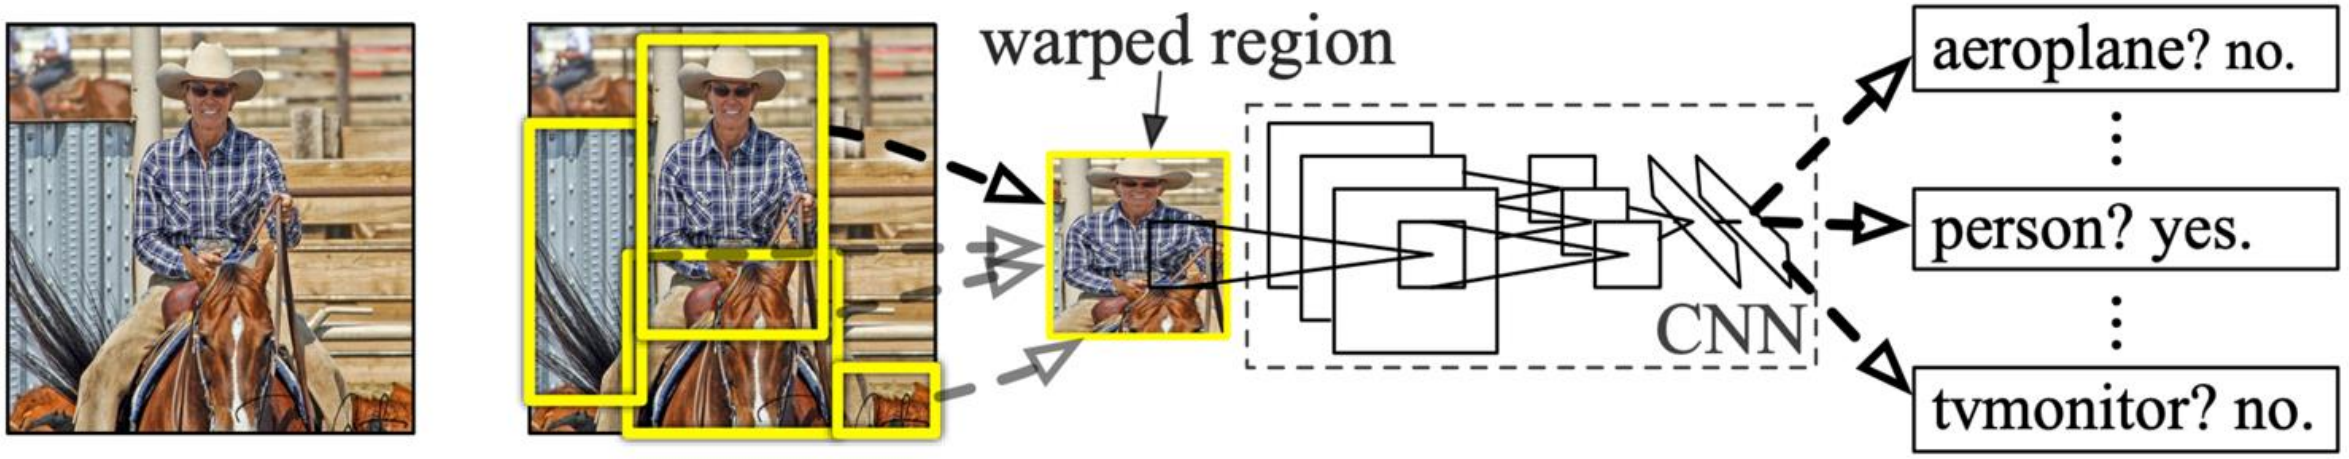
RCNN



Ros et al. "Rich feature hierarchies for accurate object detection and semantic segmentation." *CVPR*, 2014

R-CNN: jak znaleźć obiekty na zdjęciu?

Pomysł: wybierz fragmenty obrazu i rozpoznaj ich zawartość.



1. Obraz

2. Propozycje fragmentów

3. CNN opisuje zawartość

4. Rozpoznanie klasy

Osobno sprawdzamy wiele miejsc, w których może znajdować się obiekt.

Krok 1: gdzie warto szukać?

Na początku mamy pomysły na fragmenty, a nie gotowe rozpoznania.



„Tutaj może być obiekt”

Program proponuje prostokąty o różnych rozmiarach.

Selective Search szuka fragmentów na podstawie wyglądu obrazu, np. kolorów i podobnych tekstur.

Oryginalny R-CNN analizuje około 2000 takich propozycji na obraz.

Krok 2: przygotowanie wycinków

Każdy wybrany fragment dopasowujemy do wejścia sieci.

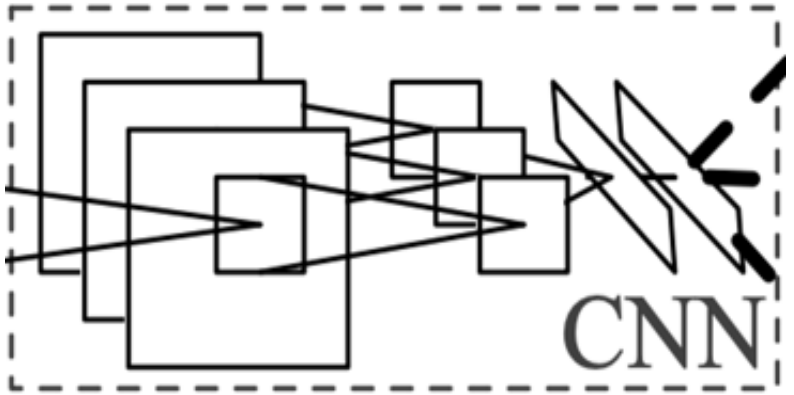
Wycinek



Zmiana rozmiaru



Ta sama sieć CNN

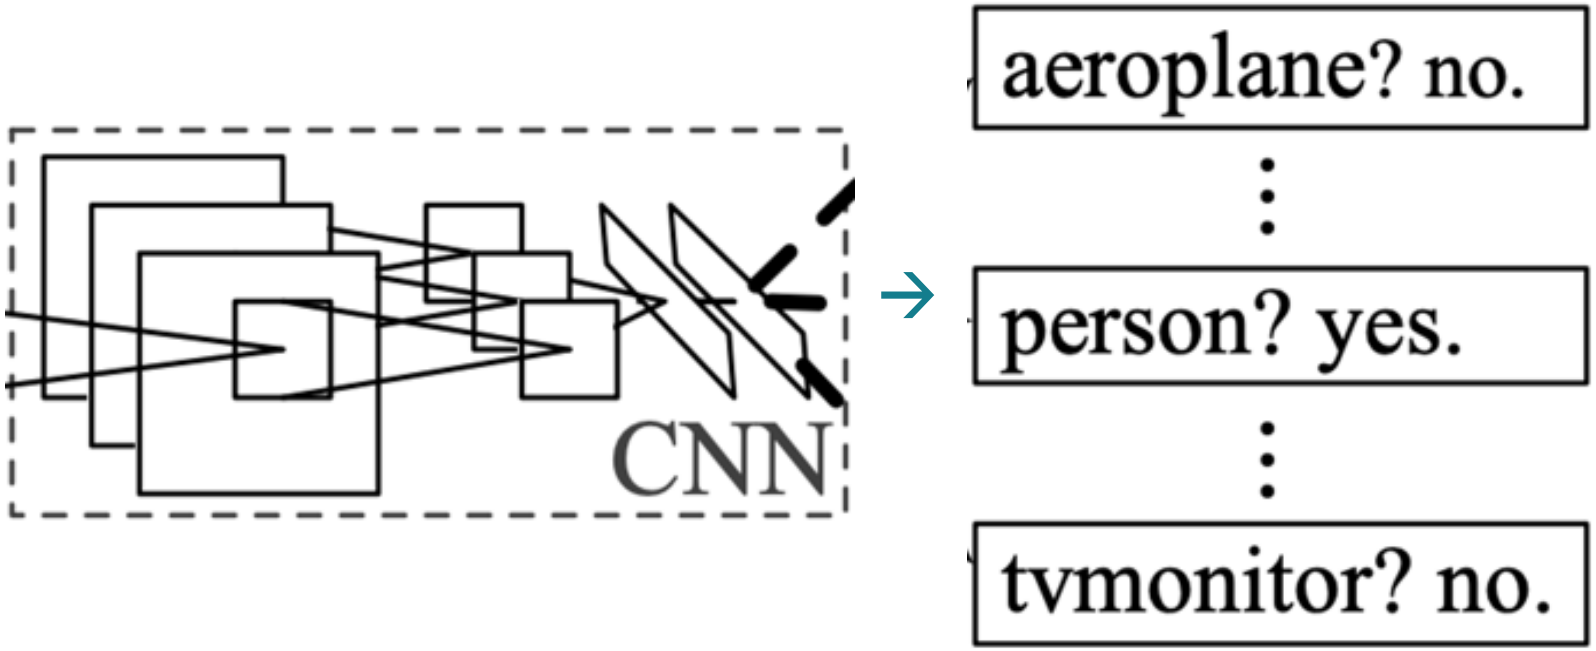


Wycinki mogą mieć różne proporcje. Podczas dopasowania mogą się rozciągnąć.

Każdy wycinek przechodzi przez tę samą sieć, ale osobno.

Krok 3: co jest we fragmencie?

CNN tworzy opis. Klasyfikator ocenia, do jakiej klasy pasuje.



CNN

Zamienia wygląd wycinka w opis zapisany liczbami.

Klasyfikator

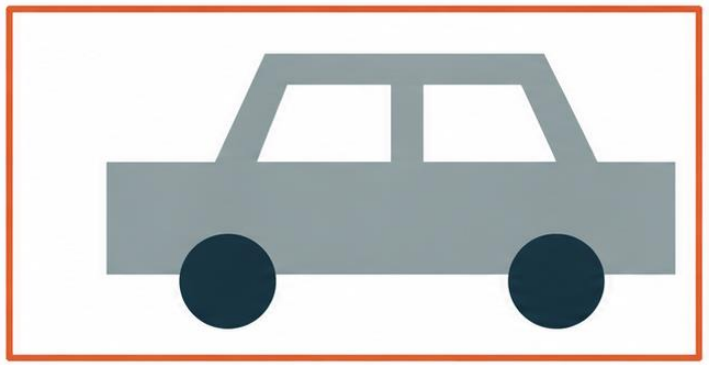
Sprawdza, czy opis pasuje np. do człowieka lub konia.

Fragment może pasować do klasy obiektu albo zostać uznany za tło.

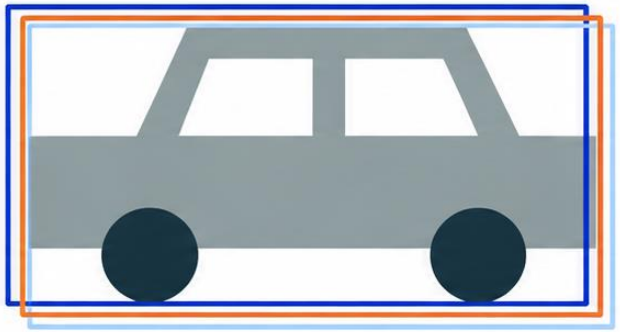
Krok 4: uporządkowanie ramek

Poprawiamy położenie i ograniczamy powtórzone wykrycia.

Początkowa ramka



Lepsze dopasowanie



Usunięcie powtórzeń



Kilka propozycji może wskazywać ten sam samochód.

Chcemy wskazać obiekt, a nie zgłosić go kilka razy.

Dlaczego R-CNN działa wolno?

Dużo wycinków oznacza dużo powtarzanej pracy.



Około 2000 wycinków

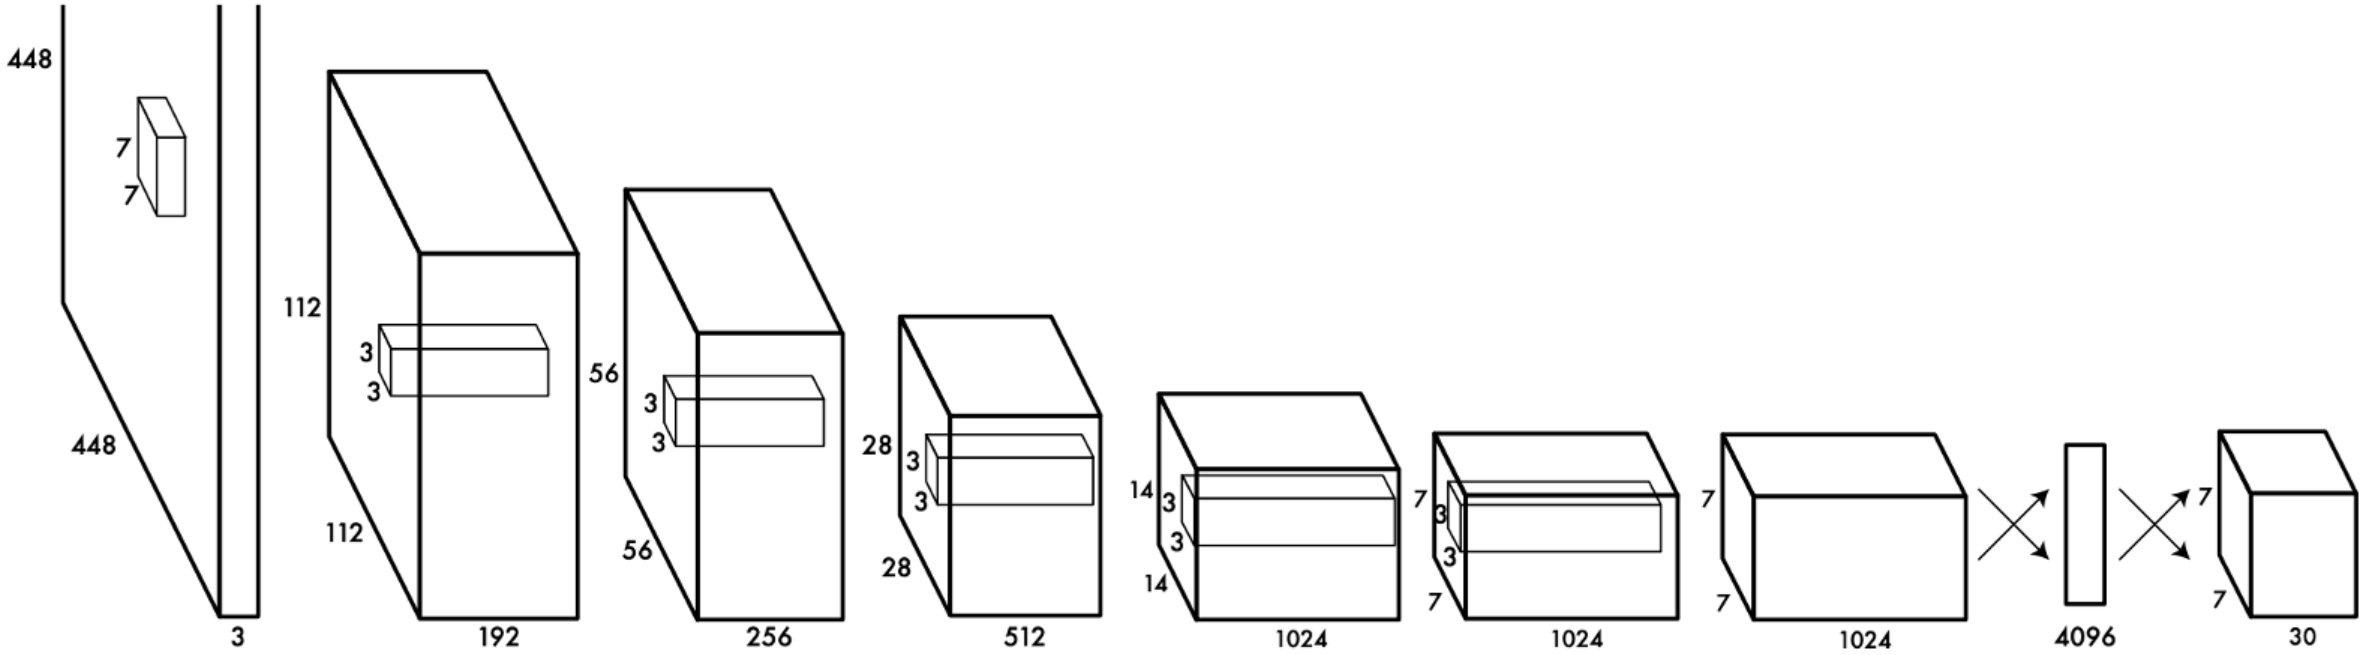
Każdy osobno przechodzi przez sieć CNN.

Nakładające się wycinki zawierają wiele tych samych pikseli.

Ta sama sieć wielokrotnie analizuje podobne fragmenty jednego zdjęcia.

YOLO: cały obraz w jednym przejściu

You Only Look Once: sieć jednocześnie przewiduje klasy i ramki.



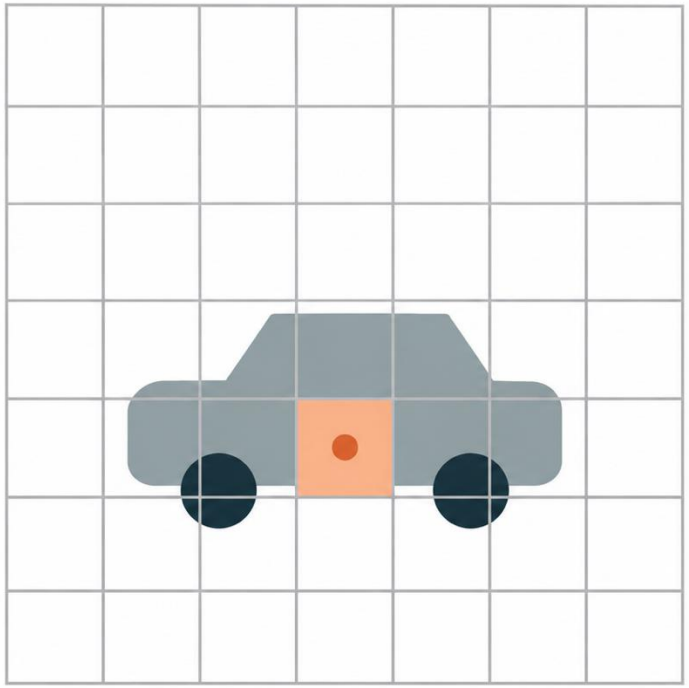
Obraz **CNN analizuje całość** **Klasy i ramki**

Na tym schemacie widzimy pierwszą wersję YOLO: YOLOv1.

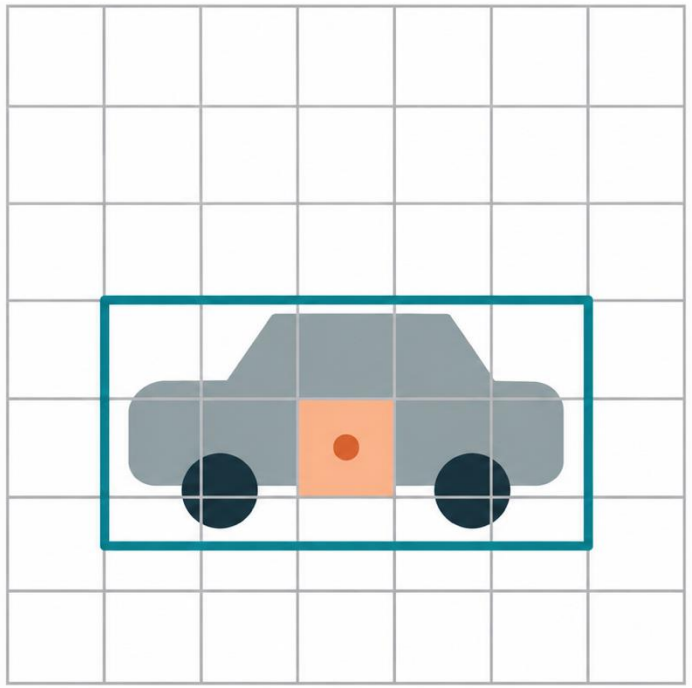
YOLOv1: kto odpowiada za dane auto?

Obraz opisujemy siatką 7×7 komórek.

Komórka ze środkiem obiektu



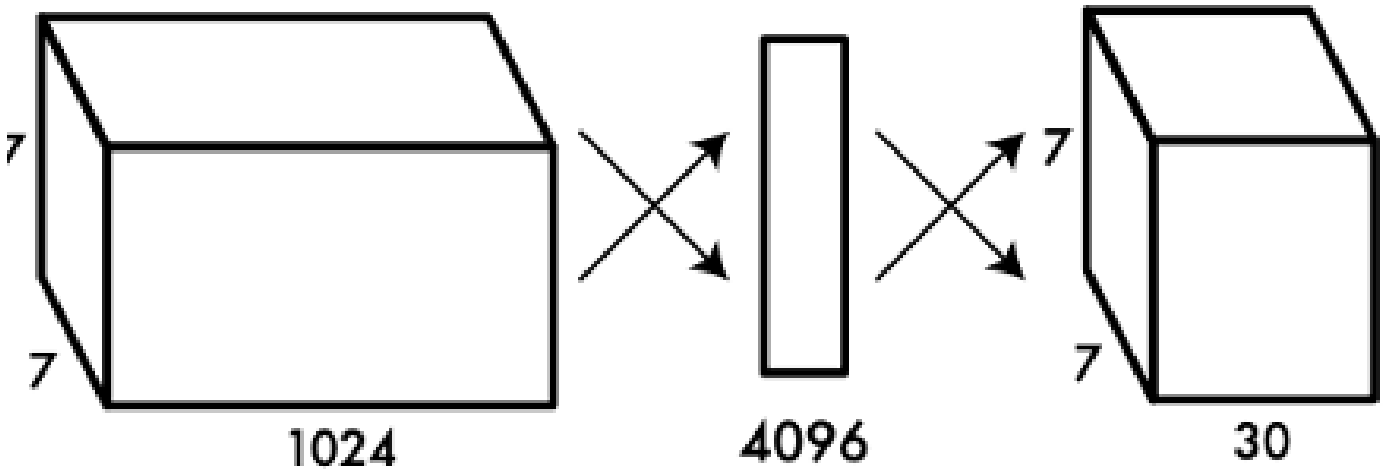
Ramka może wyjść poza komórkę



Komórka odpowiada za obiekt, którego środek do niej wpada.

YOLOv1: co zwraca sieć?

Wynik opisuje obiekt oraz jego położenie.



Klasa

Co to jest, np. samochód.

Ramka i ocena pewności

Gdzie jest obiekt i jak mocne jest zgłoszenie modelu.

Odrzucamy słabe zgłoszenia i usuwamy powtórzenia (NMS).

YOLOv1 a znany już R-CNN

Inny sposób organizacji obliczeń

R-CNN

Wiele wycinków.
Każdy osobno analizuje CNN.

YOLOv1

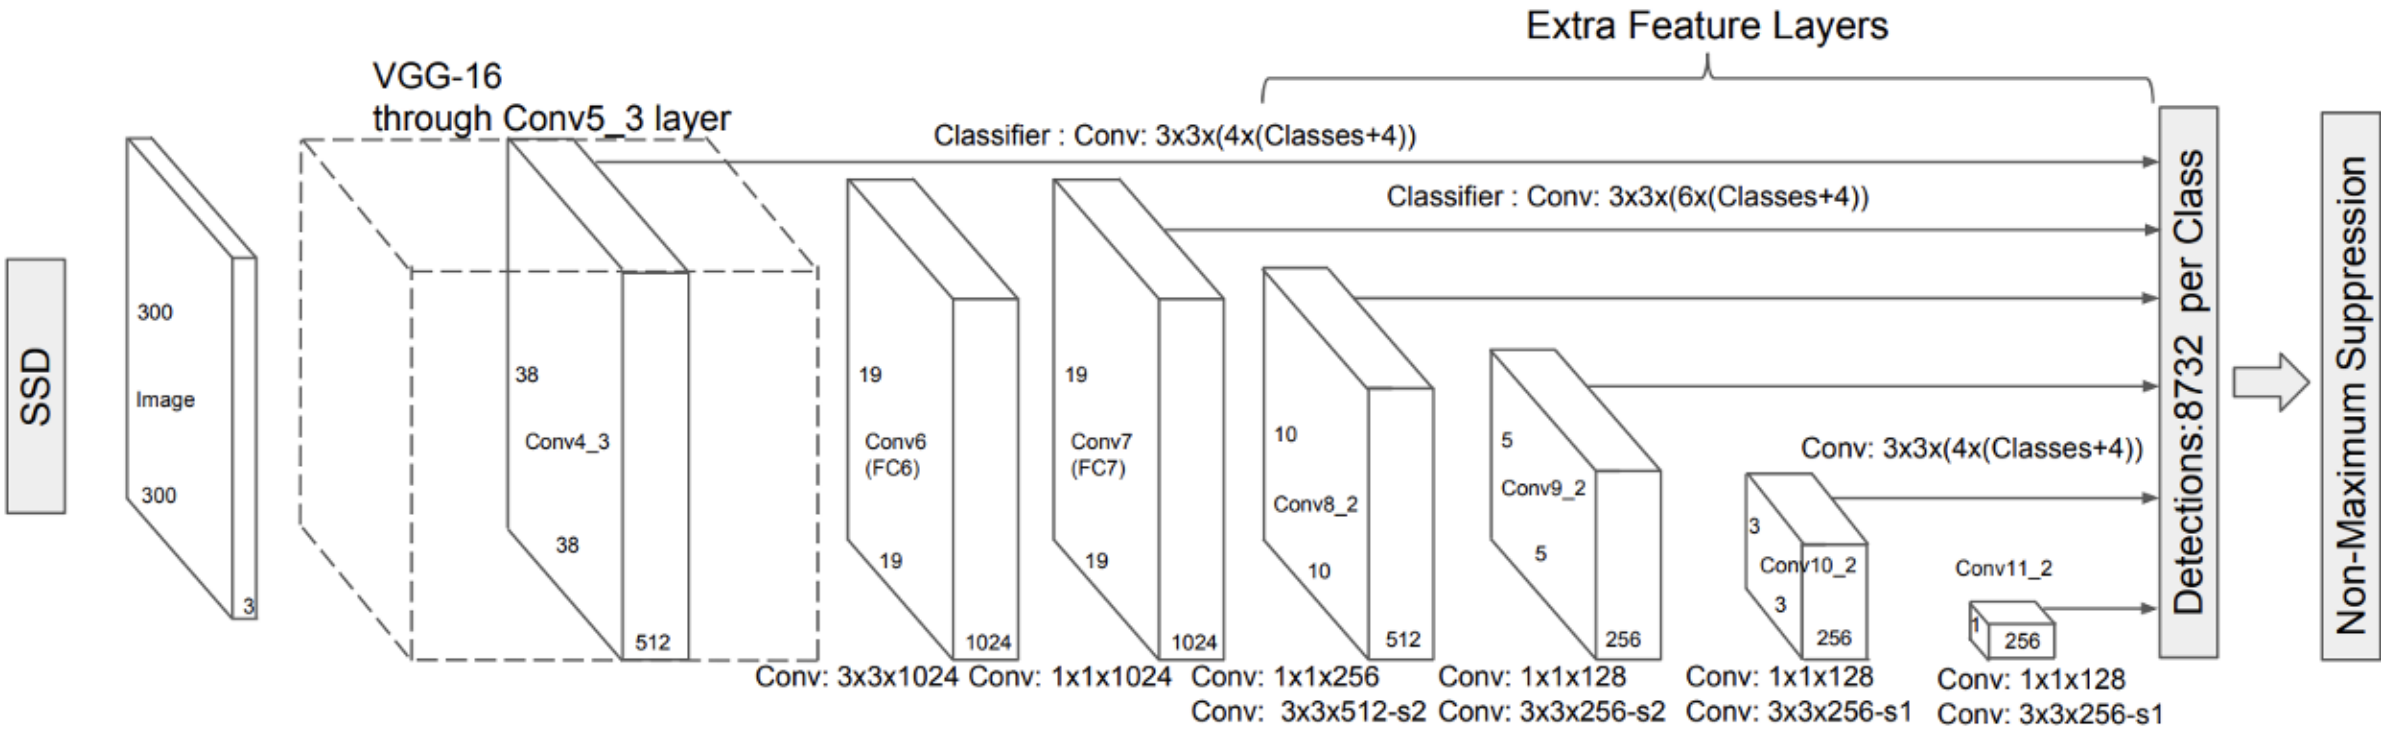
Cały obraz.
Wiele przewidywań naraz.

Małe obiekty i obiekty blisko siebie były trudnością pierwszej wersji YOLO.

Jedno przejście przez sieć pomaga ograniczyć powtarzanie pracy.

SSD: wykrywanie w kilku skalach

Single Shot MultiBox Detector: wiele poziomów jednej sieci szuka obiektów.

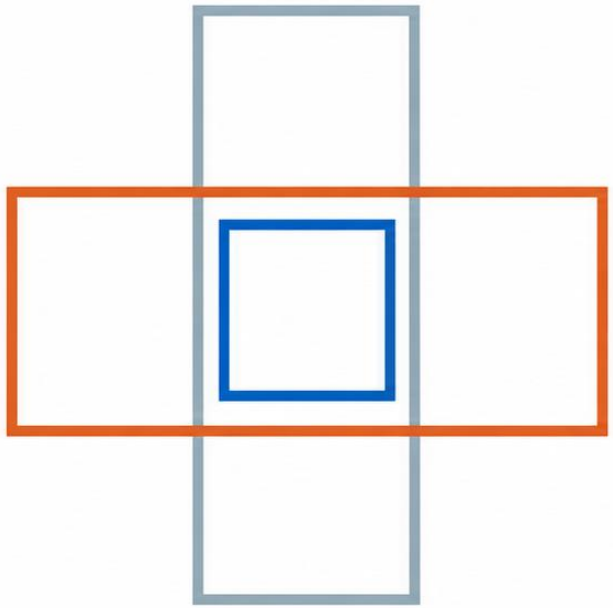


Różne poziomy cech pomagają wykrywać obiekty różnej wielkości.

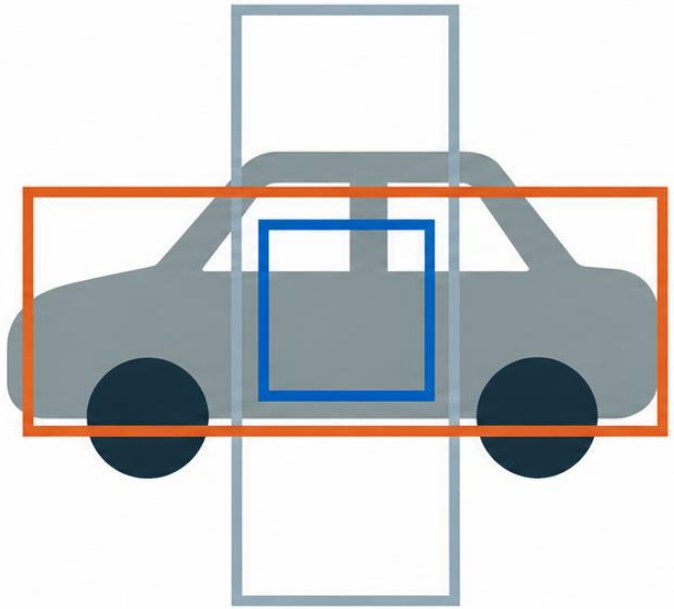
SSD: gotowe kształty ramek

Sieć dopasowuje szablony do obiektów na obrazie.

Szablony ramek



Obraz i szablony



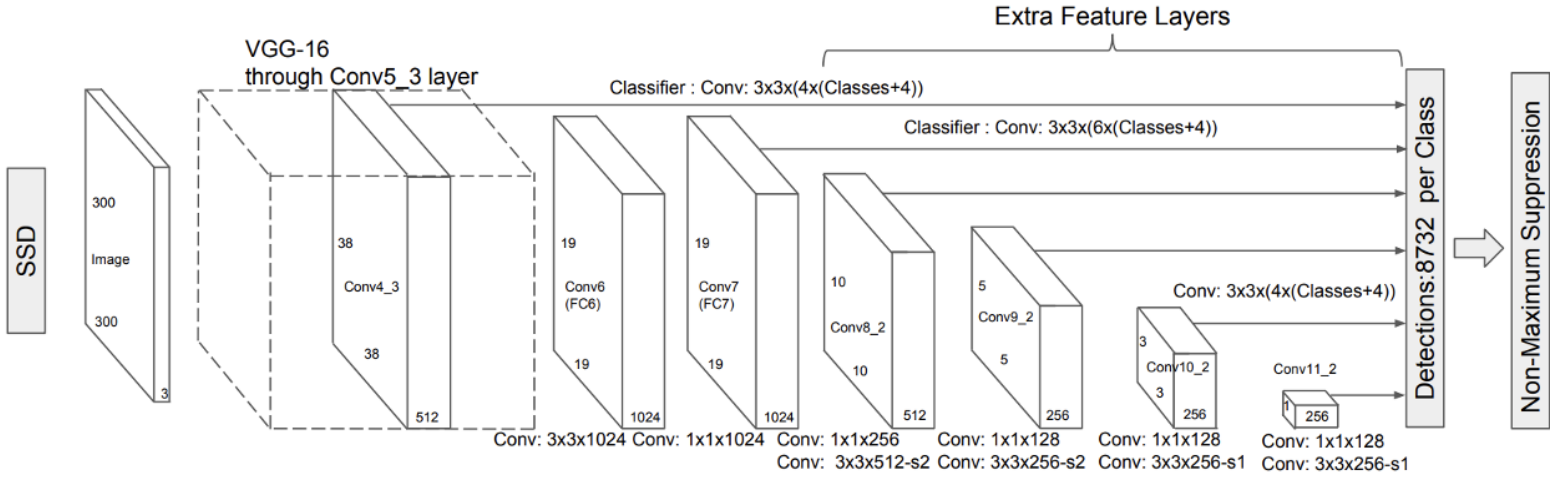
Dopasowana ramka



Szablon jest punktem startowym. Sieć poprawia jego położenie i rozmiar.

SSD: po co kilka map cech?

Wyniki pochodzą z kilku miejsc w architekturze.



Więcej szczegółów

Pomaga zauważyć mały obiekt.

Szerszy kontekst

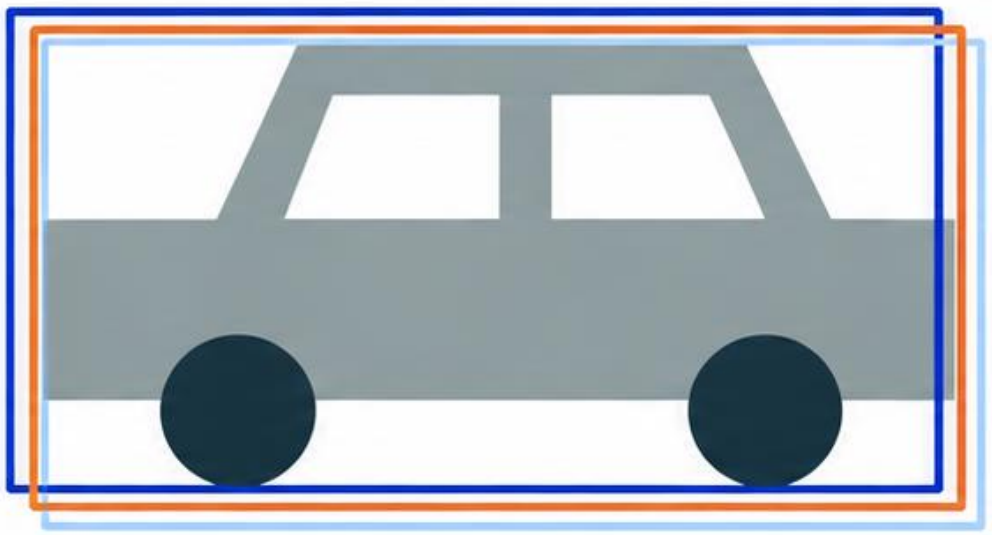
Pomaga opisać większy obszar.

Wszystkie poziomy korzystają z obliczeń tej samej sieci.

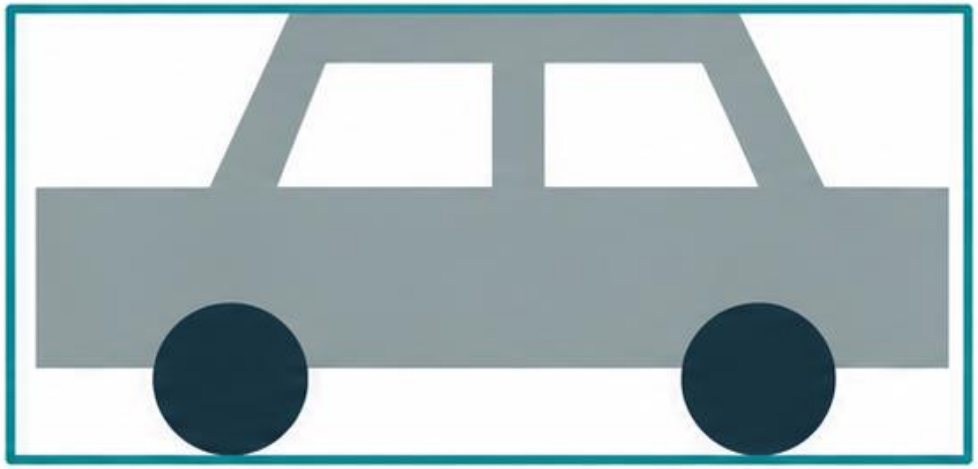
SSD: jedna lista końcowych wykryć

Łączymy ramki ze wszystkich poziomów i ograniczamy powtórzenia.

Kilka zgłoszeń tego samego auta



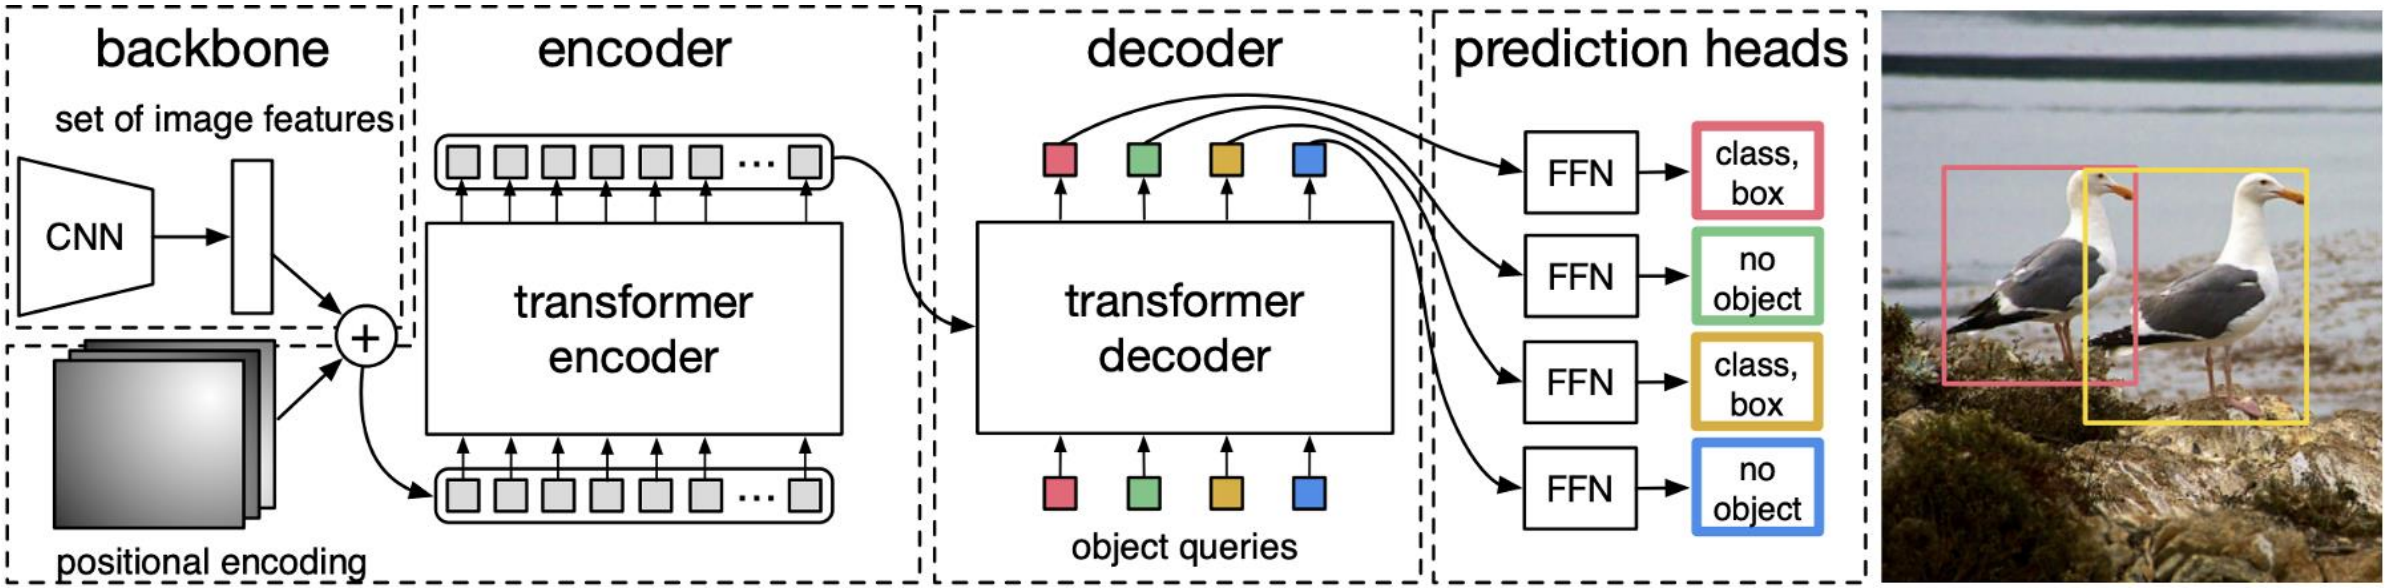
Po usunięciu powtórzeń



NMS ogranicza liczbę bardzo podobnych ramek tej samej klasy.

DETR: zestaw odpowiedzi o obiektach

CNN opisuje obraz, a transformer pomaga przewidzieć obiekty.

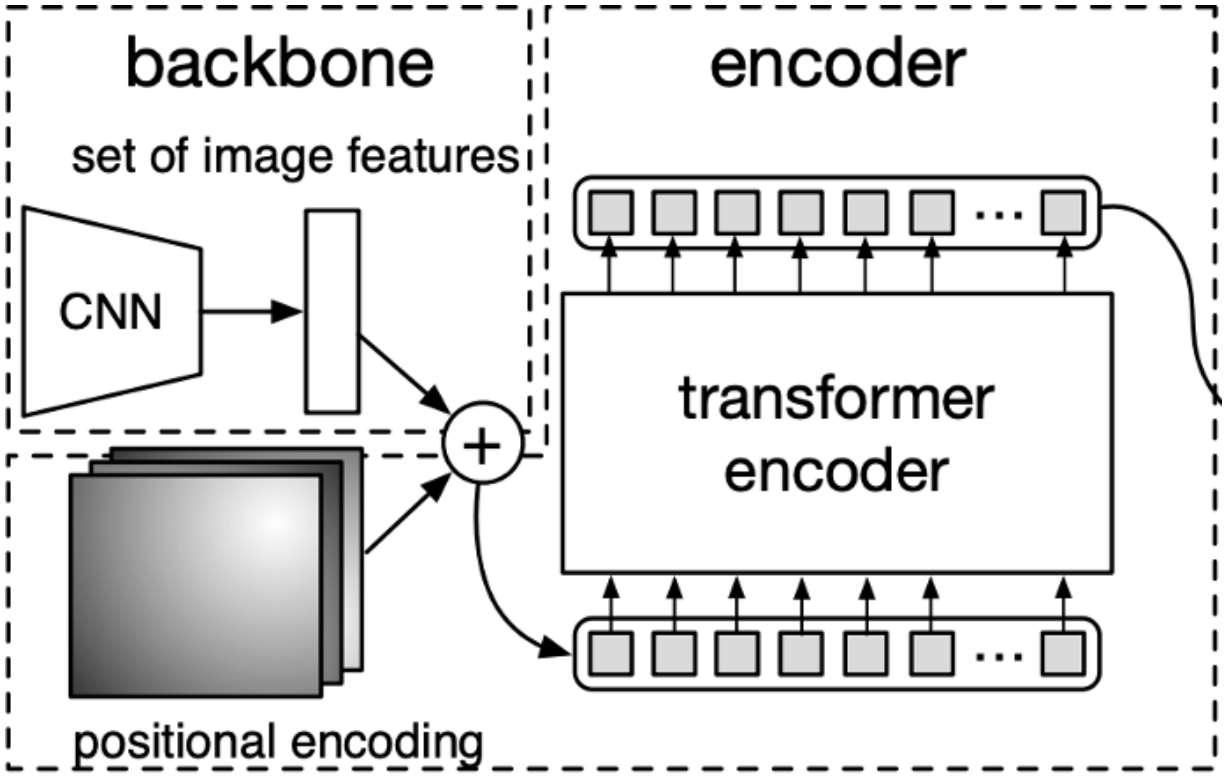


Cechy obrazu **Relacje i kontekst** **Miejsca na odpowiedzi** **Klasy i ramki**

DETR przewiduje odpowiedzi równolegle dla całego obrazu.

DETR: wygląd oraz położenie

Sieć potrzebuje informacji, co widać i gdzie.



CNN zbiera cechy

Tworzy liczbowy opis fragmentów obrazu.

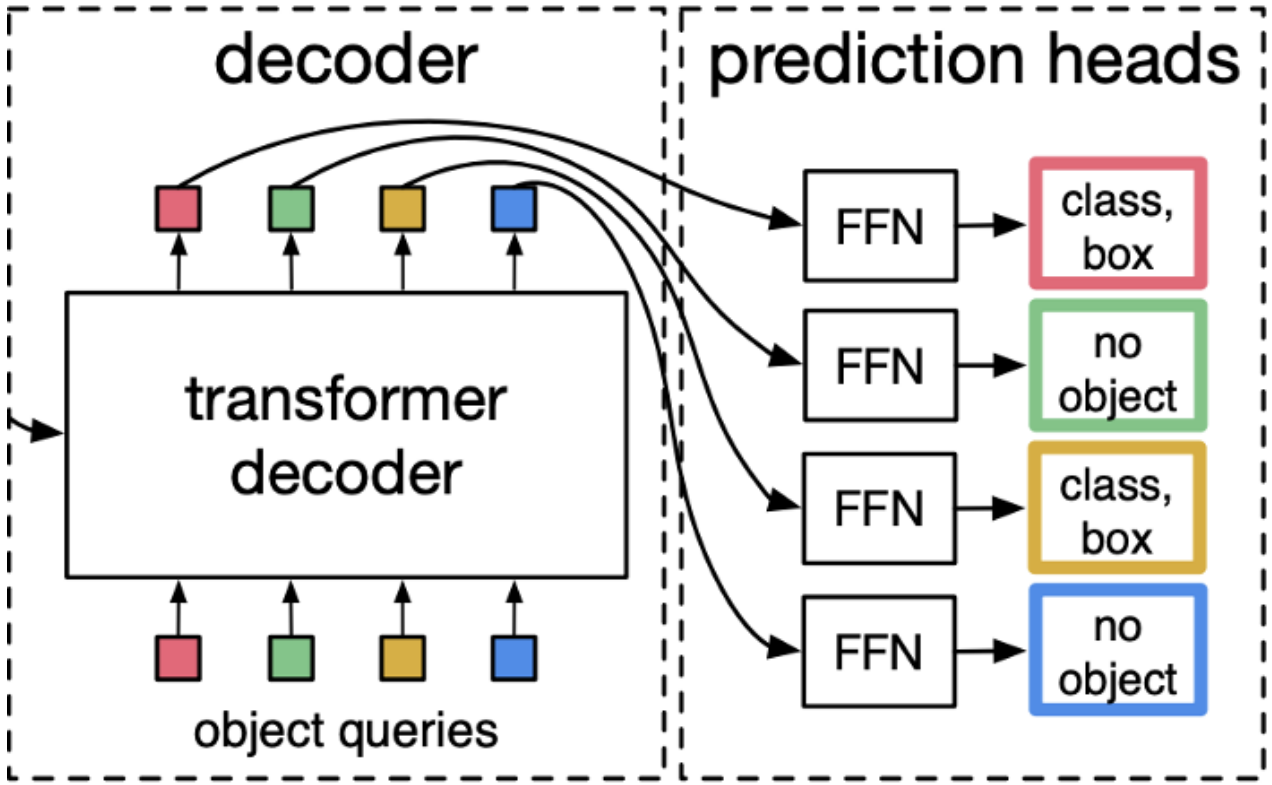
Pozycja mówi „gdzie”

Enkoder łączy informacje z różnych miejsc.

Kodowanie położenia pomaga zachować przestrzenny układ obrazu.

DETR: miejsca na odpowiedzi

Każde może zwrócić obiekt albo „brak obiektu”.



Object queries

Wyuczone miejsca na różne odpowiedzi.

Wynik jednego miejsca

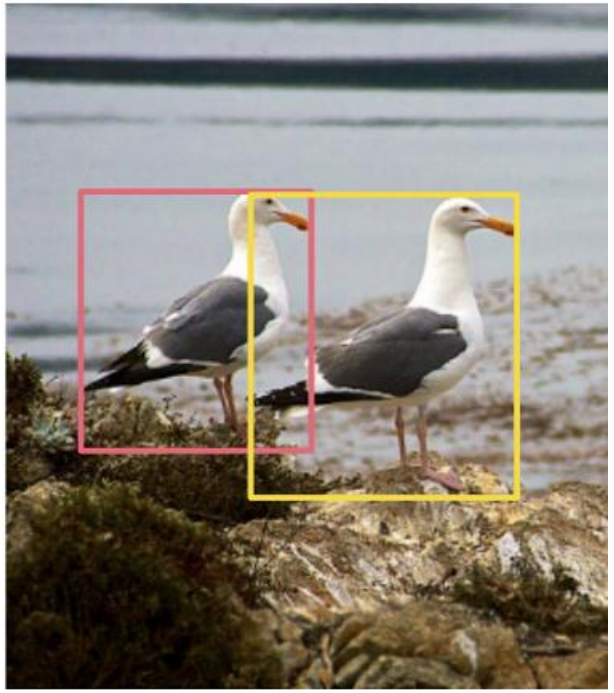
Klasa i ramka lub „brak obiektu”.

Zapytania są wyuczonymi liczbami, a nie pytaniami wpisanymi przez człowieka.

DETR: jak uczy się unikać powtórzeń?

Podczas uczenia dopasowujemy odpowiedzi do prawdziwych obiektów.

Miejsce	Przykładowy cel podczas uczenia
1. różowe	pierwszy ptak
2. zielone	brak obiektu
3. żółte	drugi ptak
4. niebieskie	brak obiektu

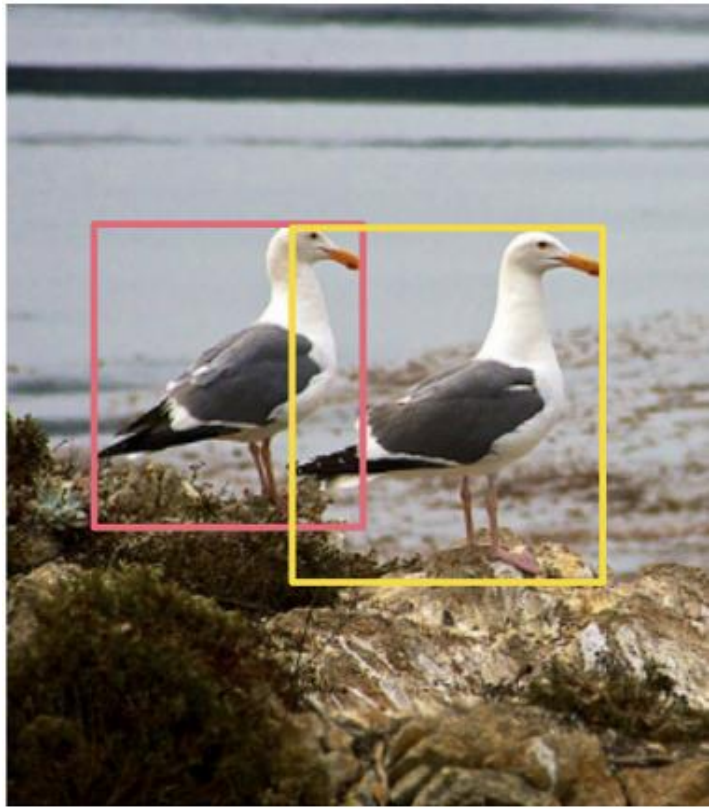


Jeden prawdziwy obiekt powinien otrzymać jedną dopasowaną odpowiedź.

DETR: końcowy zestaw wykryć

Dwa ptaki, dwa wykrycia. Pozostałe odpowiedzi mogą być puste.

Model uczy się ograniczać powtórzone zgłoszenia.



Oryginalny DETR nie wymaga NMS.

To nadal model, który może pominąć obiekt lub błędnie wskazać ramkę.

Wyniki „brak obiektu” pomijamy w końcowej liście wykryć.

Cztery pomysły na detekcję

Każdy model ma wskazać, co znajduje się na obrazie i gdzie.

Model	Główny pomysł	Powtórzenia
R-CNN	Osobna analiza wielu wycinków	Ogranicza je NMS
YOLOv1	Cały obraz i predykcje na siatce	Ogranicza je NMS
SSD	Ramki startowe i kilka skal cech	Ogranicza je NMS
DETR	Wyuczone miejsca na odpowiedzi	Uczy się jednej odpowiedzi na obiekt

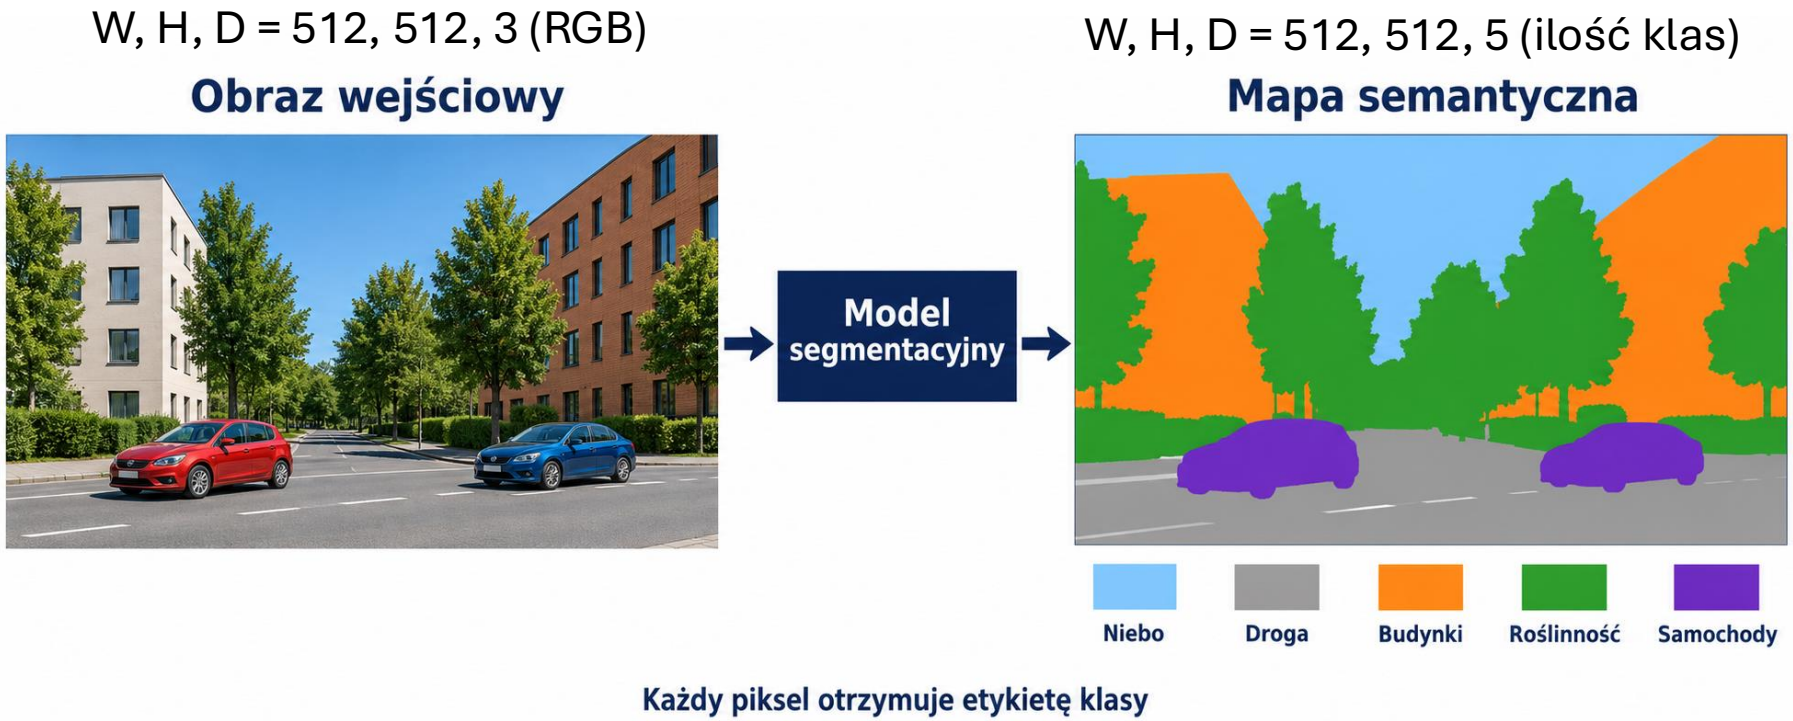
Wynik każdego z nich to klasy obiektów i ich ramki.



Segmentacja

Segmentacja - podstawy

- W zadaniach **segmentacji** mapujemy obraz do mapy semantycznej
- **Segmentacja to klasyfikacja pikseli na obrazie**

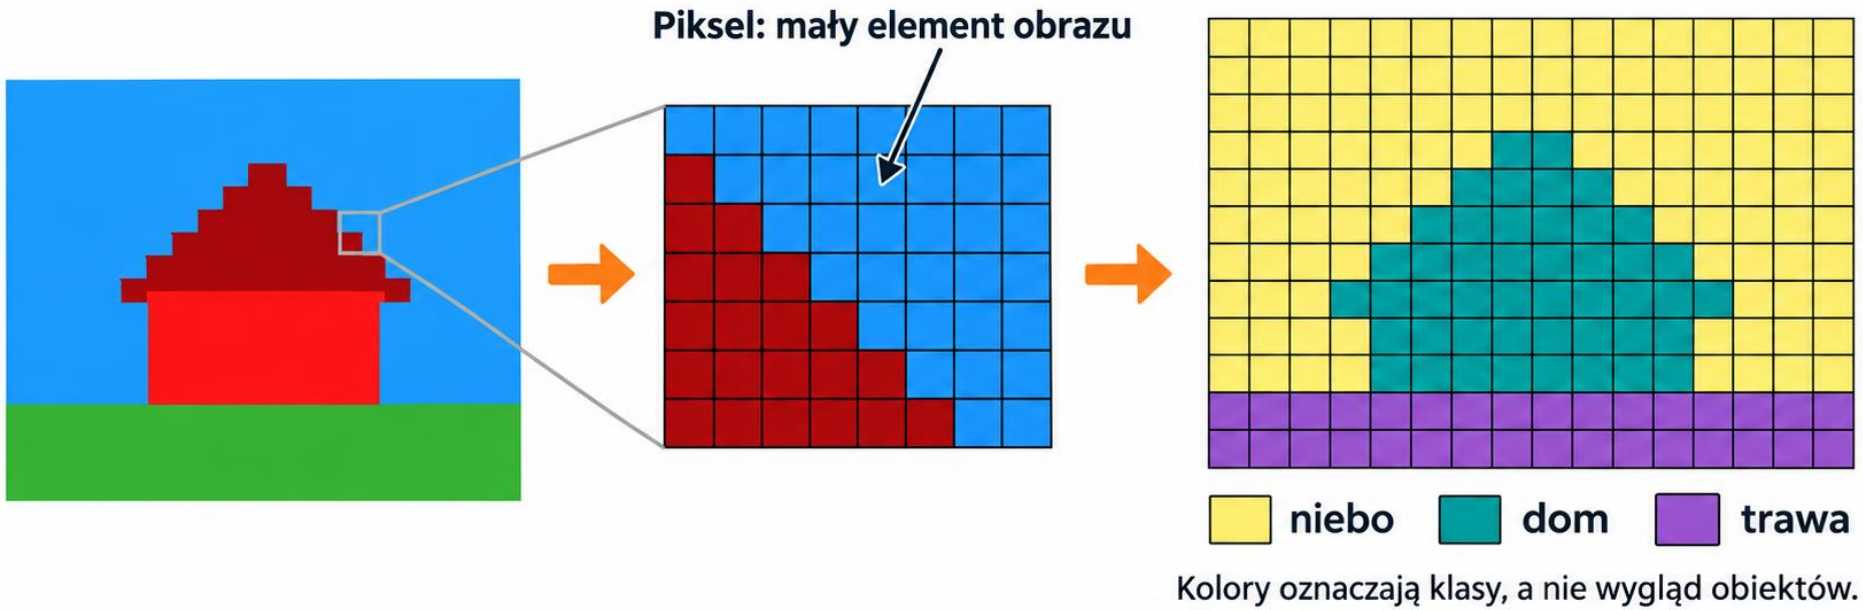


Segmentacja = klasyfikacja każdego piksela

1. Obraz

2. Piksele

3. Klasa dla każdego piksela



Kolory oznaczają klasy, a nie wygląd obiektów.

Każdy piksel otrzymuje jedną etykietę: niebo, dom albo trawa.

Rodzaje segmentacji

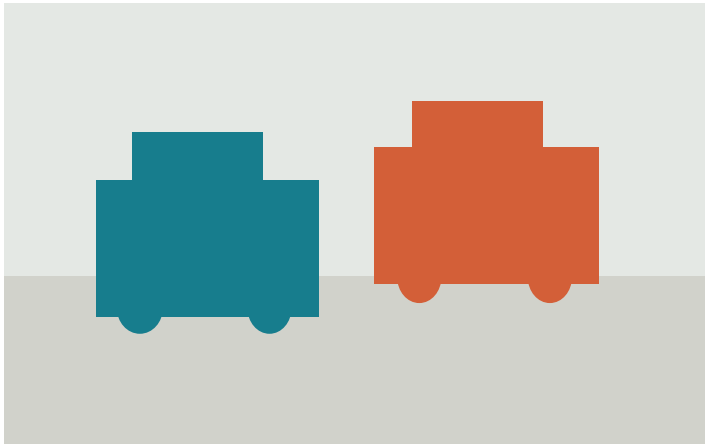
Semantyczna



Jedna klasa dla obu aut

- Wyznaczanie obszaru drogi,
- pomiar powierzchni roślinności na zdjęciach satelitarnych,
- określanie zasięgu zalania,
- zaznaczanie narządów w obrazach medycznych.

Instancji



Oddzielna maska każdego auta

- Liczenie komórek,
- rozdzielanie owoców na drzewie,
- pomiar każdego produktu na taśmie,
- wskazywanie robotowi konkretnego przedmiotu do podniesienia.

Panoptyczna



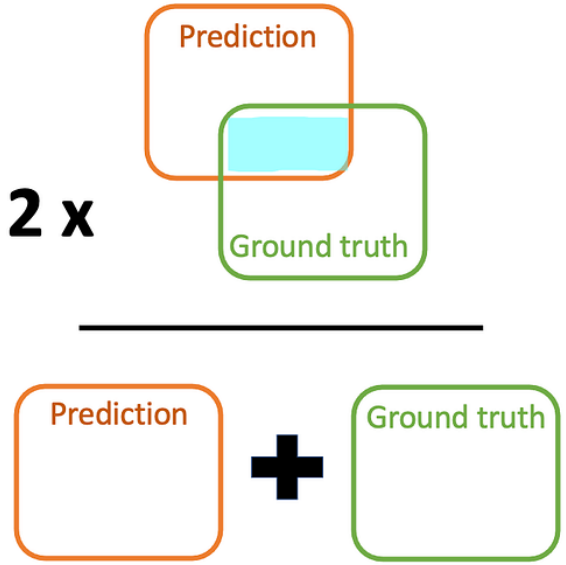
Instancje aut oraz droga i tło

- Pełny opis otoczenia pojazdu autonomicznego,
- nawigacja robotów mobilnych, analiza ulic z osobnymi pieszymi i pojazdami oraz obszarami drogi, chodnika i nieba.

Metryki używane w problemie segmentacji

- Dice Similarity Coefficient (DSC)

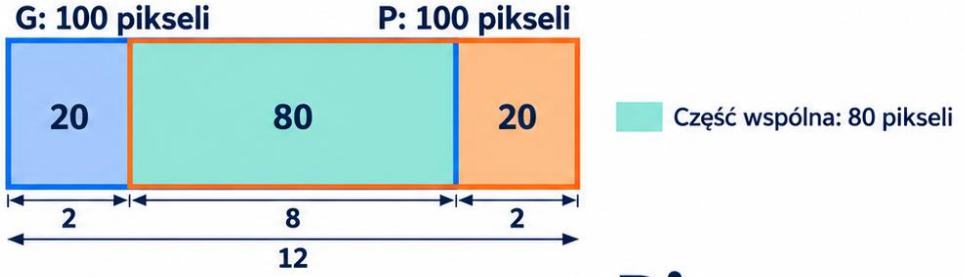
$$\text{Dice} = \frac{2\ X\ Area\ of\ overlap}{Total\ area} =$$



Kiedy Dice, a kiedy IoU?

IoU a Dice

Ta sama para masek, dwie skale wyniku



IoU

$$IoU = \frac{|G \cap P|}{|G \cup P|}$$

$$= \frac{80}{100 + 100 - 80} = 0{,}667$$

Mianownik: suma obszarów, 120 pikseli

Dice

$$Dice = \frac{2|G \cap P|}{|G| + |P|}$$

$$= \frac{160}{100 + 100} = 0{,}80$$

Mianownik: suma wielkości masek, 200 pikseli

$$Dice = \frac{2IoU}{1 + IoU}$$

Wyższa wartość Dice nie oznacza lepszej segmentacji

Odległość Hausdorffa

Odległość Hausdorffa w segmentacji nerki

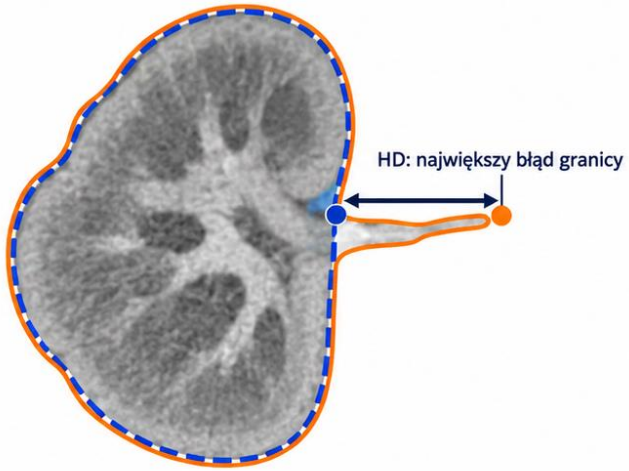
Przykład schematyczny na obrazie TK

Obraz TK z konturami



Kontur wzorcowy Kontur predykcji

Powiększenie granicy maski



Większość maski pokrywa nerkę.
IoU i Dice mogą pozostać wysokie.
HD ujawnia odległą wypustkę poza narządem.

HD sprawdza największą odległośc do najbliższego punktu drugiego konturu, w obu kierunkach.

Przydatna do oceny skrajnych błędów granicy. Mniej = lepiej.

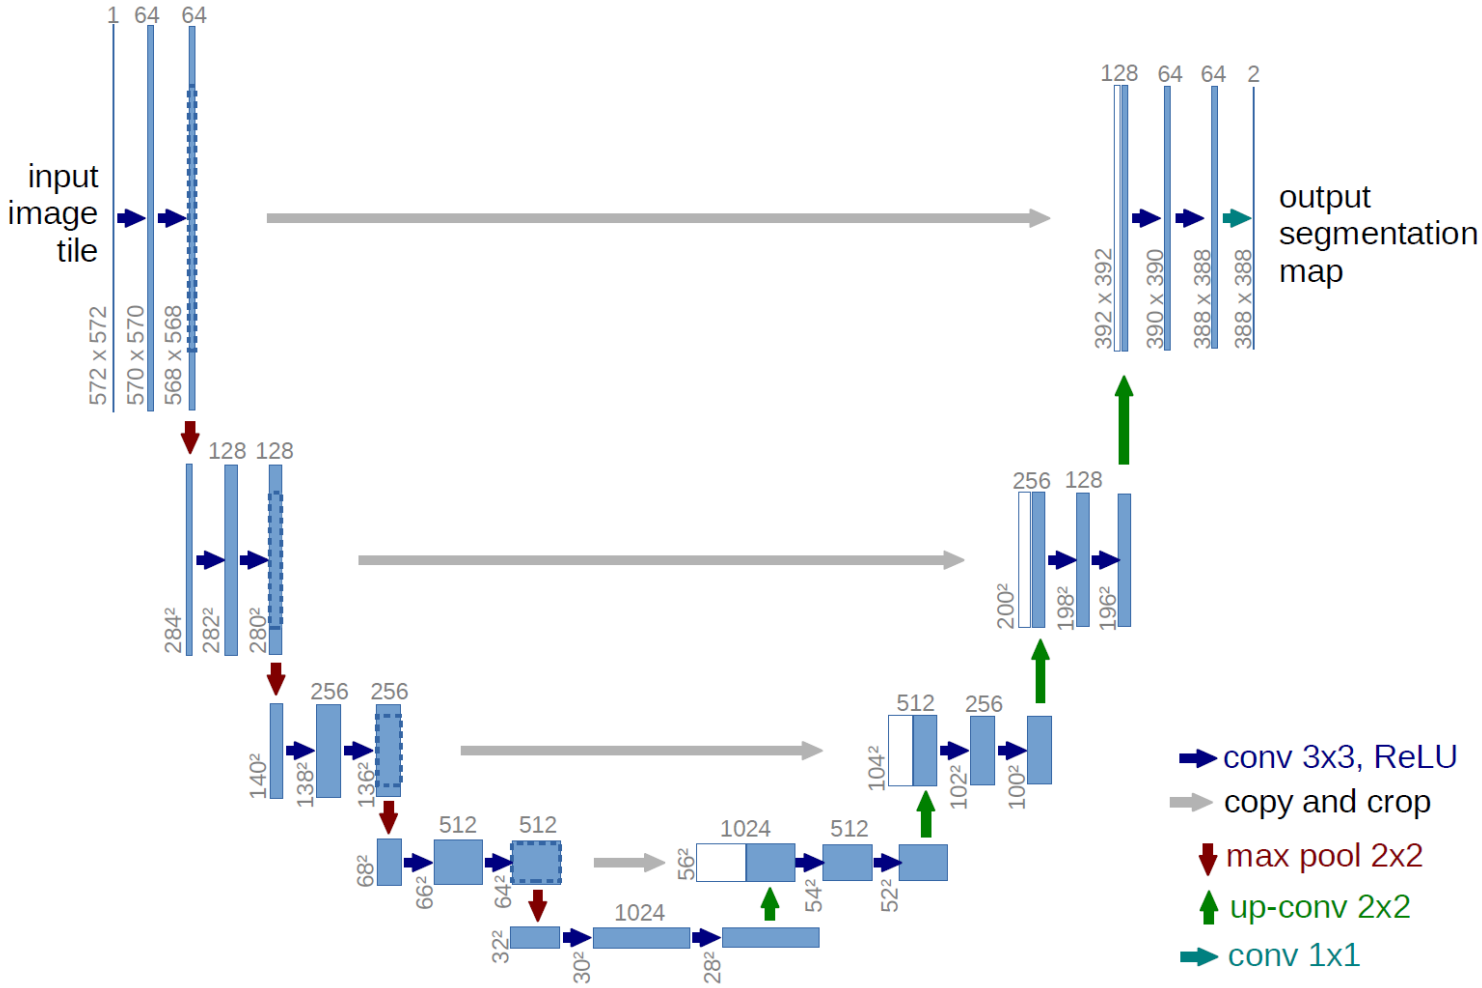
W danych medycznych odległość podajemy np. w mm, uwzględniając skalę obrazu. HD jest wrażliwa na szum.



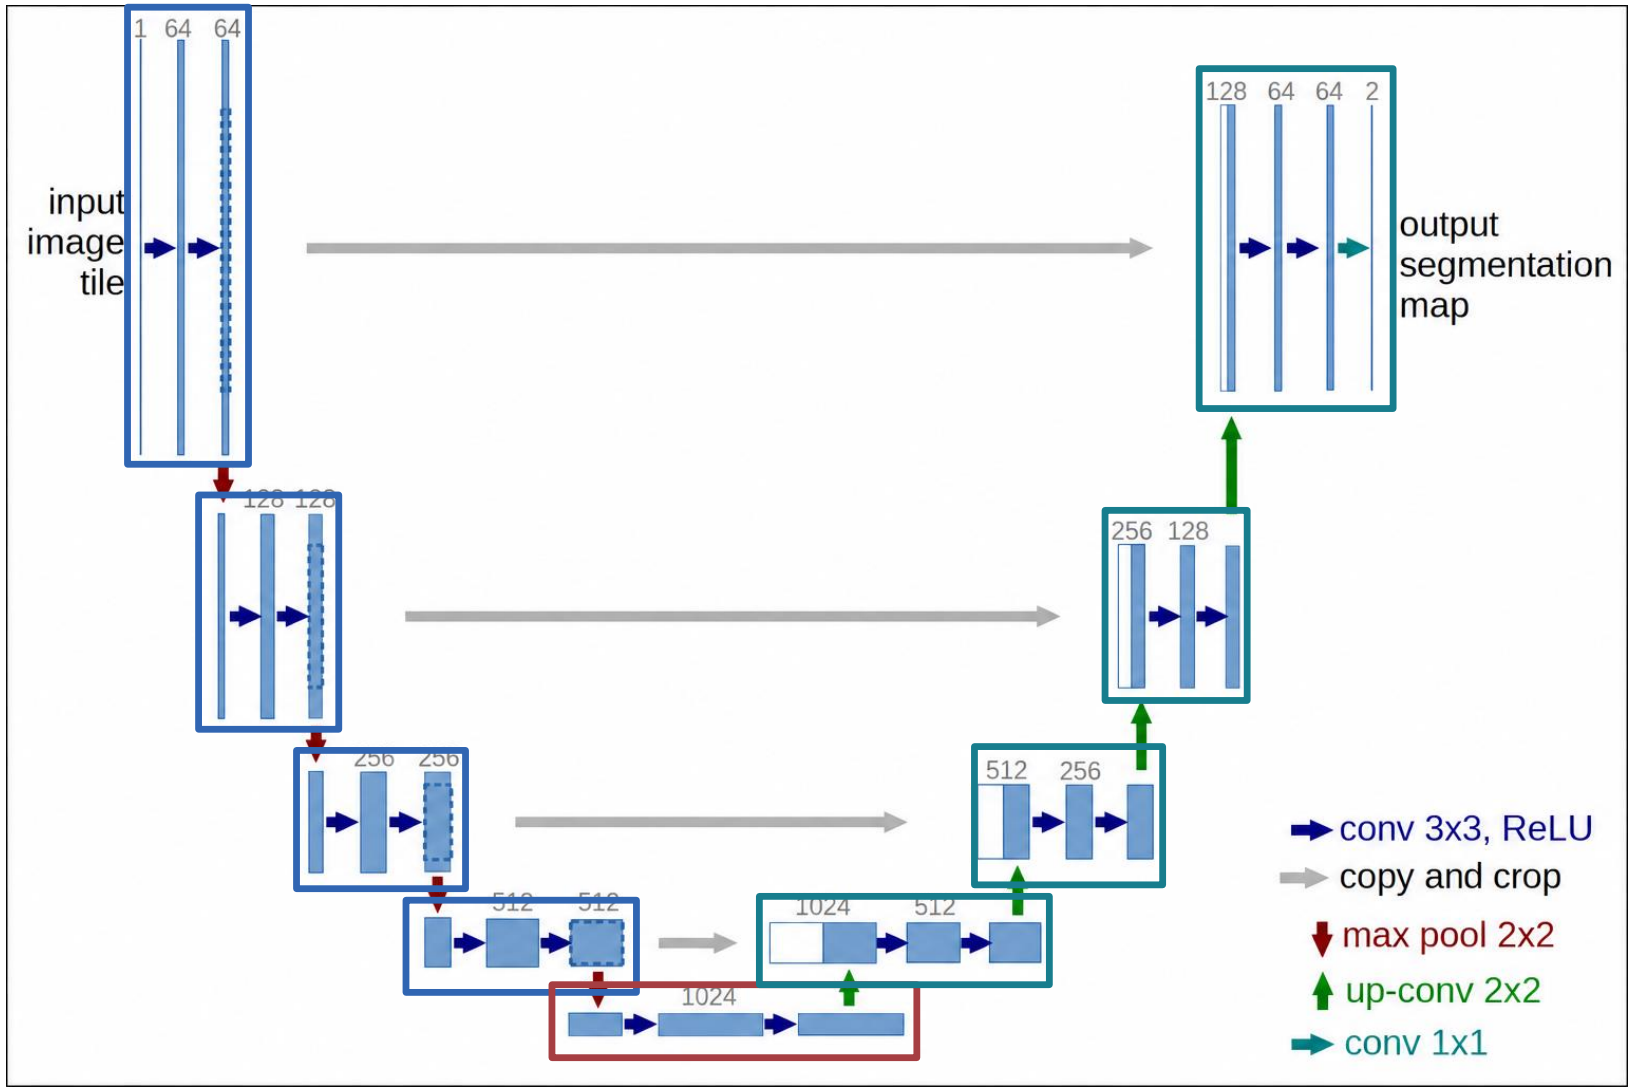
Architektury używane do segmentacji

U-Net

- Najpopularniejsza sieć wykorzystywana do segmentacji obrazów



U-Net: mapa całej architektury



Enkoder

Lewa ścieżka zmniejsza mapy i zbiera kontekst.

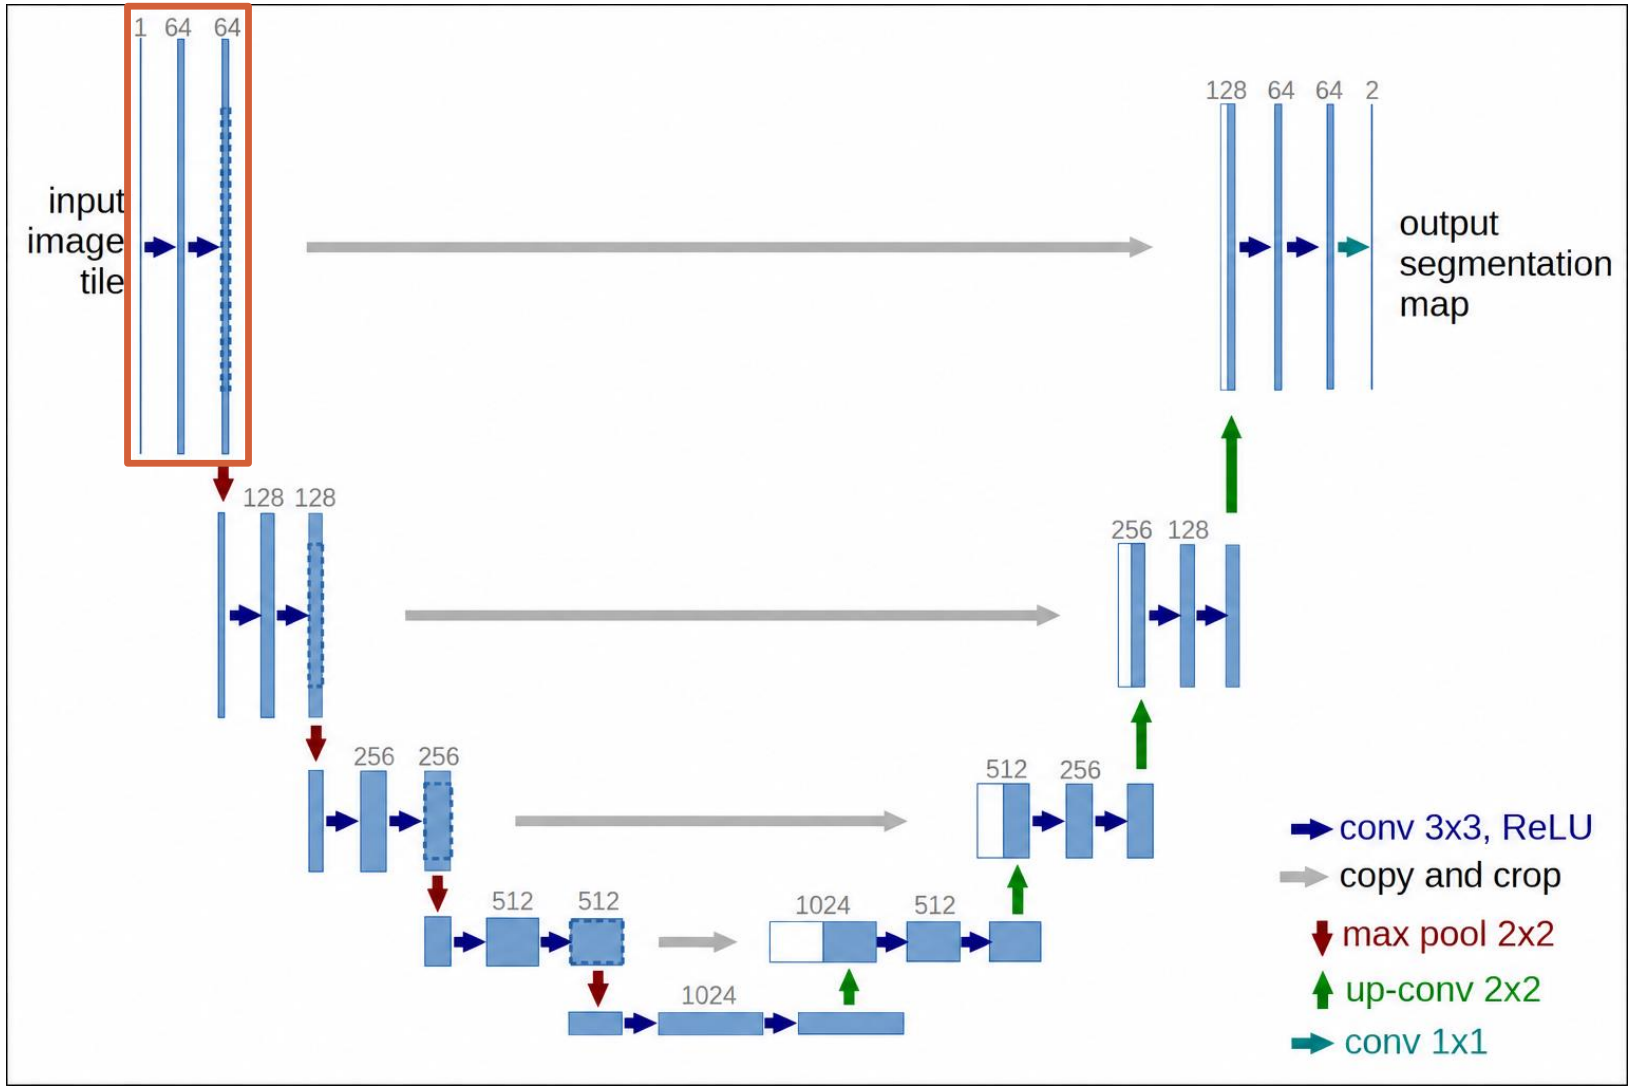
Wąskie gardło

Najniższa rozdzielczość i 1024 kanały cech.

Dekoder

Prawa ścieżka odtwarza lokalizację i mapę klas.

Sploty 3×3 i ReLU: budowanie cech



Dwa sploty w bloku

Na wejściu 1 kanał. Pierwszy blok tworzy 64 mapy cech.

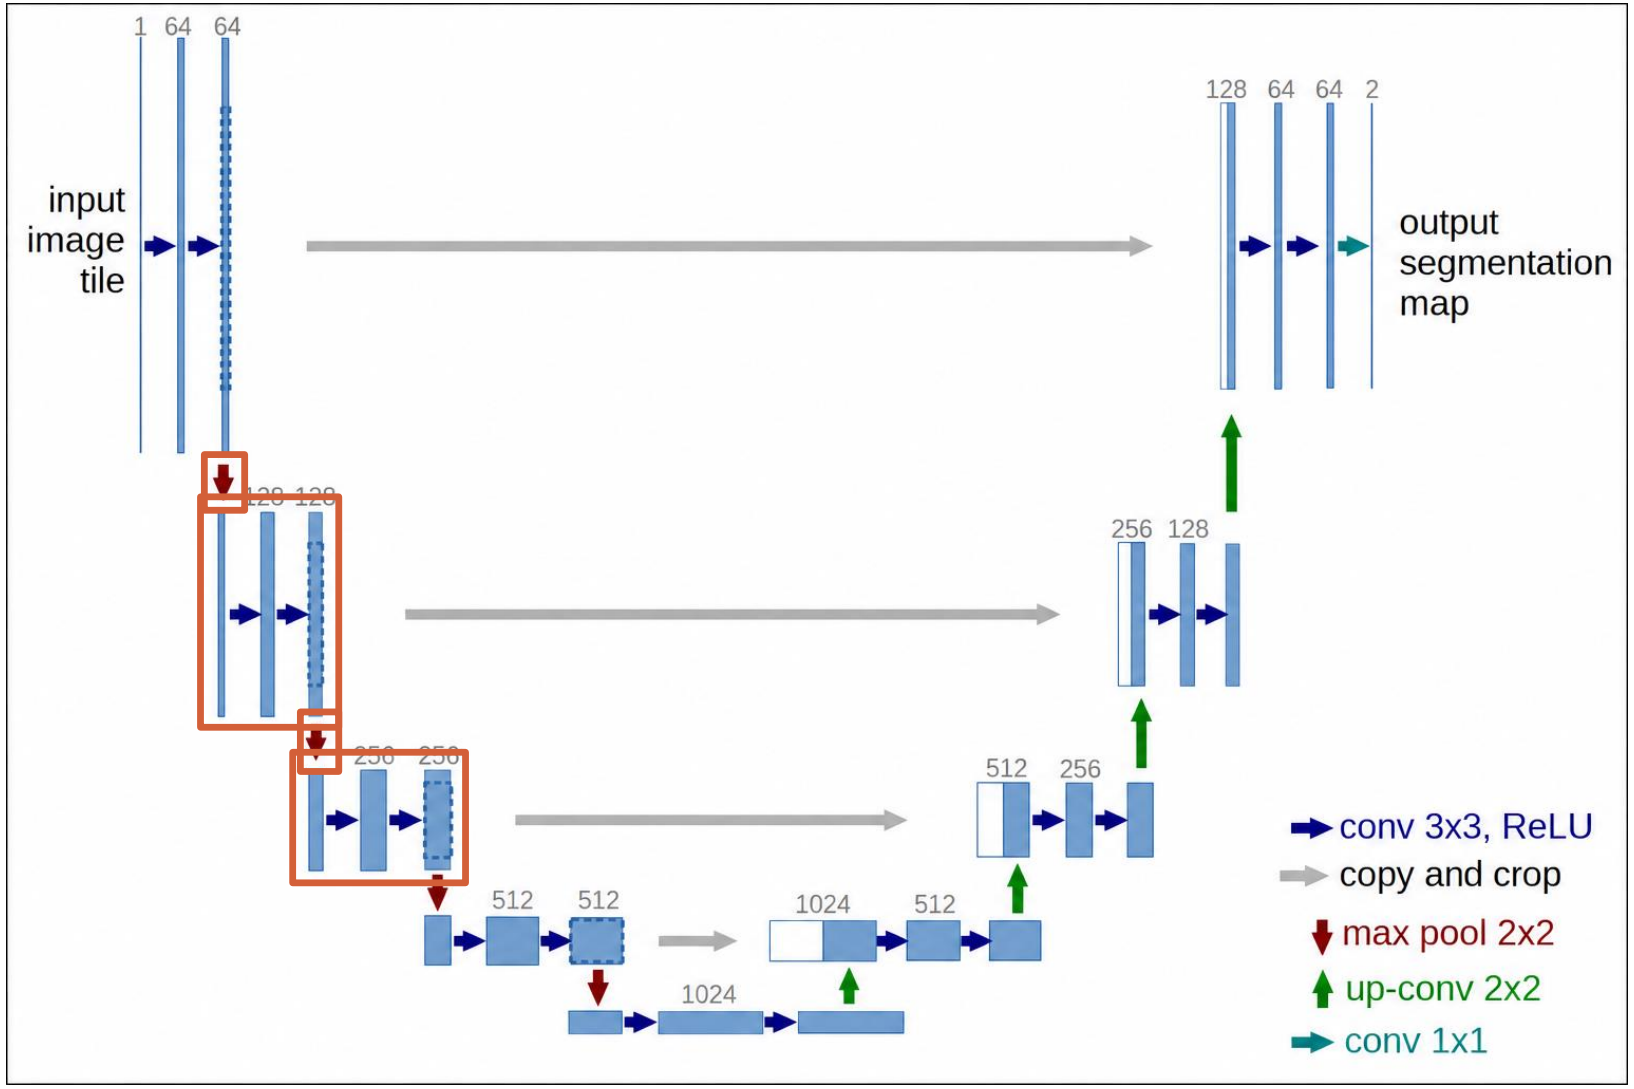
Splot i aktywacja

Filtry tworzą mapy cech. ReLU dodaje nieliniowość.

Znaczenie kanałów

64 oznacza liczbę cech, a nie liczbę pikseli.

Enkoder: max pooling i kolejne skale



Max pool 2×2

Zmniejsza wysokość i szerokość map o połowę.

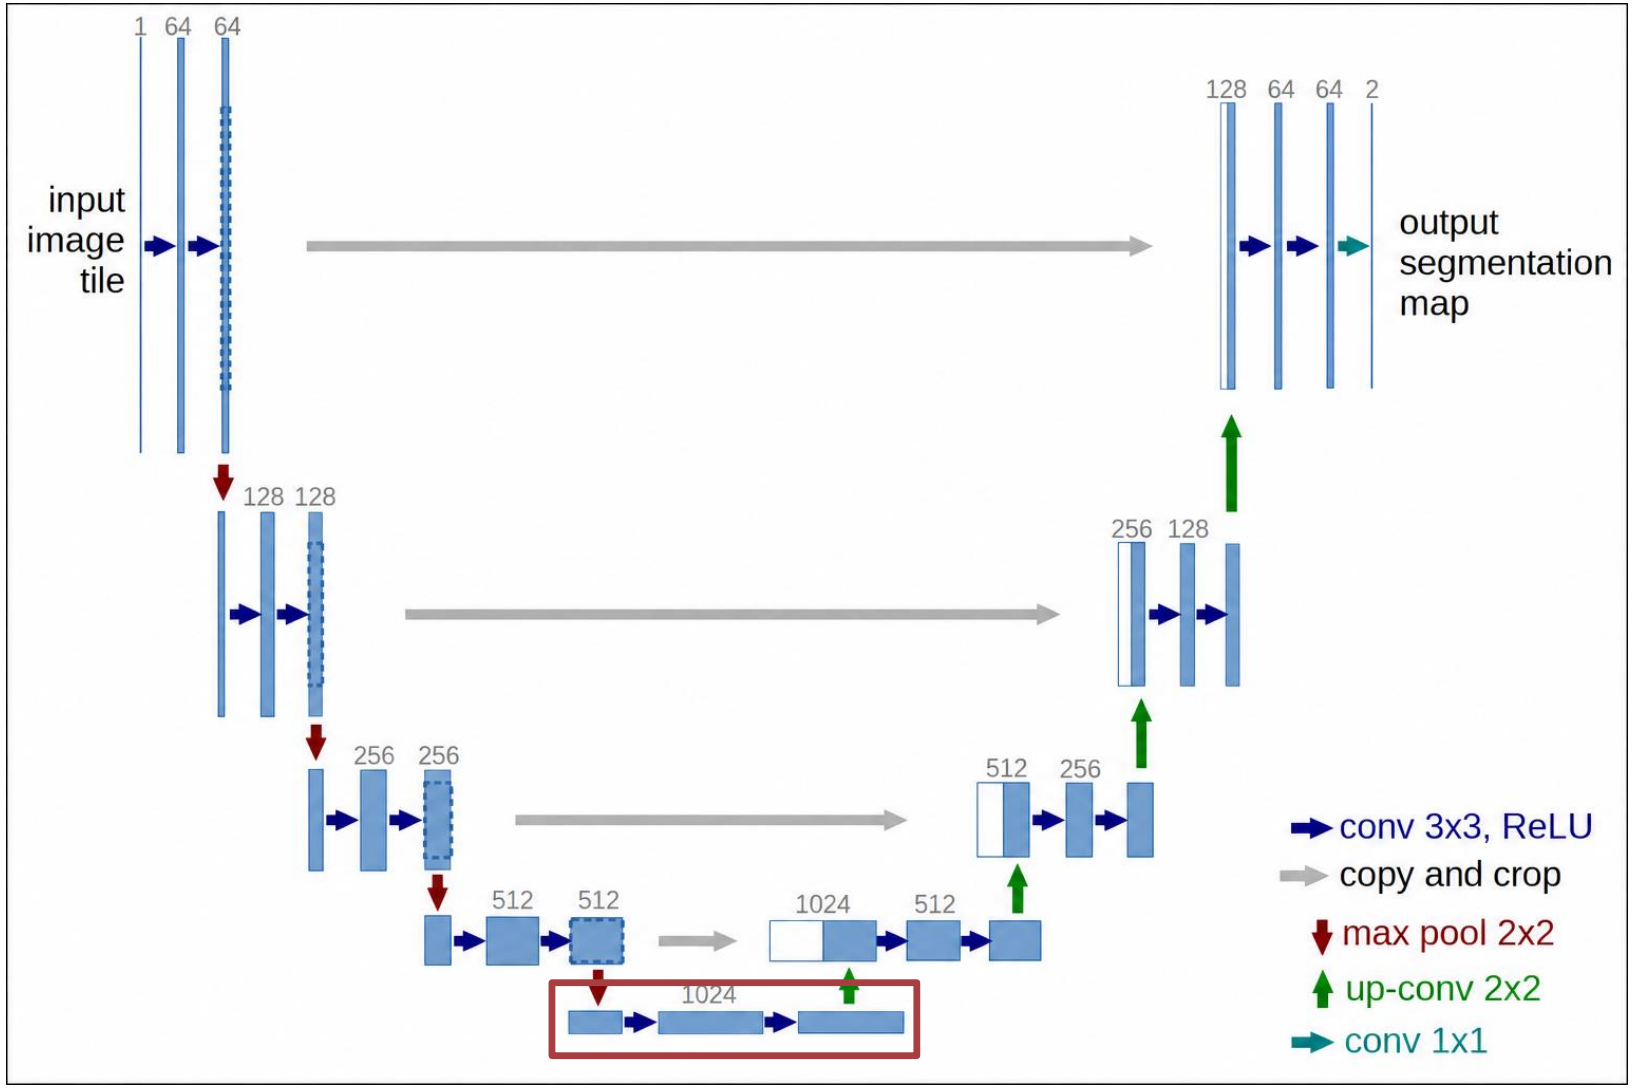
Następny blok splotów

Po operacji pooling sploty zwiększają liczbę kanałów: 64 do 128.

Kompromis

Szerszy kontekst przy mniejszej dokładności przestrzennej.

Wąskie gardło: najgłębsza reprezentacja



Najniższa rozdzielczość

Najmniejsze mapy przestrzenne w całej sieci.

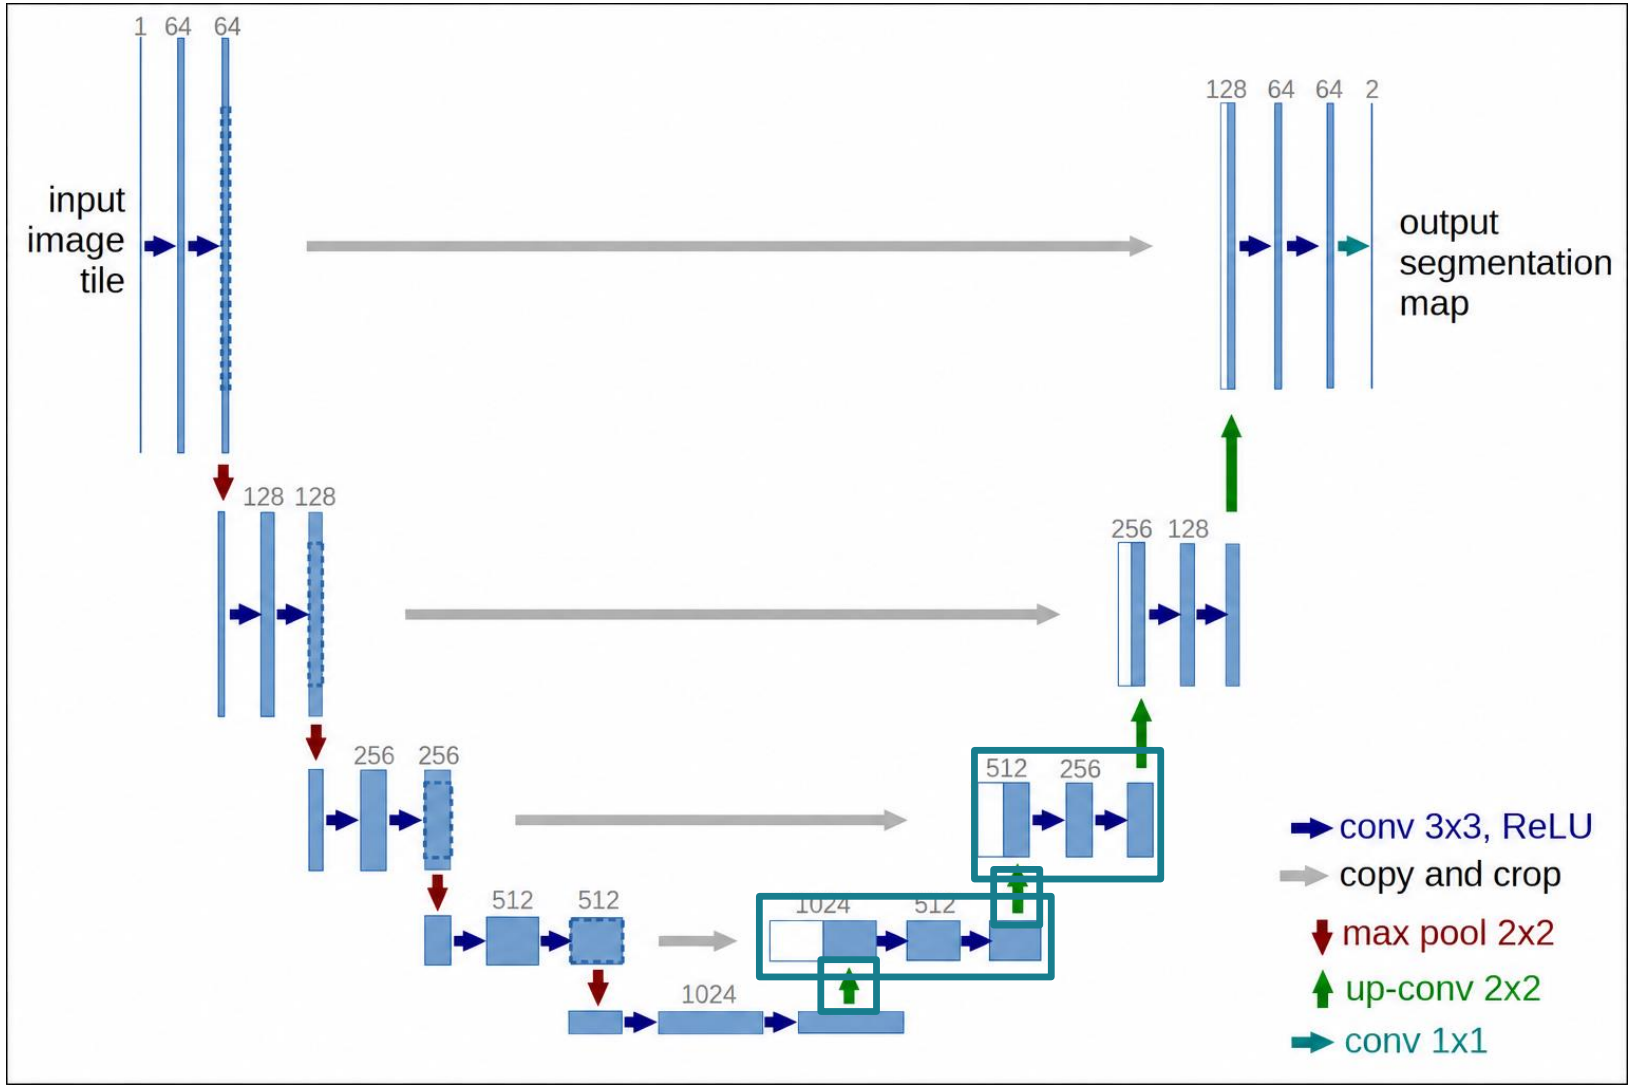
Dużo kanałów

Sploty tworzą 1024 kanały cech.

Rola tego etapu

Reprezentacja szerokiego kontekstu przed odtwarzaniem maski.

Dekoder: up-conv i odtwarzanie rozdzielczości



Up-conv 2×2

Zwiększa wysokość i szerokość map dwukrotnie.

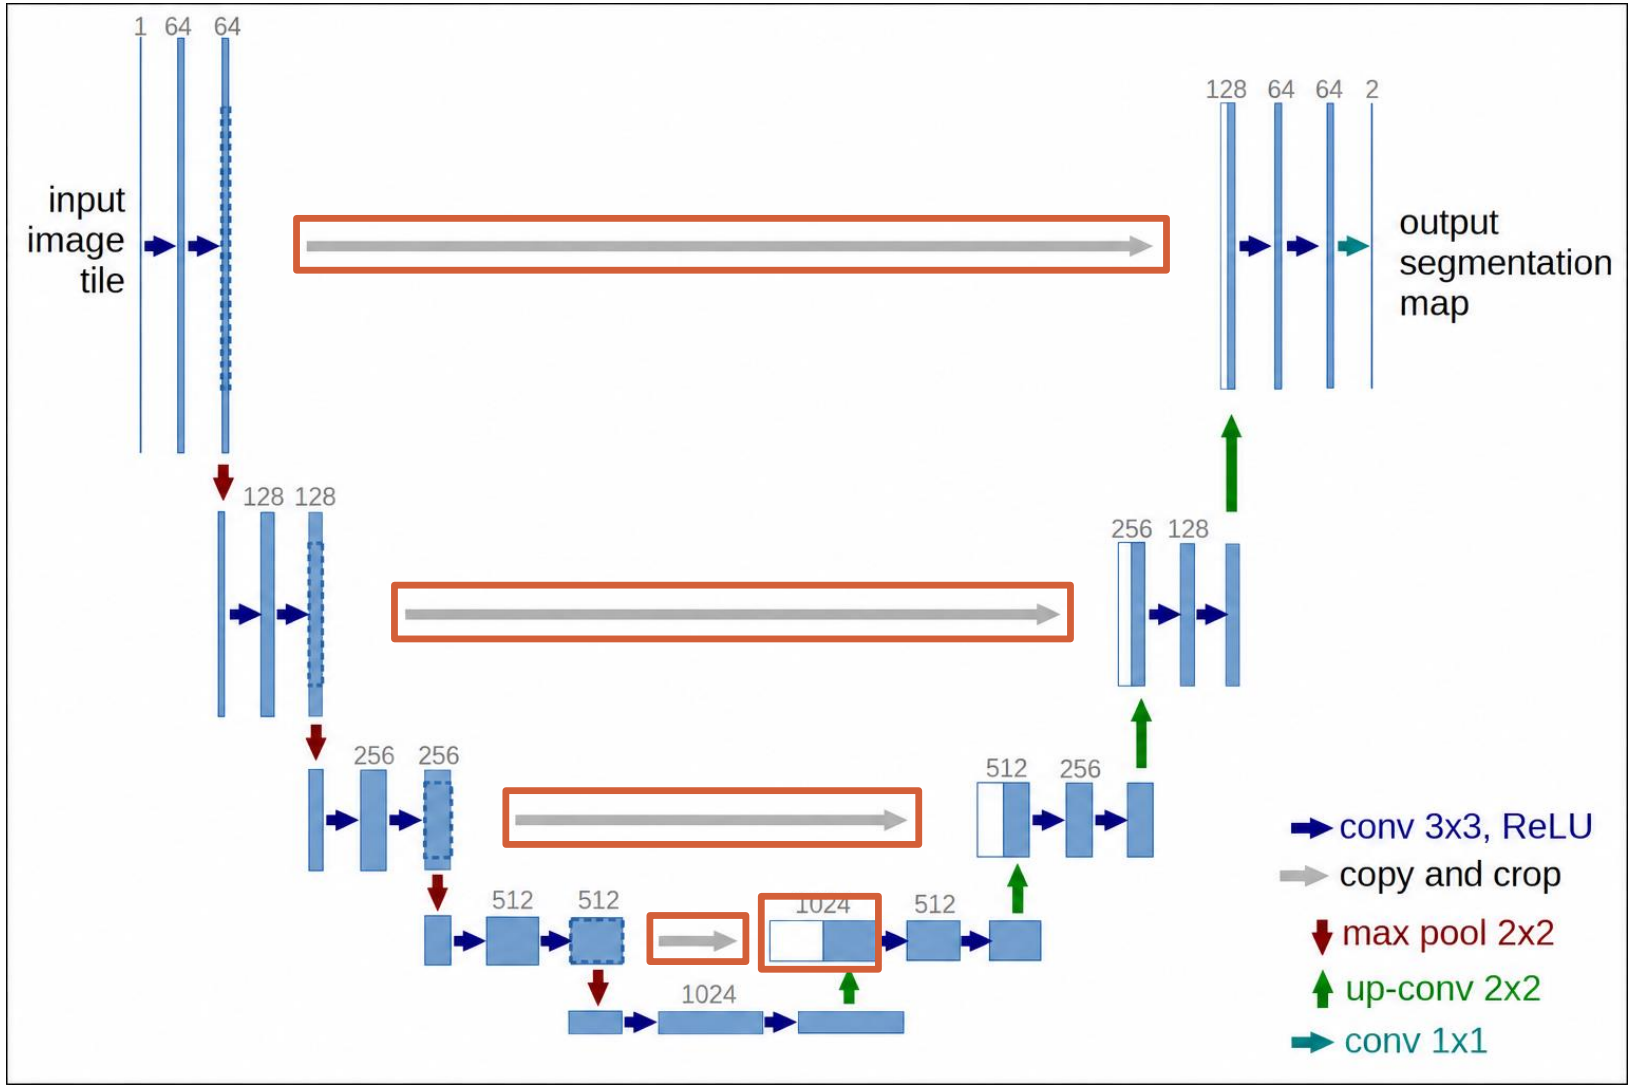
Zmiana kanałów

W tym kroku: 1024 do 512 kanałów.

Dalsze przetwarzanie

Po połączeniu z enkoderem dwa sploty dopracowują cechy.

Połączenia skrótowe: kopiowanie, crop i konkatenacja



Szare strzałki

Przenoszą cechy enkodera do odpowiadającej skali dekodera.

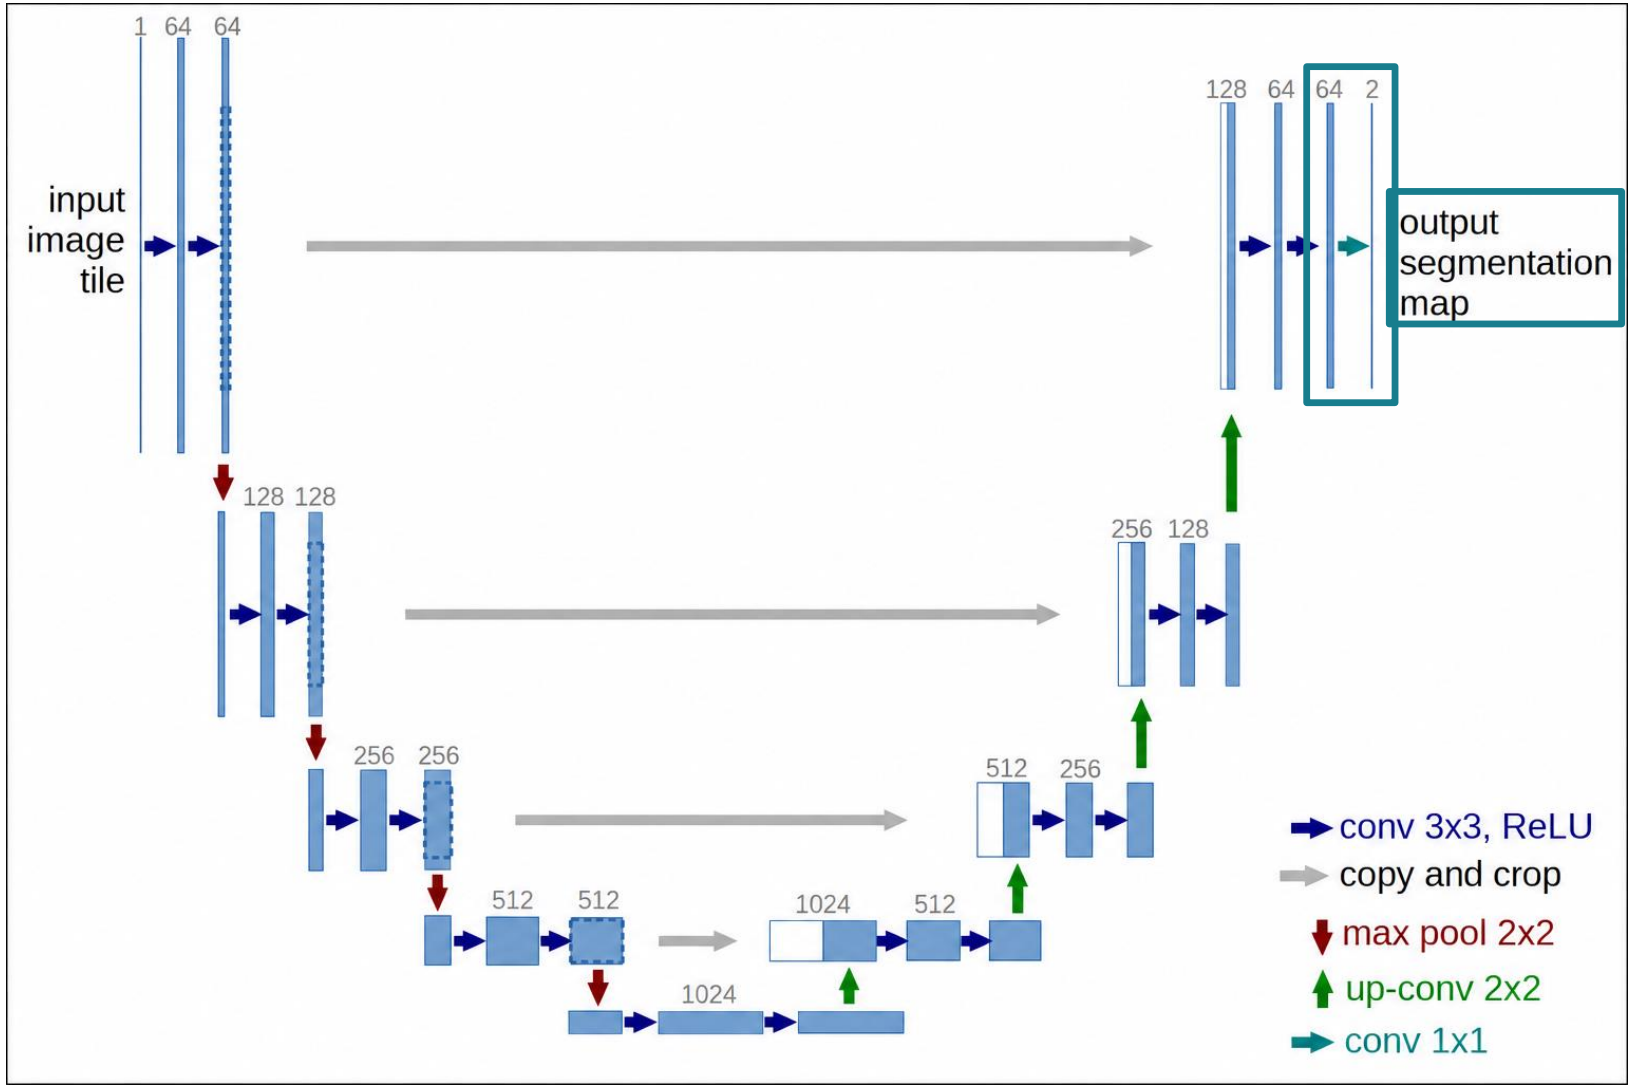
Crop

Przycięcie wyrównuje rozmiary przestrzenne map.

Konkatenacja

Łączenie po kanałach: 512 + 512 daje 1024 kanały.

Warstwa 1×1: wynik dla każdego piksela



Ostatni splot 1×1

Przekształca 64 cechy w 2 wyniki klas dla każdego położenia.

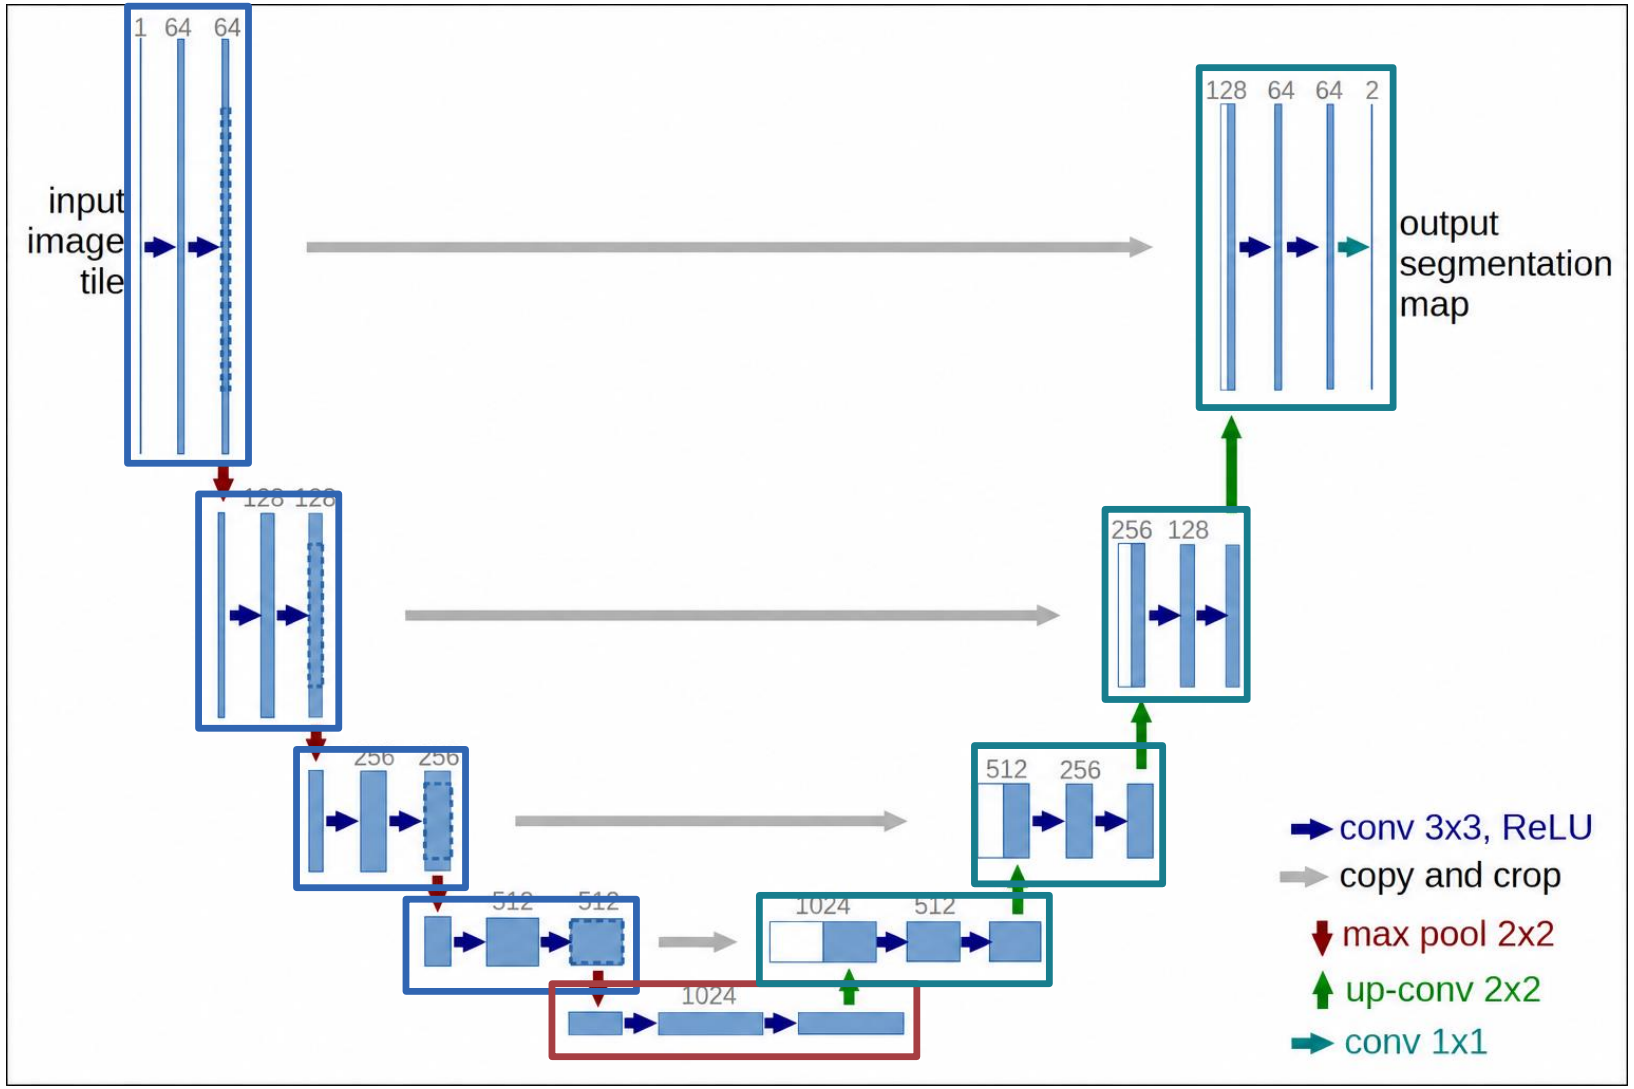
Dwa kanały wyjściowe

Każde położenie otrzymuje wynik dla każdej z 2 klas.

Mapa etykiet

Softmax daje prawdopodobieństwa, argmax wybiera klasę.

U-Net: jak powstaje mapa klas?



Enkoder

Buduje cechy w wielu skalach: 64, 128, 256 i 512 kanałów.

Wąskie gardło i skip

1024 kanały na dole. Połączenia skrótowe dostarczają dokładniejsze cechy.

Dekoder i wyjście

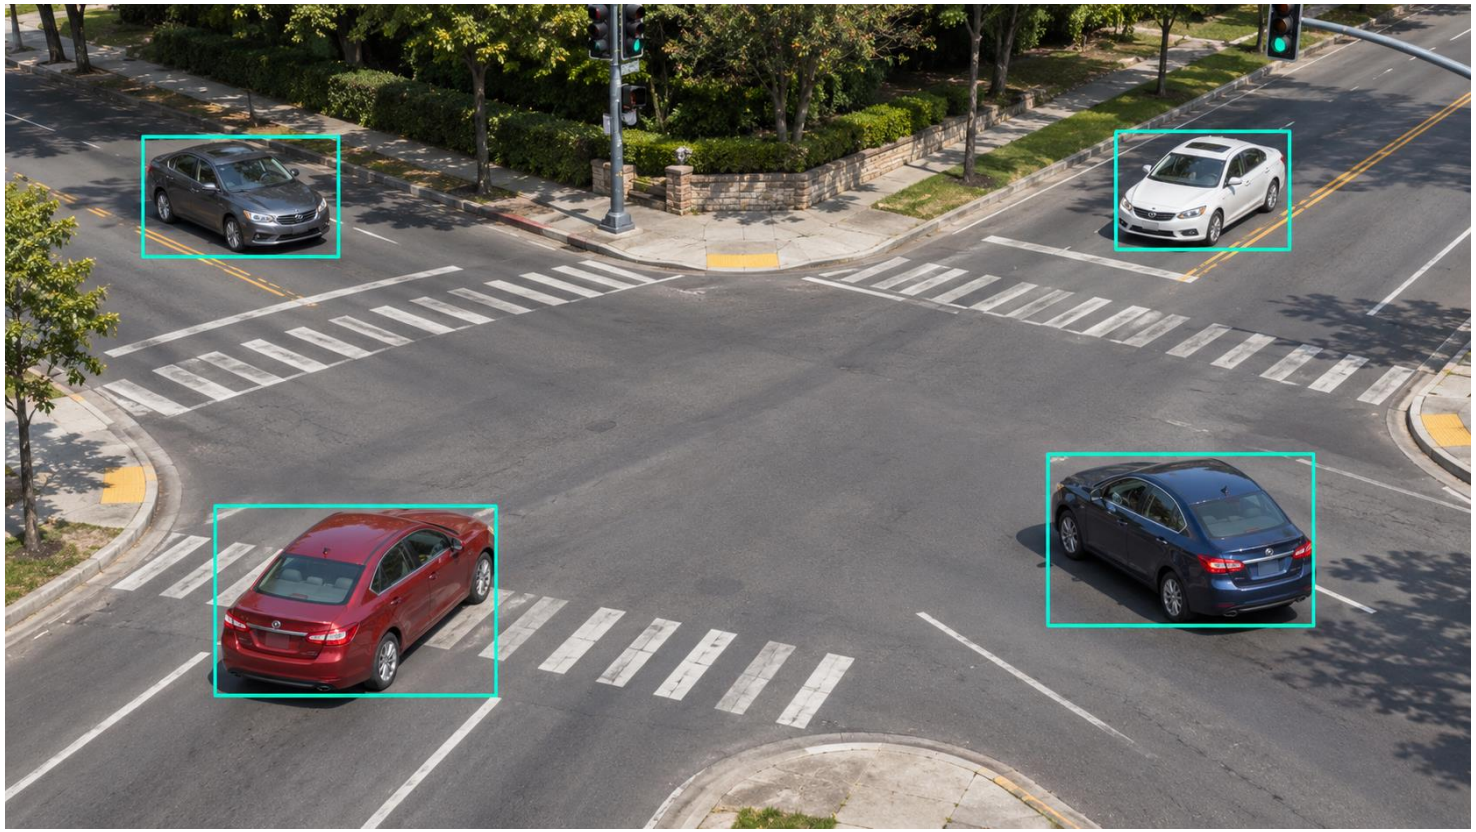
Łączy cechy i odtwarza lokalizację. Głowica 1×1 tworzy 2 kanały klas.



Zastosowania detekcji oraz segmentacji

Detekcja: ruch na drogach

Gdzie są pojazdy i ile ich widać?



Ilustracja poglądowa

Ramka wskazuje pojazd. Śledzenie pozwala liczyć przejazdy.

Przykładowy wynik

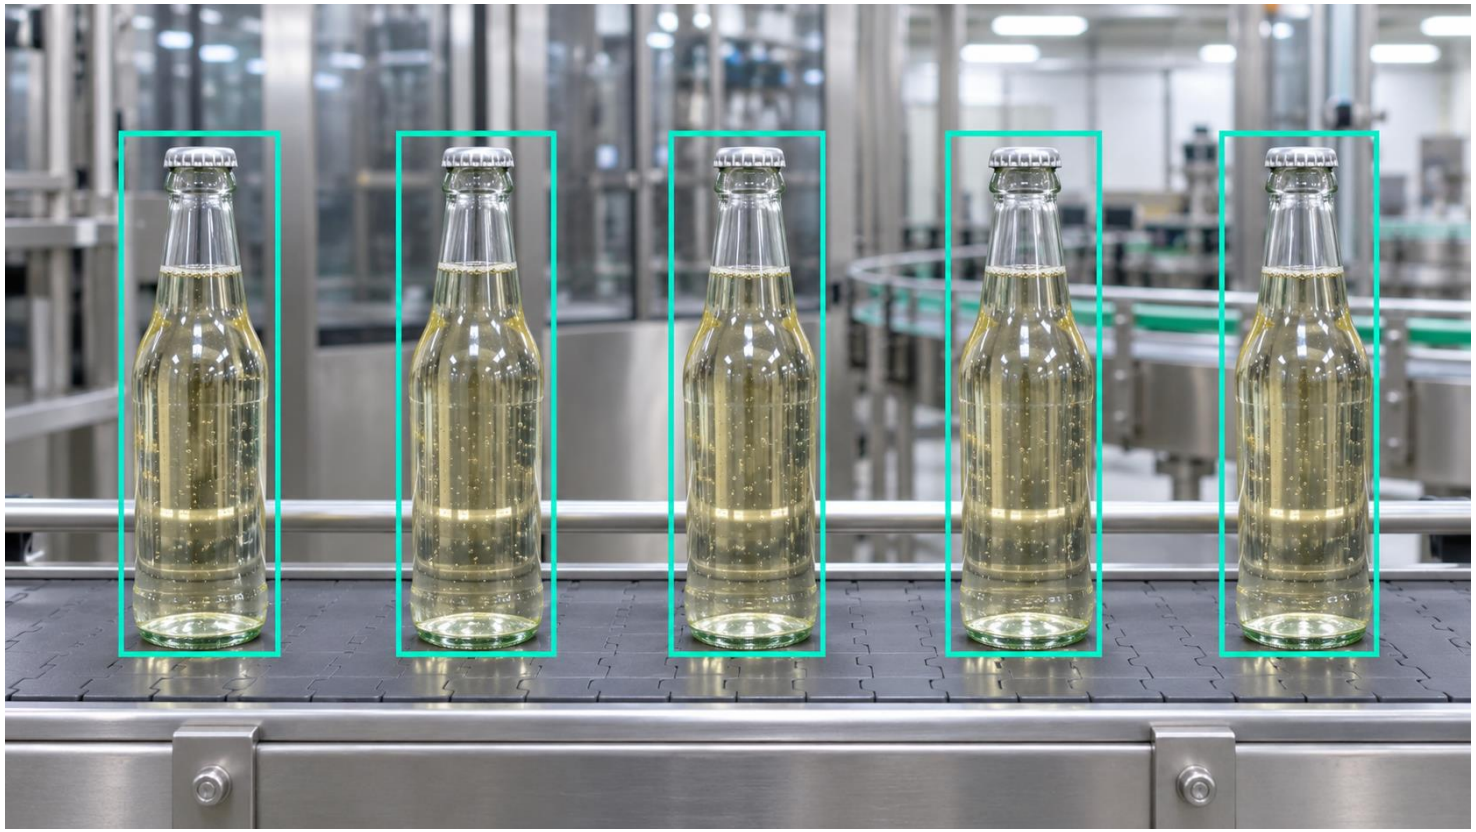
Osobna ramka dla każdego pojazdu.

Zastosowanie

Analiza natężenia ruchu i liczby przejazdów.

Detekcja: produkty na taśmie

Czy wszystkie produkty znajdują się na swoim miejscu?



Ilustracja poglądowa

Przykładowy wynik

Klasa „butelka” i położenie każdej sztuki.

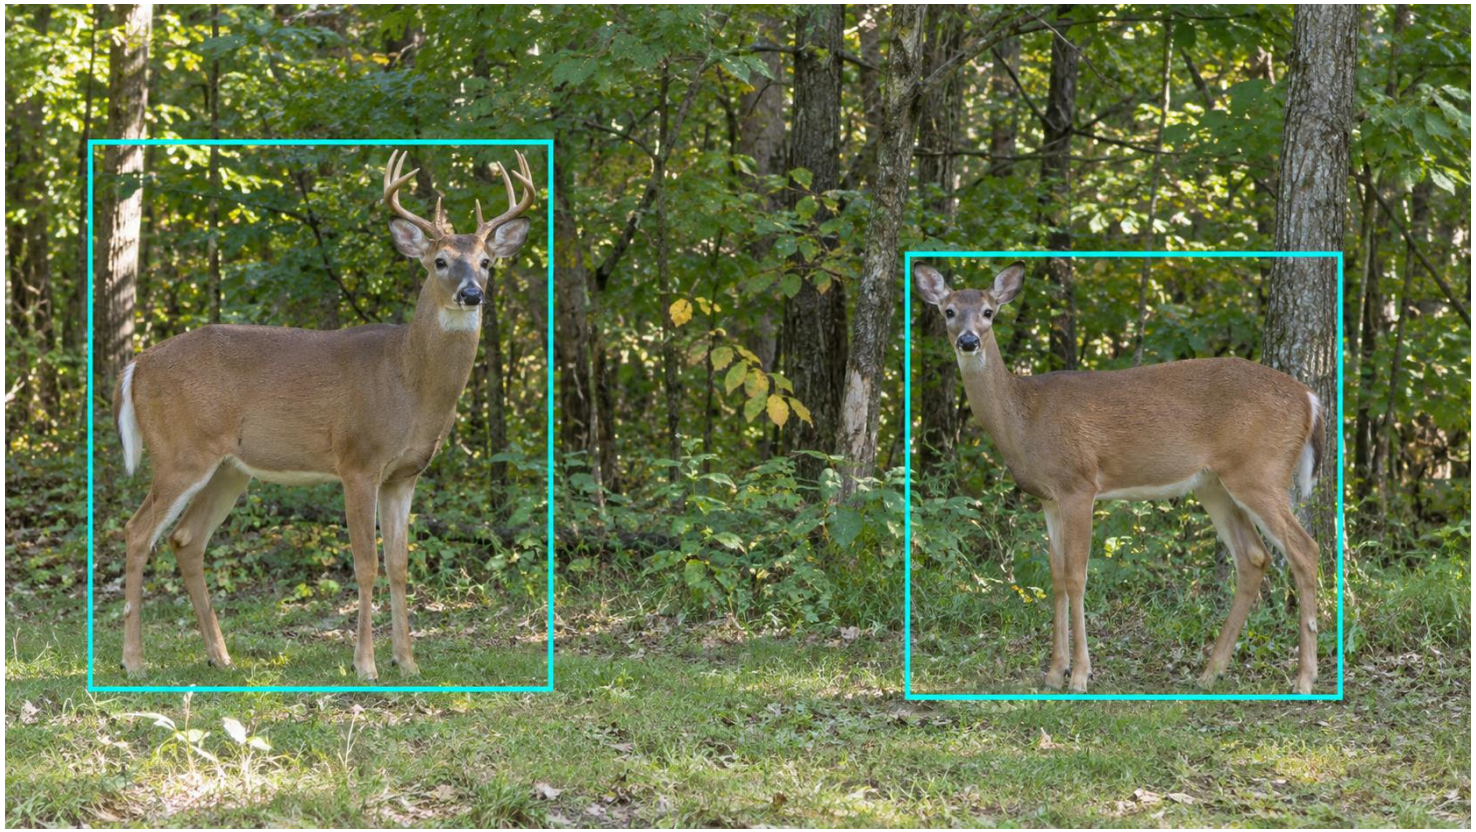
Zastosowanie

Zliczanie produktów i sprawdzanie kompletności.

Liczba wykryć pomaga zauważyć brakujące elementy.

Detekcja: obserwacja zwierząt

Które zdjęcia z fotopułapki warto przejrzeć?



Ilustracja poglądowa

Przykładowy wynik

Ramki w miejscach, gdzie widać zwierzęta.

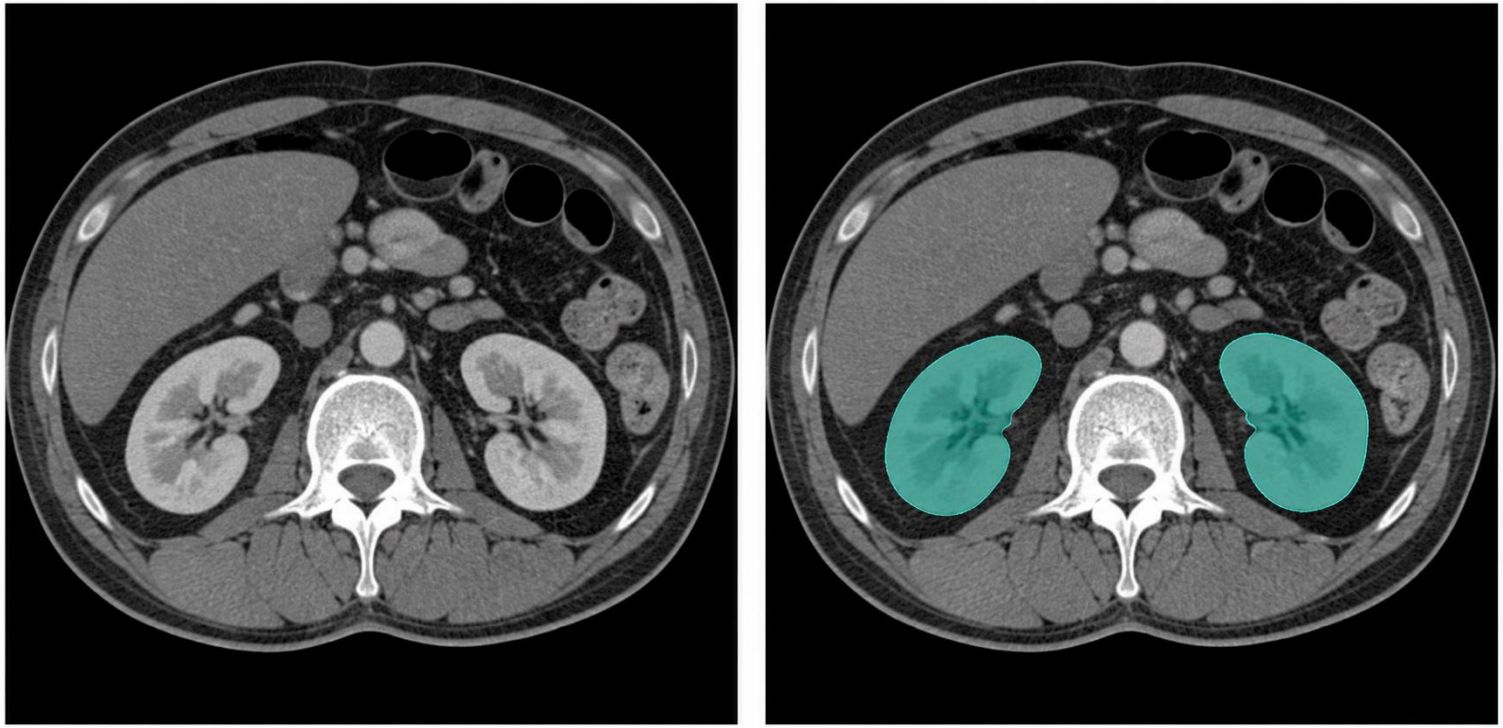
Zastosowanie

Odsiewanie pustych zdjęć i analiza obserwacji.

Znalezienie zwierzęcia i rozpoznanie gatunku to różne cele.

Segmentacja: obrazy medyczne

Które piksele należą do narządu?



Syntetyczny przekrój TK i przykładowa maska

Przykładowy wynik

Maska opisująca obszar i granice nerek.

Zastosowanie

Pomiary obszaru, a z wielu przekrojów także objętości.

Dokładne granice pomagają mierzyć narząd.

Segmentacja: mapowanie wody

Jaki obszar zajmuje woda na obrazie lotniczym?



Ilustracja poglądowa

Do obliczenia powierzchni w m^2 potrzebna jest skala obrazu.

Przykładowy wynik

Maska pikseli należących do wody.

Zastosowanie

Szacowanie zasięgu zalania i analiza zmian.

Segmentacja: osoba i tło

Jak zmienić tło podczas rozmowy wideo?



Ilustracja poglądowa

Maska powinna podążać za sylwetką, również przy włosach.

Przykładowy wynik

Maska oddzielająca osobę od otoczenia.

Zastosowanie

Rozmycie lub podmiana tła na nagraniu.

Ramka czy maska?

Najpierw ustalamy, jakiej odpowiedzi potrzebujemy.

Cel	Potrzebny wynik	Zadanie
Policzyć auta na zdjęciu	Osobna ramka dla każdego auta	Detekcja
Zmierzyć obszar wody	Dokładny obszar pikseli wody	Segmentacja
Zmienić tło rozmowy	Piksele osoby i tła	Segmentacja
Policzyć komórki i poznać ich kształty	Osobna maska każdej komórki	Segmentacja instancji

Potrzebujemy położenia obiektu czy także jego dokładnego kształtu?

Dziękuję za uwagę! ☺

Kontakt: szymon.plotka@uj.edu.pl