



Uniwersytet
Wrocławski

eXplainable Artificial Intelligence

Wykład szkoleniowy OAI III

Klaudia Dynak

Instytut Informatyki, Uniwersytet Wrocławski

Interpretowalność a Wyjaśnialność AI

Systemtyka Metod Wyjaśnialnej Sztucznej Inteligencji

Najważniejsze Metody

- Surogaty i LIME

- Wartości Shapleya i SHAP

- Mapy Istotności i Grad-CAM

Ewaluacja XAI

Interpretowalność a Wyjaśnialność AI


Takie, których wewnętrzne działanie jest w pełni zrozumiałe i możliwe do prześledzenia dla człowieka.

- regresja liniowa
- drzewa decyzyjne
- regresja logistyczna
- k najbliższych sąsiadów

Silnie ekspresywne modele, których działanie jest niemożliwe do prześledzenia i pełnego zrozumienia dla człowieka.

- sieci neuronowe
- lasy losowe
- XGBoost, LightGBM
- modele z nieliniowymi jądrami (np. SVM)


Kompromis między wyjaśnialnością a ekspresywnością



Źródło: Sajid Ali et al., Explainable Artificial Intelligence (XAI): What we know and what is left to attain

Trustworthy Artificial Intelligence, Information Fusion, 2023, <https://doi.org/10.1016/j.inffus.2023.101805>.

Interpretowalność a Wyjaśnialność AI




Źródło: Sajid Ali et al., Explainable Artificial Intelligence (XAI): What we know and what is left to attain

Trustworthy Artificial Intelligence, Information Fusion, 2023, <https://doi.org/10.1016/j.inffus.2023.101805>.

Systemtyka Metod Wyjaśnialnej Sztucznej Inteligencji

Wyjaśnialność na różnych etapach modelowania



Źródło: Sajid Ali et al., Explainable Artificial Intelligence (XAI): What we know and what is left to attain

Trustworthy Artificial Intelligence, Information Fusion, 2023, <https://doi.org/10.1016/j.inffus.2023.101805>.


- Wyjaśnienia globalne – ogólne działanie modelu
 - Jak w przybliżeniu działa model?
 - Które cechy są najistotniejsze dla modelu?
 - Jak wartości danej cechy wpływają na predykcje?
 - Jakie interakcje między zmiennymi i koncepty zostały zauważone przez model?
- Wyjaśnienia lokalne – predykcja dla konkretnej instancji
 - Z czego wynika predykcja dla zadanej obserwacji?
 - Co musiałoby się zmienić, żeby zmieniła się predykcja modelu?
 - Które cechy przesądziły o takiej predykcji?
 - Jak poszczególne cechy przekładają się na finalny wynik?

Najważniejsze Metody

Najważniejsze Metody

Surogaty i LIME

Local Interpretable Model-agnostic Explanations




Źródło: <https://ema.drwhy.ai/LIME.html>

TBA: demo

Najważniejsze Metody

Wartości Shapleya i SHAP




Źródło: <https://christophm.github.io/interpretable-ml-book/shapley.html>

TBA: demo + jak czytać wykresy

Najważniejsze Metody

Mapy Istotności i Grad-CAM

Gradient w uczeniu sieci nueronowych



TBA: demo (i czym to się różni)

Ewaluacja XAI



Uniwersytet
Wrocławski

eXplainable Artificial Intelligence

Wykład szkoleniowy OAI III

Klaudia Dynak

Instytut Informatyki, Uniwersytet Wrocławski