

Rozumienie częstotliwości

Iwona Christop

16 maja 2026 r.

Co już wiemy z poprzedniego wykładu?

- Mikrofon daje sygnał zmieniający się w czasie.
- Po próbkowaniu zapisujemy go jako ciąg próbek x_n .
- Każda próbka mówi, jaka była amplituda w danej chwili.
- Wykres sygnału pokazuje więc **amplitudę jako funkcję czasu**.

Wykres w czasie dobrze pokazuje:

- kiedy sygnał zaczyna się i kończy,
- czy jest głośniejszy czy cichszy,
- czy ma nagły impuls, ciszę albo długie wybrzmienie.


Ale słabo pokazuje:

- jakie częstotliwości są obecne,
- która część sygnału odpowiada za wysokość dźwięku,
- czy w dźwięku jest jeden ton, czy wiele tonów naraz.

Dwa sygnały mogą:

- mieć podobny zakres amplitudy,
- trwać tyle samo,
- wyglądać na pierwszy rzut oka podobnie,

a mimo to brzmieć zupełnie inaczej, bo zawierają inne częstotliwości.



W dziedzinie częstotliwości nie pytamy jaka była amplituda w chwili t , tylko:

- jakie częstotliwości są obecne,
- jak silna jest każda z nich,
- jaka jest ich faza.

Dziedzina czasu

- oś pozioma (x) - czas
- oś pionowa (y) - amplituda

Dziedzina częstotliwości

- oś pozioma (x) - częstotliwość
- oś pionowa (y) - amplituda, natężenie lub faza

Składowa sinusoidalna to bardzo prosty sygnał okresowy opisany przez amplitudę, częstotliwość i fazę.

$$x(t) = A \sin(2\pi f t + \varphi)$$

gdzie A - amplituda, f - częstotliwość, φ - faza.

Idea Fouriera jest następująca: **złożony sygnał można opisać jako sumę prostszych składowych sinusoidalnych.**

Dlaczego właśnie sinusoidy?

- Są bardzo proste matematycznie.
- Dobrze opisują ruch okresowy.
- Układy fizyczne często reagują na nie w przewidywalny sposób.
- Z wielu sinusoid można złożyć sygnał znacznie bardziej złożony.

Harmoniczne to składowe, których częstotliwości są całkowitymi wielokrotnościami częstotliwości podstawowej.


Jeśli częstotliwość podstawowa wynosi f_0 , to harmoniczne leżą przy $f_0, 2f_0, 3f_0, 4f_0, \dots$

Przykładowo, dla częstotliwości podstawowej $f_0 = 200 \text{ Hz}$, nasze składowe harmoniczne będą wynosić 200 Hz, 400 Hz, 600 Hz, 800 Hz, itd.

Widmo sygnału to opis tego, jak energia, amplituda lub natężenie sygnału rozkłada się pomiędzy częstotliwości.

W praktyce widmo pomaga odpowiedzieć na pytania:

- gdzie są główne piki częstotliwości,
- które częstotliwości dominują,
- czy sygnał jest tonalny, harmoniczny czy szumowy.



Transformata Fouriera odpowiada na pytanie:

Jak silnie każda częstotliwość jest obecna w sygnale?

W praktyce wykonuje trzy kroki myślowe:

1. bierze wiele możliwych częstotliwości,
2. sprawdza zgodność sygnału z każdą z nich,
3. zapisuje wynik jako widmo.

Ciągła transformata Fouriera (CTFT)

Używamy jej wtedy, gdy myślimy o sygnale ciągłym $x(t)$.

$$X(f) = \int_{-\infty}^{\infty} x(t) e^{-i2\pi ft} dt$$

gdzie $x(t)$ to sygnał w czasie, a $X(f)$ to jego opis w częstotliwościach.

Wynik mówi, co dzieje się dla każdej częstotliwości f .

Jeśli sygnał zawiera:

- silną składową 100 Hz,
- słabszą składową 300 Hz,
- prawie nic przy 1000 Hz,

to w $X(f)$ zobaczymy właśnie taki rozkład.



CTFT jest więc narzędziem teoretycznym, które:

- bardzo dobrze opisuje sygnały ciągłe,
- buduje intuicję,
- stanowi punkt wyjścia do wersji dyskretnej używanej w komputerze.

Założmy, że nagrywamy dźwięk podobny do samogłoski albo dźwięku instrumentu.

W dziedzinie czasu widzimy złożoną falę, a w dziedzinie częstotliwości możemy zobaczyć:

- pik przy f_0 ,
- kolejne piki przy $2f_0, 3f_0, 4f_0$,
- różne wysokości tych pików.



W praktyce nie mamy idealnego $x(t)$, tylko skończony ciąg próbek:

$$x_0, x_1, x_2, \dots, x_{N-1}$$

To oznacza, że komputer:

- pracuje na sygnale dyskretnym,
- analizuje zwykle skończony fragment sygnału,
- potrzebuje wersji Fouriera dostosowanej do próbek.

Dyskretna transformata Fouriera (DFT)

DFT zamienia skończony ciąg próbek w skończony zestaw współczynników opisujących obecność określonych częstotliwości.

Najczęściej zapisujemy ją jako:

$$X_k = \sum_{n=0}^{N-1} x_n \cdot e^{-i2\pi \frac{k}{N} n}$$

gdzie n - indeks próbki, k - indeks częstotliwości, N - liczba próbek analizowanego fragmentu.

Wynik X_k można czytać jako odpowiedź dla kolejnych *koszyków częstotliwości*, czyli **binów**.

Jeśli częstotliwość próbkowania wynosi f_s , to biny odpowiadają częstotliwościom:

$$0, \frac{f_s}{N}, \frac{2f_s}{N}, \dots, \frac{(N-1)f_s}{N}$$

Dla sygnałów rzeczywistych w praktyce najczęściej oglądamy tylko zakres od 0 do $\frac{f_s}{2}$.

Najważniejsza intuicja:

- większe N daje gęstsze biny,
- gęstsze biny dają lepszą rozdzielczość częstotliwościową.

Szybka transformata Fouriera (FFT)

FFT to szybki algorytm obliczania DFT.

Najważniejsza idea:

- DFT mówi **co** liczymy
- FFT mówi **jak policzyć to szybciej**

Dlaczego to ważne?

- mniej operacji,
- szybsza analiza,
- możliwość pracy niemal w czasie rzeczywistym.

Jedno widmo opisuje zwykle **cały analizowany fragment sygnału naraz**.

To działa dobrze dla sygnałów prawie stałych w czasie, ale gorzej dla sygnałów zmiennych, np.: mowy, muzyki, świergotu ptaka, syreny o zmieniającej się wysokości.

Widmo mówi **jakie częstotliwości są obecne**, ale nie mówi jeszcze dobrze **kiedy** się pojawiają.

Chcemy jednocześnie wiedzieć:

- **co** jest w sygnale pod względem częstotliwości,
- **kiedy** to występuje.

Dlatego używamy reprezentacji czas-częstotliwość, której najpopularniejszym przykładem jest **spektrogram**.

Krótkoczasowa transformata Fouriera (STFT)

Idea STFT jest prosta:

1. bierzemy krótki fragment sygnału,
2. liczymy dla niego DFT,
3. przesuwamy się o kawałek dalej,
4. liczymy DFT ponownie,
5. powtarzamy ten proces wiele razy.

Wynikiem jest seria lokalnych widm, czyli **informacja o częstotliwościach w kolejnych momentach czasu.**

Okno to krótki fragment sygnału wybrany do lokalnej analizy częstotliwościowej.


Najczęściej:

- mnożymy sygnał przez funkcję okna,
- wygaszamy brzegi fragmentu,
- zmniejszamy niepożądane artefakty w widmie.

Najpopularniejsze typy okien to prostokątne, Hann, Hamming.


Krótkie okno:

- lepiej lokalizuje zdarzenia w czasie,
- gorzej rozróżnia bliskie częstotliwości.



Długie okno:

- lepiej rozróżnia częstotliwości,
- gorzej lokalizuje szybkie zmiany w czasie.



Spektrogram to obraz pokazujący, jak widmo sygnału zmienia się w czasie.

Zwykle:

- oś pozioma: czas,
- oś pionowa: częstotliwość,
- kolor lub jasność: siła składowej.

Spektrogram jest najczęściej tworzony właśnie z użyciem STFT.





Jak czytać spektrogram?

Szukamy trzech rzeczy:

- **położenia w poziomie** - kiedy coś się dzieje,
- **położenia w pionie** - jaka to częstotliwość,
- **koloru lub jasności** - jak silna jest składowa.

Typowe wzory:

- poziome linie - stabilne tony,
- pionowe smugi - krótkie impulsy,
- ukośne linie - częstotliwość rośnie lub maleje w czasie.



W analizie częstotliwościowej często patrzymy nie tylko na amplitudę, ale na **natężenie**.

Intuicyjnie:

- większa amplituda ciśnienia zwykle oznacza większe natężenie,
- natężenie jest związane z energią niesioną przez falę,
- dla wielu zastosowań używamy wielkości proporcjonalnej do średniego kwadratu ciśnienia.

W uproszczeniu możemy powiedzieć, że $I \propto \langle p^2 \rangle$.

Decybel (dB) to skala logarytmiczna używana do opisu stosunków natężenia, ciśnienia lub amplitudy.

Poziom natężenia:


$$L_I = 10 \lg \left(\frac{I}{I_0} \right) \text{ [dB]}$$

Poziom amplitudy:

$$L_A = 20 \log_{10} \left(\frac{A}{A_0} \right) \text{ [dB]}$$

Dlaczego używamy decybeli?

- zakres wartości bywa bardzo szeroki,
- skala logarytmiczna jest czytelniejsza,
- lepiej odpowiada temu, jak odbieramy głośność,
- łatwiej dostrzec słabsze składowe obok bardzo silnych.



Skala liniowa:

- bardzo silne składowe mogą zdominować obraz,
- słabsze szczegóły stają się mało widoczne.

Skala logarytmiczna (dB):

- kontrast jest bardziej użyteczny,
- łatwiej zauważyć słabsze harmoniczne,
- łatwiej porównywać fragmenty o różnej sile.

Dlaczego spektrogramy mają znaczenie dla AI?

Dla modeli AI surowy sygnał w czasie bywa trudniejszy do analizy niż dobrze dobrana reprezentacja.

Spektrogram:

- porządkuje informację w czasie i częstotliwości,
- ujawnia wzory ważne dla mowy, muzyki i zdarzeń akustycznych,
- jest wygodny jako wejście do klasyfikatorów i sieci neuronowych.

Prosty sygnał

```
import numpy as np
from scipy import signal

fs = 16000
seg_t = np.linspace(0, 0.5, fs // 2, endpoint=False)

x1 = np.sin(2 * np.pi * 440 * seg_t)           # Ton 440 Hz
x2 = 0.6 * np.sin(2 * np.pi * 880 * seg_t)    # Ton 880 Hz o mniejszej amplitudzie
x3 = signal.chirp(seg_t, f0=300, f1=3000, t1=0.5) # Chirp (sygnał o rosnącej częstotliwości)

x = np.concatenate([x1, x2, x3])
```

Python


Obliczenie FFT

```
import matplotlib.pyplot as plt

freq = np.fft.rfftfreq(len(x), d=1 / fs)
X = np.fft.rfft(x)
amp = np.abs(X)

plt.figure(figsize=(8, 4))
plt.plot(freq, amp)
plt.xlim(0, 4000)
plt.xlabel("Częstotliwość [Hz]")
plt.ylabel("Amplituda")
```

Python




```
freq = array([0.00000000e+00, 6.66666667e-01, 1.33333333e+00, ...,
              7.99866667e+03, 7.99933333e+03, 8.00000000e+03], shape=(12001,))
```

```
X = array([ 8.08663089e-02+0.j, 7.85270216e+00+2.5158285j,
           7.90175616e+00-2.54478908j, ..., -8.14826785e-01+0.48645129j,
          -8.14997417e-01-0.48606876j, 1.50314892e-05+0.j],
          shape=(12001,))
```

Spektrogram

```
f, tt, Sxx = signal.spectrogram(  
    x, fs=fs, window="hann", nperseg=512,  
    noverlap=384  
)  
Sxx_db = 10 * np.log10(Sxx + 1e-12)  
  
plt.figure(figsize=(8, 4))  
plt.pcolormesh(tt, f, Sxx_db, shading="gouraud",  
    cmap="magma")  
plt.ylim(0, 4000)  
plt.xlabel("Czas [s]")  
plt.ylabel("Częstotliwość [Hz]")  
plt.colorbar(label="Poziom [dB]")
```

Python



Podsumowanie

- Dziedzina czasu pokazuje, **jak sygnał zmienia się w czasie**.
- Dziedzina częstotliwości pokazuje, **z jakich częstotliwości składa się sygnał**.
- Widmo jest dobre dla opisu składu częstotliwościowego całego fragmentu.
- CTFT jest wersją ciągłą, DFT wersją dyskretną, a FFT szybkim algorytmem.
- Dla sygnałów zmiennych w czasie potrzebujemy STFT i spektrogramu.
- Natężenie i decybele pomagają sensownie porównywać siłę składowych.
- Spektrogram jest jedną z podstawowych reprezentacji używanych w AI dla audio.